UNIVERSIDAD AUTÓNOMA METROPOLITANA

Análisis de la Dinámica de Transmisión del COVID-19 en México como un Sistema Físico No Lineal: Un Enfoque desde el Modelo SIR y Teoría de Sistemas Dinámicos

Proyecto Terminal I

Presenta:
Angel Omar García Hernández

Asesor:
Dr. Adrian Mauricio Escobar Ruiz

Agosto 2025

Resumen

La pandemia de COVID-19 en México se analiza bajo el paradigma de la física de sistemas dinámicos no lineales. Utilizando un modelo Susceptible-Infectado-Recuperado (SIR) como una aproximación de campo medio, este Proyecto Terminal reconstruye las trayectorias empíricas de las cinco grandes olas pandémicas en el espacio de fases. El modelo es rigurosamente calibrado con datos de vigilancia epidemiológica, incorporando una corrección fundamental por subregistro basada en encuestas nacionales de seroprevalencia (ENSANUT) y un parámetro de evasión inmune inferido numéricamente para las olas de Ómicron. Se emplea una simulación de Monte Carlo para cuantificar la evolución del número reproductivo básico (R_0), revelando una dinámica no monótona que alcanzó un máximo de $R_0 \approx 4{,}28$ con la variante Ómicron BA.1. La validación del modelo muestra que, si bien funciona como una robusta aproximación de primer orden, sus discrepancias sistemáticas con los datos son altamente informativas: la desviación en la primera ola constituye una evidencia cuantitativa del efecto de las intervenciones no farmac´euticas, mientras que los fallos en la predicción de la ola de Ómicron exponen los límites del formalismo SIR simple. Se concluye que el enfoque de la física no solo permite modelar la pandemia, sino que utiliza las fallas del modelo como una sonda teórica para entender la complejidad subyacente del sistema socio-sanitario real.

Palabras Clave: COVID-19, Modelo SIR, Sistemas Dinámicos, Espacio de Fases, Número Reproductivo Básico (R_0), Evasión Inmune, Simulación de Monte Carlo, Física Estadística.

Para la elaboración de este documento, se utilizó la asistencia de herramientas de inteligencia artificial generativa (Gemini de Google). Su rol se centró en tareas de apoyo como la reestructuración de párrafos, el refinamiento de la redacción para mejorar la claridad y la formalidad académica, y la depuración de código. El diseño de la investigación, el análisis de los datos, la interpretación de los resultados y las conclusiones aquí presentadas son enteramente obra del autor.

Agradecimientos

Índice general

Resumen **1**

Agradecimientos **3**

1. Introducción a la Física de las Pandemias **7**

1.1. La Pandemia como Objeto de Estudio de la Física 7

1.2. El Modelo SIR como Aproximación de Campo Medio 8

1.3. Hipótesis, Pregunta de Investigación y Objetivos 8

1.4. Estructura del Proyecto Terminal 9

2. Marco Teórico – La Epidemiología como Sistema Dinámico **11**

2.1. El Modelo SIR: Axiomas y Derivación Formal 11

2.1.1. Axiomas del Sistema 11

2.1.2. Ecuaciones de Movimiento 12

2.2. Estructura Geométrica de la Dinámica Epidémica 12

2.2.1. Invariante del Sistema y Reducción de Dimensionalidad 12

2.2.2. Espacio de Fases Normalizado 14

2.2.3. Nulclinas y Topología del Flujo 14

2.3. Puntos de Equilibrio y Análisis de Estabilidad Lineal 14

2.3.1. Estabilidad del DFE y la Condición de Invasión Epidémica 14

2.4. La Transición Epidémica como Bifurcación Transcrítica 16

2.5. Teorema del Tamaño Final de la Epidemia 16

2.6. Limitaciones del Modelo como Hoja de Ruta Analítica 16

3. Datos, Metodología y Calibración del Modelo **18**

3.1. Adquisición y Preprocesamiento de Datos: Aislamiento de la Señal Epidemiológica . . . 18
3.2. Definición Operacional de Olas: Un Criterio Topológico Objetivo . . . 19
3.3. Parametrización del Modelo . . . 19
3.3.1. Ajuste por Subregistro: Anclaje con Datos de Seroprevalencia (ENSANUT) . . . 19
3.3.2. Inferencia de S_0/N y la Falsación del Modelo de Inmunidad Permanente 21
3.4. Estimación de R_0: Cuantificación de la Incertidumbre con Monte Carlo . . . 21
3.4.1. Principio del Método: Crecimiento Exponencial . . . 23
3.4.2. Identificación de la Fase Exponencial . . . 23
3.4.3. Propagación de Incertidumbre con Monte Carlo . . . 24

4. Resultados y Validación Crítica del Modelo 26
4.1. Estimación de la Transmisibilidad Intrínseca (R_0) . . . 26
4.1.1. Valores Medios: La Narrativa de la Co-evolución Viral . . . 26
4.1.2. Cuantificación y Significado de la Incertidumbre . . . 28
4.2. Validación Cuantitativa: Métricas de Desempeño del Modelo . . . 29
4.3. Análisis Crítico de las Trayectorias en el Espacio de Fases . . . 29
4.3.1. Ola 1: La Firma Inequívoca de la Mitigación Externa . . . 29
4.3.2. Ola 2: El Régimen de Máxima Concordancia Clásica . . . 30
4.3.3. Ola 3 (Delta): La Firma del Comportamiento Adaptativo . . . 30
4.3.4. Ómicron y los Límites Estructurales del Modelo . . . 32

5. Discusión Física y Análisis Dinámico de la Pandemia 35
5.1. Síntesis y Justificación de Hallazgos Físicos . . . 35
5.2. El Paisaje Conceptual de la Dinámica Pandémica . . . 37
5.3. El Contrafactual Teórico: Análisis de la Cinética de los Compartimentos . . . 37
5.4. La Dinámica del Control: Análisis de la Evolución de R_t . . . 40
5.5. Recomendaciones Operativas y Políticas de Salud Pública . . . 40
5.6. Limitaciones, Advertencias y Verificación Futura . . . 43

6. Aplicación: Simulación de un Sistema de Alerta Temprana Dinámico 44
6.1. La Necesidad de un Sistema Proactivo: Indicador Líder vs. Indicador Rezagado 44
6.2. Diseño del Sistema de Alerta Dinámico . . . 45

6.2.1. Principio Operativo y Entradas del Sistema 45
6.2.2. Indicadores y Umbrales Adaptativos 45
6.3. Fiabilidad de los Indicadores 45
6.4. Simulación Retrospectiva: Dashboards y Métricas de Rendimiento 46
6.5. Protocolo Operativo Sugerido ante una Alerta Roja 46
6.6. Limitaciones y Consideraciones 46
6.7. Conclusión del Capítulo 52

7. Conclusiones **53**
7.1. Síntesis de Hallazgos Fundamentales 53
7.2. Contribución al Campo e Implicaciones 54
7.2.1. Contribución a la Física Aplicada: El Modelo como Laboratorio Teórico 54
7.2.2. Implicaciones para la Salud Pública: Hacia una Vigilancia Predictiva . . 54
7.3. Limitaciones y Agenda de Investigación Futura 54
7.4. Reflexiones Finales: El Poder de los Modelos Simples 55

Capítulo 1

Introducción a la Física de las Pandemias

1.1. La Pandemia como Objeto de Estudio de la Física

La pandemia de COVID-19 representa una de las disrupciones más significativas del siglo XXI. En México, su impacto se manifestó en más de siete millones de casos registrados y cientos de miles de muertes, trascendiendo la esfera de la salud pública para reconfigurar la totalidad del tejido social y económico. Ante un fenómeno de esta escala, el formalismo de la física —disciplina dedicada a la modelización de sistemas complejos y al estudio del comportamiento colectivo— no es solo relevante, sino fundamental. El objetivo central de este Proyecto Terminal es aplicar el paradigma de la física de sistemas dinámicos para extraer una comprensión cuantitativa de la dinámica pandémica en México.

Se postula que la propagación de un agente infeccioso es un **fenómeno emergente**, un concepto central en la física de la materia condensada. Propiedades macroscópicas y observables, como la curva epidémica, surgen de millones de interacciones humanas discretas y estocásticas a nivel local. Es imposible deducir la forma y escala de una ola pandémica estudiando a un solo individuo; esta solo existe como una propiedad del colectivo.

Un análisis riguroso de este sistema colectivo revela un conjunto de características que lo sitúan firmemente en el dominio de la física de sistemas complejos. La dinámica es intrínsecamente **no lineal**: la tasa de nuevas infecciones depende del producto entre la población infectada y la susceptible, estableciendo bucles de realimentación que pueden conducir a un crecimiento exponencial. Para analizar esta dinámica, es indispensable recurrir al concepto de **espacio de fases**, un espacio de estados definido por las variables macroscópicas del sistema (las fracciones de población Susceptible, Infectada y Recuperada). Cada epidemia traza una trayectoria única a través de este espacio, y el propósito fundamental de este trabajo es reconstruir y analizar dichas trayectorias. Además, el sistema es **adaptativo**: los individuos ajustan su comportamiento en respuesta a la percepción del riesgo, creando un bucle de realimentación secundario que altera los parámetros de transmisión y modifica la trayectoria de la epidemia.

1.2. El Modelo SIR como Aproximación de Campo Medio

Modelar explícitamente cada interacción en una población de millones de individuos resulta computacionalmente intratable. Ante este desafío, la física estadística ofrece un paradigma de simplificación de enorme poder: la **aproximación de campo medio** (mean-field theory). Originada en el estudio de transiciones de fase, esta aproximación reemplaza la compleja red de interacciones locales con un campo de influencia promedio y homogéneo que afecta a cada agente por igual.

El modelo **Susceptible-Infectado-Recuperado (SIR)** es la manifestación canónica de este enfoque en la epidemiología. Su postulado central, la **mezcla homogénea**, es análogo a asumir que un individuo está inmerso en un çampo de infección"promedio, cuya intensidad es proporcional a la densidad global de infectados.

La elección de este modelo no es una omisión de la complejidad, sino una estrategia científica deliberada. Se postula el modelo SIR como un **modelo nulo** o de orden cero, cuyo propósito es establecer una línea base para cuantificar qué fracción de la dinámica observada puede explicarse únicamente por los mecanismos fundamentales de transmisión y recuperación. Las desviaciones sistemáticas entre las predicciones de este modelo y los datos empíricos no constituyen un fracaso del análisis. Por el contrario, son precisamente esas discrepancias las que se convierten en la **señal experimental**, permitiéndonos medir cuantitativamente el impacto de la "física faltante": fenómenos de orden superior como la estructura de la red de contactos, la heterogeneidad espacial o el comportamiento adaptativo, cuya importancia solo puede ser evaluada en contraste con una línea base bien definida.

1.3. Hipótesis, Pregunta de Investigación y Objetivos

Este trabajo de investigación se articula en torno a la siguiente hipótesis central, una pregunta de investigación derivada y un conjunto de objetivos específicos diseñados para abordarla sistemáticamente.

Hipótesis Central

Se postula que la dinámica macroscópica de las cinco olas pandémicas de COVID-19 en México puede ser representada cuantitativamente como un conjunto de trayectorias en el espacio de fases de un sistema dinámico no lineal. La calibración rigurosa de un modelo SIR, entendido como una aproximación de campo medio de primer orden, permite cuantificar la evolución de los parámetros de control del sistema (como R_0) y revelar, a través de sus desviaciones sistemáticas con los datos empíricos, el impacto de fenómenos de orden superior no incluidos en el modelo canónico.

Pregunta de Investigación

¿En qué medida un modelo SIR canónico, calibrado con datos epidemiológicos y de seroprevalencia de México, puede reconstruir las trayectorias empíricas de las cinco olas pandémicas en el espacio de fases? ¿Qué revelan los valores cuantitativos de los parámetros del modelo (R_0, S_0/N) y sus fallos predictivos sobre la coevolución del virus y la respuesta del sistema socio-sanitario?

Objetivos Específicos

Para responder esta pregunta, se establecen los siguientes objetivos:

- **Reconstruir las trayectorias empíricas.** Propósito: Traducir los datos brutos de salud pública al lenguaje del espacio de fases de la física, corrigiendo sesgos observacionales fundamentales como el subregistro.
- **Cuantificar los parámetros de control del sistema.** Propósito: Asignar valores numéricos y distribuciones de incertidumbre a las variables clave del modelo (R_0, S_0/N) para cada ola, fundamentando el análisis en evidencia estadística robusta.
- **Validar cuantitativamente el modelo canónico SIR.** Propósito: Confrontar rigurosamente la teoría con la realidad, utilizando métricas de error para medir la bondad de ajuste y, de forma crucial, las desviaciones sistemáticas.
- **Interpretar la transición epidémica en el marco de la teoría de bifurcaciones.** Propósito: Conectar los resultados empíricos con la teoría fundamental de la estabilidad de sistemas dinámicos, formalizando el inicio de una ola como una bifurcación transcrítica.

1.4. Estructura del Proyecto Terminal

El presente documento se articula en la siguiente estructura para guiar al lector desde los fundamentos teóricos hasta la interpretación de los resultados:

Capítulo 2: Marco Teórico. Se expone el andamiaje teórico, derivando el modelo SIR como un sistema dinámico y analizando formalmente su espacio de fases, puntos fijos, estabilidad y la naturaleza de la transición epidémica como una bifurcación.

Capítulo 3: Datos y Metodología. Se describe en detalle el protocolo computacional y estadístico, desde la adquisición y el preprocesamiento de los datos epidemiológicos hasta la estimación de los parámetros del modelo y sus incertidumbres.

Capítulo 4: Resultados y Validación del Modelo. Se presentan los resultados cuantitativos del análisis, notablemente las estimaciones de R_0 para cada ola. Es aquí donde se confronta la simplicidad del modelo con la complejidad de los datos reales, analizando tanto las concordancias como las desviaciones.

Capítulo 5: Discusión e Interpretación Física. Se desarrolla una discusión profunda de los resultados, utilizando los fallos del modelo como una sonda teórica para interpretar la dinámica subyacente del sistema socio-sanitario real.

Capítulo 6: Aplicación: Simulación de un Sistema de Alerta Temprana. Se explora una aplicación directa del formalismo, simulando un sistema de alerta basado en la dinámica del sistema (sus "velocidadesz .ªceleraciones") en lugar de en indicadores de estado estáticos.

Capítulo 7: Conclusiones. Finalmente, se sintetizan los hallazgos fundamentales, se discuten sus implicaciones para la física y la salud pública, se reconocen sus limitaciones y se proponen líneas de investigación futura.

Capítulo 2

Marco Teórico – La Epidemiología como Sistema Dinámico

Este capítulo establece el fundamento teórico del Proyecto Terminal. Se deriva el modelo Susceptible-Infectado-Recuperado (SIR) como un sistema dinámico canónico a partir de primeros principios. El objetivo es construir el marco analítico —espacio de fases, constantes de movimiento, puntos de equilibrio, estabilidad lineal y bifurcaciones— que se utilizará para cuantificar la dinámica de la pandemia en México. Las derivaciones matemáticas aquí presentadas son la base para la validación y el análisis de los capítulos subsecuentes.

2.1. El Modelo SIR: Axiomas y Derivación Formal

El modelo de Kermack y McKendrick (1927) reduce la complejidad de las interacciones humanas a un sistema con pocos grados de libertad, regido por un conjunto mínimo de axiomas.

2.1.1. Axiomas del Sistema

Se particiona una población total N en tres compartimentos: Susceptibles (S), Infectados (I) y Recuperados (R). La evolución del sistema se rige por los siguientes postulados:

1. **Población Cerrada:** La población total N es una constante de movimiento. Los procesos demográficos se consideran irrelevantes en la escala temporal de una ola epidémica, imponiendo la restricción $\frac{d}{dt}(S + I + R) = 0$.

2. **Mezcla Homogénea (Aproximación de Campo Medio):** Cada individuo tiene la misma probabilidad de interactuar con cualquier otro. Esta es la aproximación de campo medio del sistema, que ignora la estructura topológica de las redes sociales. Las desviaciones de esta idealización, analizadas en el Capítulo 4, son una señal experimental de la ”física faltante”.

3. **Cinética de Transición:** El flujo entre compartimentos sigue una cinética de reacción:
    - **Infección (S → I):** Proceso de segundo orden ($S + I \rightarrow 2I$) que depende de la çolisión.[en]tre un susceptible y un infectado.
    - **Recuperación (I → R):** Proceso de primer orden ($I \rightarrow R$) con una tasa constante γ. La duración del periodo infeccioso sigue, por tanto, una distribución exponencial.
4. **Inmunidad Permanente:** El compartimento R es un estado absorbente. La falsación empírica de este axioma (Capítulo 3) es un hallazgo central de este Proyecto Terminal.

2.1.2. Ecuaciones de Movimiento

A partir de estos axiomas, se derivan las ecuaciones diferenciales del sistema.

- **Flujo de Infección (S→I):** El decremento en S es proporcional al número de susceptibles (S) y a la densidad de infectados (I/N). El factor de proporcionalidad, β, es la tasa de transmisión efectiva.
$$\frac{dS}{dt} = -\frac{\beta SI}{N} \tag{2.1}$$
- **Flujo de Recuperación (I→R):** El flujo hacia R es proporcional al número de infectados. La constante γ es la tasa de recuperación, y su inverso, $D = 1/\gamma$, es la duración media del periodo infeccioso.
$$\frac{dR}{dt} = \gamma I \tag{2.2}$$
- **Dinámica Neta de los Infectados:** La variación neta en I es la diferencia entre el flujo entrante y el saliente.
$$\frac{dI}{dt} = \frac{\beta SI}{N} - \gamma I \tag{2.3}$$

2.2. Estructura Geométrica de la Dinámica Epidémica

2.2.1. Invariante del Sistema y Reducción de Dimensionalidad

La suma de las ecuaciones (2.1)-(2.3) es cero, lo que confirma que $S(t) + I(t) + R(t) = N$ es una constante de movimiento. Esta ley de conservación confina la trayectoria del sistema a un plano de conservación bidimensional dentro del espacio de estados tridimensional. Esto justifica la reducción formal de la dimensionalidad del sistema.

Figura 2.1: Diagrama de Flujo del Modelo de Compartimentos SIR

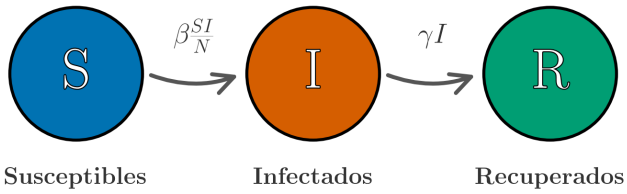

Figura 2.1: Diagrama de flujo del modelo compartimental SIR. Visualiza los compartimentos como estados y las flechas como los flujos de transición, regidos por las tasas de reacción $\beta SI/N$ y γI.

2.2.2. Espacio de Fases Normalizado

Para un análisis general, se normalizan las variables: $s = S/N$, $i = I/N$, $r = R/N$. El sistema adimensional es:

$$\frac{ds}{dt} = -\beta si \tag{2.4}$$

$$\frac{di}{dt} = i(\beta s - \gamma) \tag{2.5}$$

El análisis se realiza en el espacio de fases s-i, donde cada punto representa un estado macroscópico del sistema. La evolución temporal traza una trayectoria determinada por el campo vectorial $\vec{F}(s, i) = (-\beta si, i(\beta s - \gamma))$.

2.2.3. Nulclinas y Topología del Flujo

Las nulclinas—curvas donde una componente del campo vectorial se anula— determinan la estructura del flujo.

- **s-nulclina ($\dot{s} = 0$):** Las líneas $s = 0$ y $i = 0$.
- **i-nulclina ($\dot{i} = 0$):** La línea $i = 0$ y la línea vertical $s = \gamma/\beta$.

La i-nulclina no trivial, $s = 1/R_0$ (donde $R_0 \equiv \beta/\gamma$), representa el umbral de inmunidad de rebaño. A la derecha de esta línea ($s > 1/R_0$), $\dot{i} > 0$ y la epidemia crece. A su izquierda ($s < 1/R_0$), $\dot{i} < 0$ y la epidemia decae. El pico de la epidemia ocurre en el instante en que la trayectoria cruza esta nulclina.

2.3. Puntos de Equilibrio y Análisis de Estabilidad Lineal

Los puntos de equilibrio (s^*, i^*) del sistema son las soluciones de $\vec{F}(s, i) = (0, 0)$.

- **Equilibrio Libre de Enfermedad (DFE):** El estado $E_0 = (1, 0)$, una población enteramente susceptible.
- **Equilibrio Endémico (EE):** Un estado con $i^* > 0$, que existe solo si $R_0 > 1$.

2.3.1. Estabilidad del DFE y la Condición de Invasión Epidémica

La estabilidad del DFE determina si una epidemia puede iniciarse. Se analiza la evolución de una pequeña perturbación en la vecindad de E_0 mediante la matriz Jacobiana $J(s, i)$, la aproximación lineal del campo vectorial.

$$J(s, i) = \begin{pmatrix} -\beta i & -\beta s \\ \beta i & \beta s - \gamma \end{pmatrix}$$

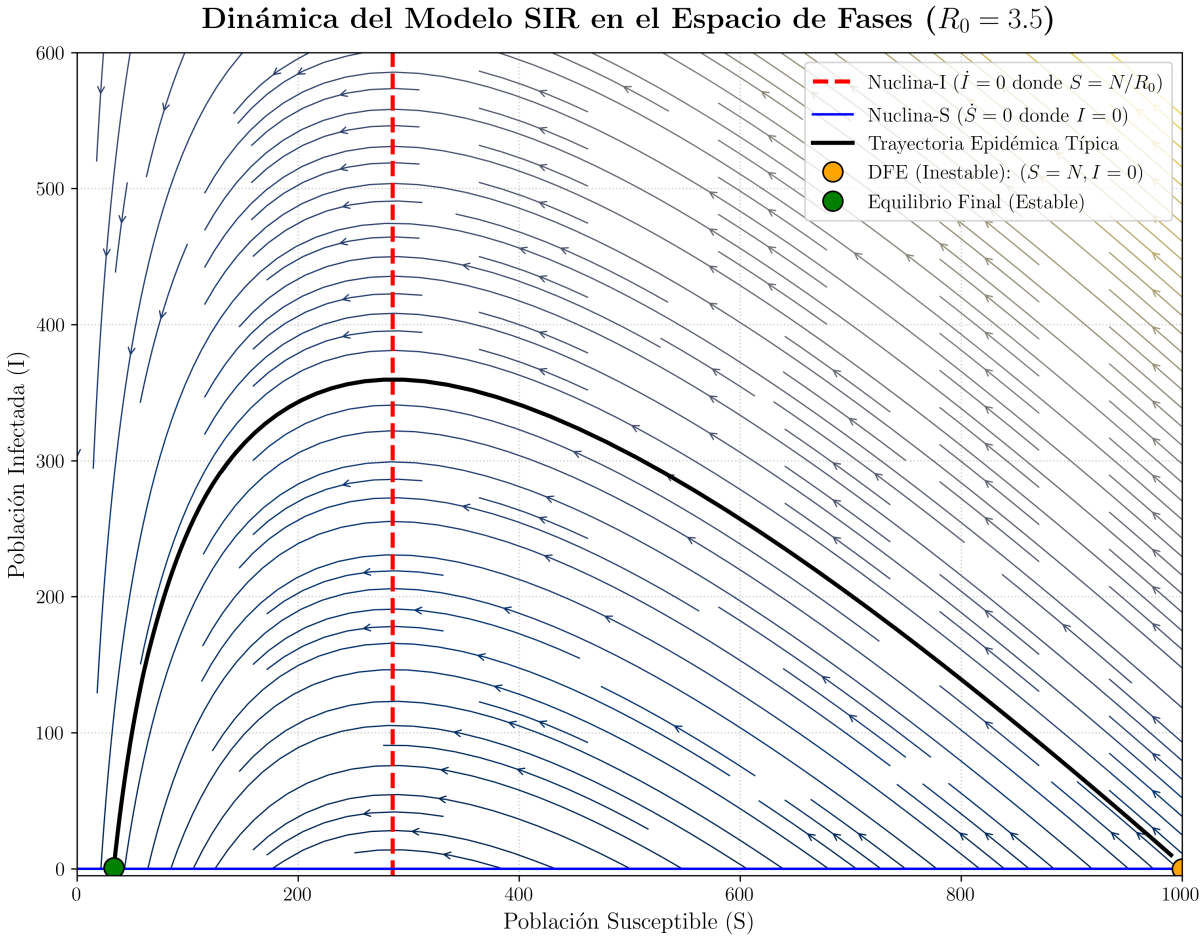

Figura 2.2: Campo vectorial del modelo SIR en el espacio de fases S-I. Las líneas de flujo indican la evolución del sistema. La trayectoria epidémica típica (línea gruesa) emerge de un estado inestable y evoluciona hacia un equilibrio final estable. Las nulclinas (líneas discontinuas) definen la frontera entre el crecimiento ($\dot{I} > 0$) y el decaimiento ($\dot{I} < 0$) de la epidemia.

Evaluando en el DFE, $E_0 = (1, 0)$:

$$J(1,0) = \begin{pmatrix} 0 & -\beta \\ 0 & \beta - \gamma \end{pmatrix} \tag{2.6}$$

Los autovalores son $\lambda_1 = 0$ y $\lambda_2 = \beta - \gamma$. El autovalor λ_2 gobierna la estabilidad en la dirección de la infección. La epidemia crece si una perturbación se amplifica, es decir, si $\lambda_2 > 0$. La condición de inestabilidad es:

$$\lambda_2 = \beta - \gamma > 0 \implies \frac{\beta}{\gamma} > 1$$

Esta desigualdad define formalmente el **Número Reproductivo Básico**, $R_0 \equiv \beta/\gamma$. R_0 es el factor de amplificación del sistema en el estado DFE. La condición para la invasión epidémica es $R_0 > 1$.

2.4. La Transición Epidémica como Bifurcación Transcrítica

El cambio cualitativo en la estabilidad del sistema que ocurre en $R_0 = 1$ es una **bifurcación transcrítica**. Este evento es análogo a una transición de fase de segundo orden en física.

- El **Parámetro de Control** es R_0.
- El **Parámetro de Orden** es la fracción de infectados en equilibrio, i^*.

Para $R_0 < 1$, el único equilibrio estable es el DFE ($i^* = 0$), una fase no epidémica. Para $R_0 > 1$, el DFE se desestabiliza y transfiere su estabilidad al EE, donde $i^* > 0$, una fase endémica. Este intercambio de estabilidad es la firma de la bifurcación.

2.5. Teorema del Tamaño Final de la Epidemia

Una predicción clave del modelo es el tamaño final de la epidemia, r_f, la fracción total de la población infectada al concluir la ola. Al dividir la ecuación (2.5) por la (2.4) para eliminar la dependencia del tiempo e integrar desde el inicio ($s_0 \approx 1, i_0 \approx 0$) hasta el final de la epidemia ($s_f, i_f = 0$), se obtiene:

$$r_f = 1 - e^{-R_0 r_f} \tag{2.7}$$

Esta ecuación trascendental vincula directamente el parámetro de la dinámica inicial (R_0) con el resultado macroscópico final (r_f).

2.6. Limitaciones del Modelo como Hoja de Ruta Analítica

Los axiomas del modelo definen sus fronteras de validez y, por tanto, una hoja de ruta para el análisis de datos. Las desviaciones entre el modelo y la realidad son señales que apuntan

Figura 2.2: Análisis de Estabilidad y Bifurcación del Modelo SIR

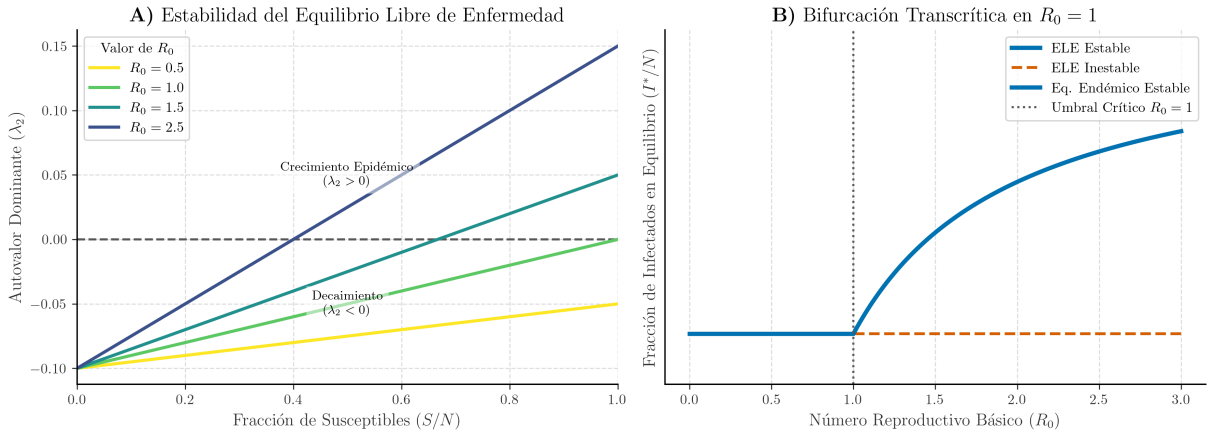

Figura 2.3: Análisis de estabilidad y bifurcación del modelo SIR. (A) El autovalor dominante (λ_2) se vuelve positivo cuando $S/N > 1/R_0$, permitiendo el crecimiento epidémico. (B) Diagrama de bifurcación que muestra la fracción de infectados en equilibrio (I^*/N) en función de R_0. Las líneas continuas representan equilibrios estables y las discontinuas, inestables. Se observa el intercambio de estabilidad en el punto crítico $R_0 = 1$.

a la ”física faltante”. Este estudio se centrará en cuantificar el impacto de la violación de dos postulados:

- **Inmunidad Permanente:** La evasión inmune viola el supuesto de que R es un estado absorbente. Esto requerirá cuantificar el flujo R→S (Capítulo 3).
- **Parámetros Constantes:** El modelo asume que β es constante. El comportamiento humano adaptativo puede modular β durante una misma ola. El análisis de las trayectorias en el Capítulo 4 buscará las firmas de esta dinámica coevolutiva.

Capítulo 3

Datos, Metodología y Calibración del Modelo

Este capítulo constituye el puente entre el formalismo teórico del Capítulo 2 y el análisis de resultados del Capítulo 4. Su objetivo es detallar el protocolo computacional y estadístico integral diseñado para calibrar el modelo SIR con los datos empíricos de la pandemia en México. Se presenta la transformación de la serie de tiempo cruda de la vigilancia epidemiológica —una señal inherentemente ruidosa y sesgada— en un conjunto de parámetros y condiciones iniciales robustos y físicamente significativos para el sistema dinámico. Cada paso del pipeline de análisis, desde la adquisición de los datos hasta la estimación final de los parámetros, se justifica explícitamente para garantizar la reproducibilidad y la validez científica del estudio.

3.1. Adquisición y Preprocesamiento de Datos: Aislamiento de la Señal Epidemiológica

El fundamento empírico de este estudio reside en la serie de tiempo de casos diarios confirmados a nivel nacional, obtenida de los datos abiertos de la Dirección General de Epidemiología (DGE). Desde una perspectiva de procesamiento de señales, esta serie de tiempo cruda, $I_{\text{crudo}}(t)$, puede modelarse como la superposición de la señal de baja frecuencia de interés, $I_{\text{tendencia}}(t)$, un artefacto estacional de alta frecuencia, $I_{\text{semanal}}(t)$, y un ruido estocástico, $n(t)$. El primer objetivo metodológico es aislar $I_{\text{tendencia}}(t)$.

El principal artefacto en los datos de vigilancia es una periodicidad de 7 días, producto de los ciclos de reporte del fin de semana. Para suprimir este ruido de alta frecuencia sin distorsionar la señal subyacente, se aplicó un filtro de media móvil centrada con una ventana de 7 días, definido por la ecuación de convolución:

$$I_{\text{suavizado}}(t) = \frac{1}{7} \sum_{j=-3}^{3} I_{\text{crudo}}(t+j) \tag{3.1}$$

Se eligió este filtro sobre alternativas más complejas (ej. Savitzky-Golay) por tres razones funda-

mentales: 1) **Interpretabilidad Directa:** La ventana de 7 días ataca específicamente la frecuencia del ruido conocido. 2) **Cero Desplazamiento de Fase:** Al ser un filtro centrado, no introduce retrasos artificiales en la señal, preservando la correcta temporización de los picos epidémicos. 3) **Preservación de la Magnitud:** La media móvil preserva el área bajo la curva (el número total de casos), una característica esencial para la calibración posterior del modelo.

3.2. Definición Operacional de Olas: Un Criterio Topológico Objetivo

Para segmentar la serie temporal continua en las .olas"que constituyen las unidades de análisis de este Proyecto Terminal, se empleó un criterio algorítmico y reproducible. Se identificaron los valles de mínima transmisión aplicando la función `find_peaks` de la librería SciPy a la serie de tiempo invertida, $-I_{\text{suavizado}}(t)$.

La robustez de este método depende del hiperparámetro *prominence*, que mide la significancia topológica de un pico (en este caso, un valle). Define la altura vertical mínima que un pico debe tener con respecto al terreno circundante para ser considerado como tal. Tras un análisis de sensibilidad (Figura 3.1), se seleccionó un valor de *prominence*=2500. Este umbral fue elegido porque segmenta la pandemia en las cinco grandes fases macroscópicas que se correlacionan con la dominancia de distintos linajes virales (ancestral, Alpha/Gamma, Delta, Ómicron BA.1 y sublinajes de Ómicron), alineando así la segmentación puramente topológica con la realidad biológica subyacente.

3.3. Parametrización del Modelo

3.3.1. Ajuste por Subregistro: Anclaje con Datos de Seroprevalencia (ENSANUT)

Un análisis basado únicamente en los casos confirmados carecería de validez física, ya que el modelo SIR opera sobre el número total de infectados, no solo los detectados. Para corregir este sesgo observacional, se ancló el análisis a los datos de seroprevalencia de las Encuestas Nacionales de Salud y Nutrición (ENSANUT) de 2020, 2021 y 2022, que funcionan como nuestro "ground truth". Se definió una **Fracción de Detección (FD)** para cada periodo:

$$\text{FD} = \frac{\text{Casos Acumulados Reportados}}{\text{Población Total} \times \text{Seroprevalencia}} \tag{3.2}$$

Dada la disponibilidad de tres encuestas para cinco olas, se adoptó una aproximación de FD constante por tramos, el enfoque más robusto que evita introducir suposiciones ad hoc (como interpolaciones) sin soporte empírico. El resultado de esta corrección, que revela la magnitud de la "pandemia invisible", se muestra en la Figura 3.3.

Figura 3.1: Análisis de Sensibilidad para la Definición de Olas

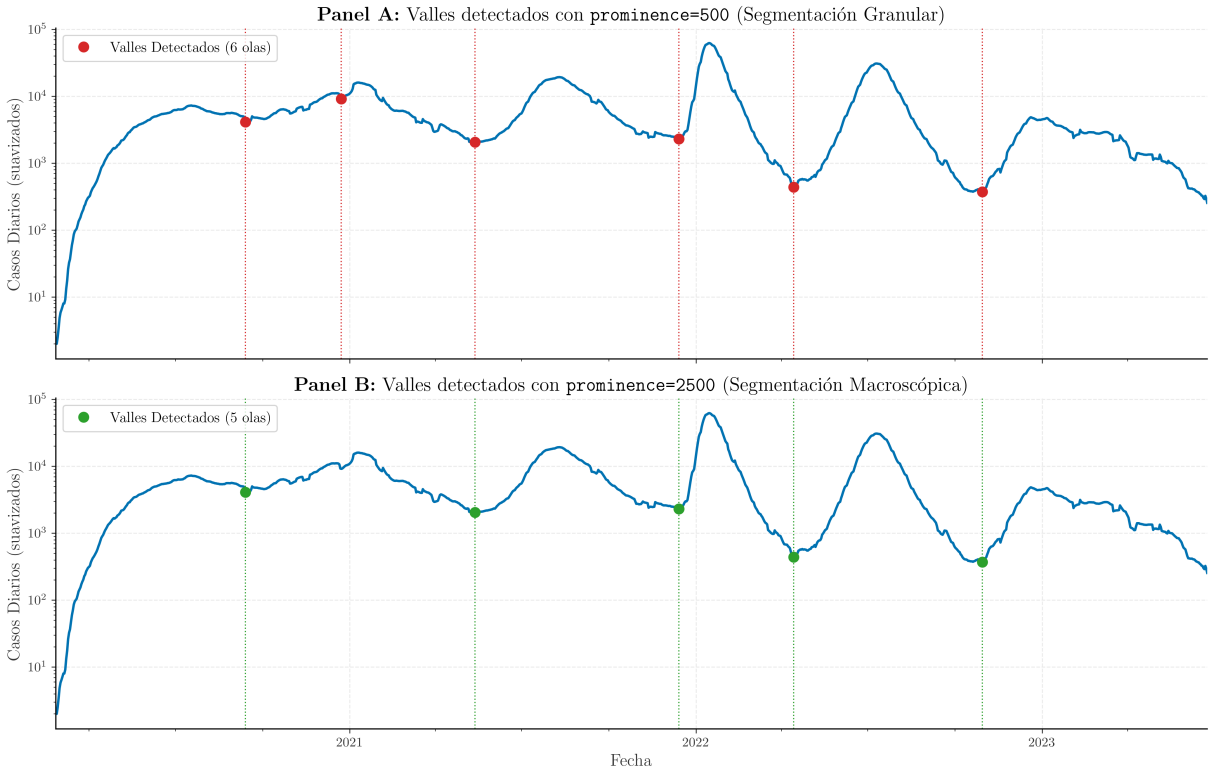

Figura 3.1: Análisis de sensibilidad para la definición de olas. (A) Un valor bajo de *prominence* resulta en una segmentación granular. (B) El valor seleccionado de *prominence*=2500 identifica las 5 olas macroscópicas utilizadas en este estudio.

Figura 3.1: Dinámica y Hitos de la Pandemia de COVID-19 en México (5 Olas)

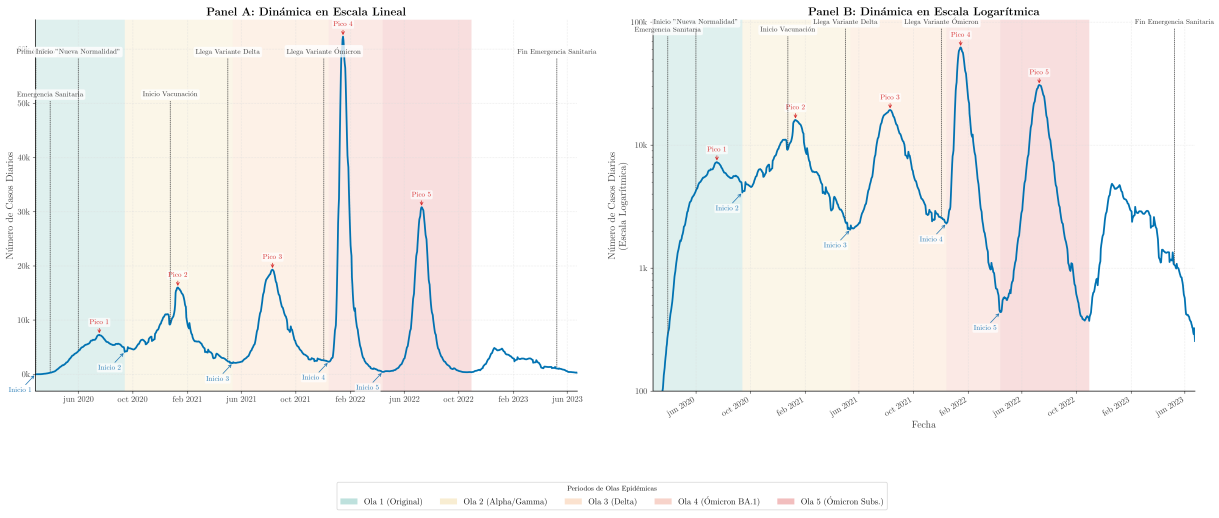

Figura 3.2: Dinámica de la pandemia de COVID-19 en México y segmentación en cinco olas. Las áreas sombreadas delimitan las unidades de análisis fundamentales para este Proyecto Terminal.

Figura 3.2: Comparativa de Casos Reportados vs. Infecciones Estimadas por Subregistro

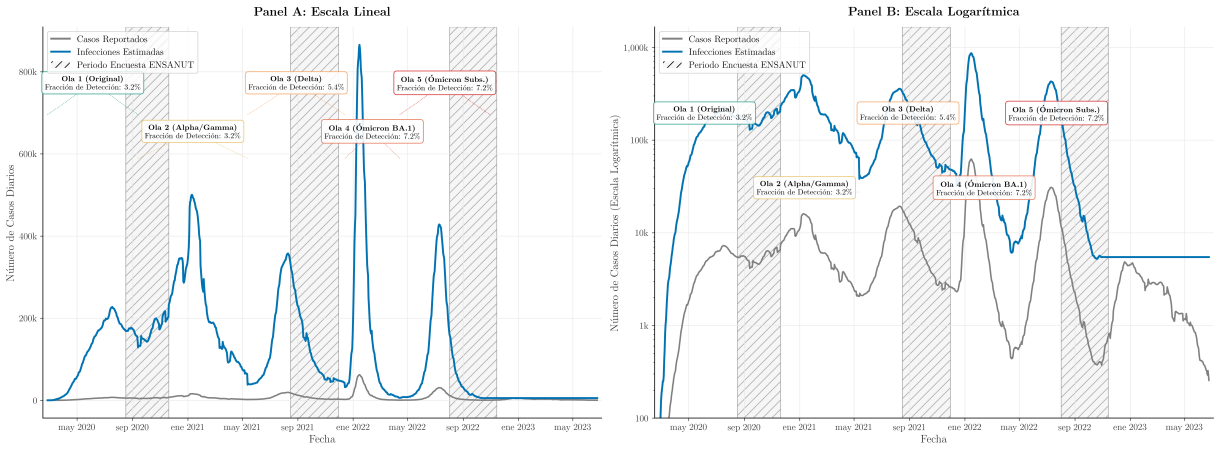

Figura 3.3: Comparativa de casos reportados (gris) vs. infecciones reales estimadas (azul) tras aplicar la Fracción de Detección.

3.3.2. Inferencia de S_0/N y la Falsación del Modelo de Inmunidad Permanente

La fracción inicial de susceptibles, S_0/N, es una condición inicial crucial para cada ola. Un modelo simple de agotamiento, donde $S_{0,i+1}/N = S_{0,i}/N - I_{\text{reales},i}/N$, se aplicó inicialmente. Este modelo, que asume inmunidad permanente, produjo un resultado físicamente imposible ($S/N < 0$) al proyectar el inicio de la Ola 5.

Este resultado no fue un error, sino una falsación empírica del modelo simple. Los datos demostraron que el supuesto de inmunidad permanente del SIR canónico había sido violado por la biología de la variante Ómicron. Para capturar este fenómeno de evasión inmune, se introdujo el parámetro $\epsilon \in [0, 1]$, definido como la fracción de la población recuperada (R) que vuelve al compartimento susceptible (S) ante la llegada de una nueva variante. La condición inicial se modifica a:

$$S_{0,\text{nueva}} = S_{\text{restante}} + \epsilon \cdot R_{\text{vieja}}$$

El valor de ϵ no fue un ajuste arbitrario, sino que fue inferido de los datos mediante un algoritmo de optimización. Se buscó el valor que minimizaba el Error Cuadrático Medio (RMSE) entre la trayectoria del modelo y los datos de la ola de Ómicron. La existencia de un mínimo bien definido en la función de costo (Figura 3.4) justifica la selección del valor óptimo, transformando este paso metodológico en una medición indirecta del impacto de la evolución viral.

3.4. Estimación de R_0: Cuantificación de la Incertidumbre con Monte Carlo

Para obtener una estimación rigurosa de R_0, el parámetro de control del sistema, se empleó una Simulación de Monte Carlo (MCS) con 100,000 iteraciones por ola.

Figura 3.4: Inferencia del Parámetro de Evasión Inmune (ϵ) para la Ola 4

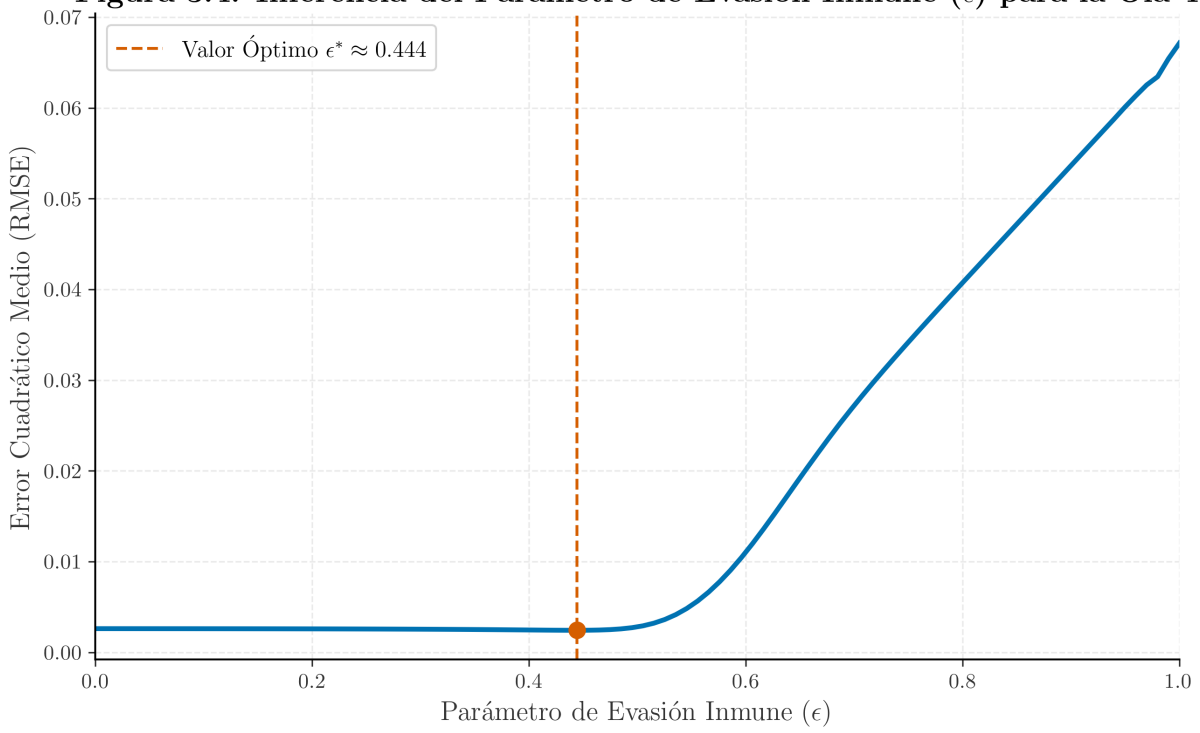

Figura 3.4: Inferencia del parámetro de evasión inmune (ϵ) para la Ola 4. El mínimo bien definido de la curva RMSE justifica la selección del valor óptimo.

3.4.1. Principio del Método: Crecimiento Exponencial

En la fase inicial de una epidemia, con $s \approx S_0/N$, la ecuación (2.5) puede aproximarse como:

$$\frac{di}{dt} = i\left(\beta\frac{S_0}{N} - \gamma\right) = r \cdot i$$

donde r es la tasa de crecimiento exponencial. La solución es $i(t) \propto e^{rt}$. La tasa r puede medirse ajustando una regresión log-lineal a los datos iniciales de la ola. Una vez obtenido r, se puede despejar R_0:

$$r = \gamma\left(R_0\frac{S_0}{N} - 1\right) \implies R_0 = \left(\frac{r}{\gamma} + 1\right) / \left(\frac{S_0}{N}\right) \tag{3.3}$$

3.4.2. Identificación de la Fase Exponencial

Para asegurar que r se mide objetivamente en el periodo donde la aproximación exponencial es más válida, se implementó un algoritmo que desliza una ventana de 21 días al inicio de la ola y selecciona la posición que maximiza el coeficiente de determinación (R^2) de la regresión log-lineal. Esto garantiza que el cálculo se basa en la fase de crecimiento más pura. La Figura 3.5 muestra un ejemplo de este ajuste, con un $R^2 > 0{,}99$, validando la suposición de crecimiento exponencial en esa ventana.

Figura 3.5: Estimación de la Tasa de Crecimiento (r) para la Ola 3 (Delta)

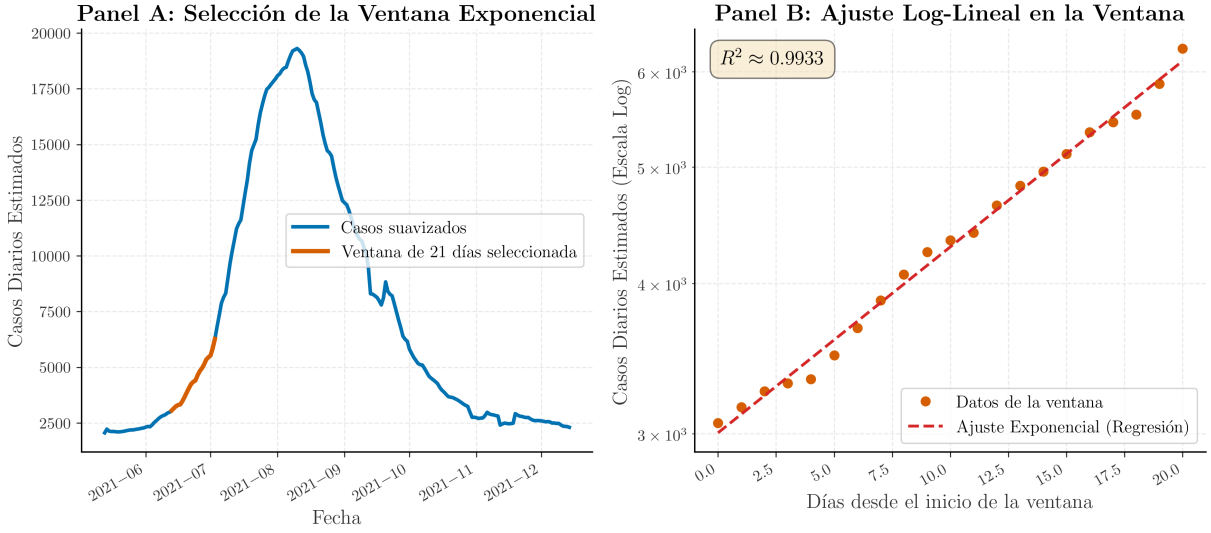

Figura 3.5: Ejemplo de la estimación de la tasa de crecimiento (r) para la Ola 3. (A) Ventana de 21 días seleccionada. (B) Ajuste log-lineal en dicha ventana, mostrando una correlación casi perfecta.

3.4.3. Propagación de Incertidumbre con Monte Carlo

Una estimación puntual de R_0 es engañosa, ya que sus componentes ($D = 1/\gamma$, FD, S_0/N) son inciertos. MCS es el método estándar para propagar estas incertidumbres. En cada una de las 100,000 iteraciones, se muestreó un valor para cada parámetro de entrada a partir de una distribución de probabilidad. Se eligió una distribución triangular con un rango de $\pm 20\,\%$ en torno al valor medio. Esta elección es más robusta y conservadora que asumir una distribución Normal cuando solo se conocen el modo y los límites plausibles del parámetro. La repetición de este proceso genera una distribución de probabilidad completa para R_0, permitiendo el cálculo de su media y sus intervalos de confianza.

El pipeline metodológico completo, desde los datos crudos hasta los productos finales, se resume en la Figura 3.6.

Figura 3.6: Diagrama de Flujo del Pipeline Metodológico Completo

Figura 3.6: Diagrama de flujo del pipeline metodológico. Resume el proceso secuencial desde la entrada de datos, a través de los módulos de preprocesamiento, calibración y simulación, hasta la obtención de los resultados cuantitativos y su posterior interpretación.

Capítulo 4

Resultados y Validación Crítica del Modelo

Este capítulo constituye el núcleo empírico del Proyecto Terminal. Aquí, el formalismo teórico del modelo SIR, establecido como nuestro modelo nulo, se confronta sistemáticamente con las trayectorias empíricas de la pandemia en México. La estructura de este capítulo es dual: primero, se presentan los resultados cuantitativos de los parámetros de control del sistema, notablemente el número reproductivo básico (R_0), derivados de la metodología del Capítulo 3. Segundo, y de manera crucial, se realiza una validación crítica donde las desviaciones sistemáticas entre el modelo y los datos se analizan no como fallos, sino como la principal fuente de conocimiento físico, revelando y cuantificando la dinámica compleja subyacente que el modelo simple no captura.

4.1. Estimación de la Transmisibilidad Intrínseca (R_0)

El parámetro R_0 es el principal parámetro de control del sistema dinámico en su fase inicial. Su evolución a lo largo de las cinco olas no es meramente un registro de la infectividad viral, sino un indicador cuantitativo de la compleja carrera coevolutiva entre el patógeno y la inmunidad poblacional.

4.1.1. Valores Medios: La Narrativa de la Co-evolución Viral

La aplicación del pipeline metodológico de Monte Carlo arrojó las estimaciones para el valor medio de R_0 presentadas en la Figura 4.1.

La secuencia de valores — $2{,}12 \rightarrow 1{,}50 \rightarrow 3{,}37 \rightarrow 4{,}28 \rightarrow 3{,}37$ — cuenta una historia:

- **Ola 1 (Original, $R_0 \approx 2{,}12$):** Establece la transmisibilidad base del linaje ancestral en el contexto mexicano.
- **Ola 2 (Alpha/Gamma, $R_0 \approx 1{,}50$):** El descenso en el R_0 efectivo inicial es un hallazgo sutil pero importante. Refleja que, aunque las variantes eran biológicamente más transmi-

Figura 4.1: Estimación de R_0 con Intervalos de Confianza del 95%

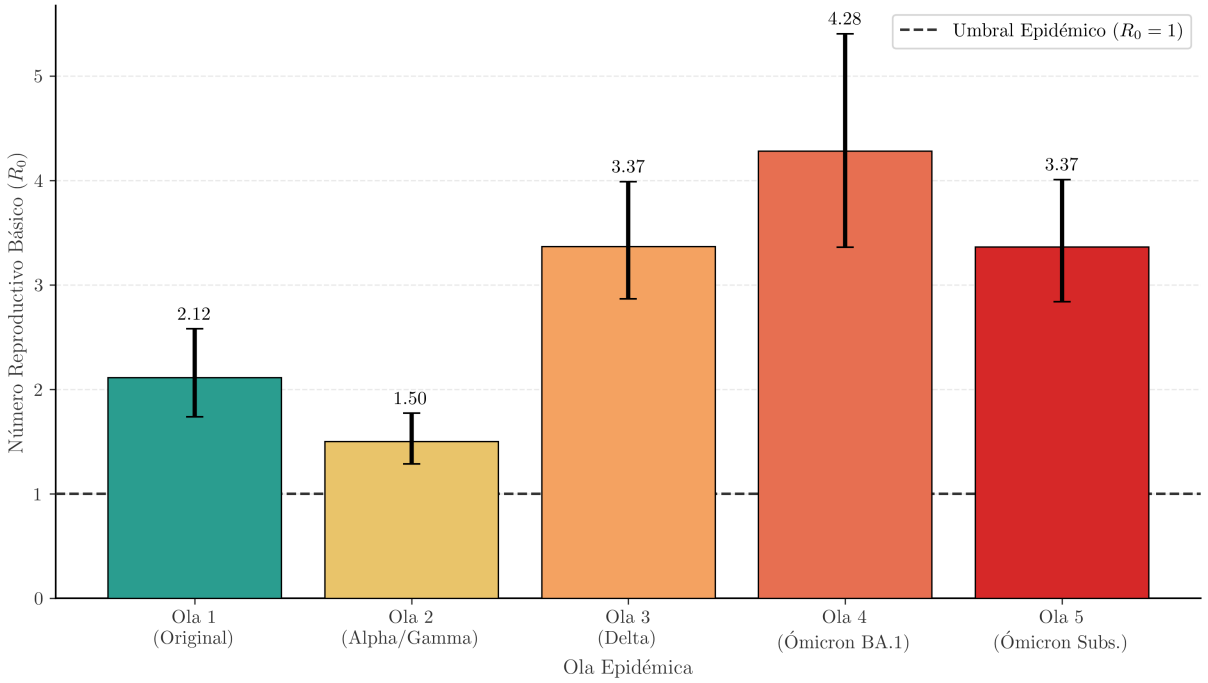

Figura 4.1: Estimación del Número Reproductivo Básico (R_0) medio para cada ola pandémica. Las barras de error representan el intervalo de confianza del 95 %. La línea punteada marca el umbral epidémico ($R_0 = 1$).

sibles, la epidemia comenzó en una población con inmunidad parcial, lo que redujo la tasa de crecimiento exponencial inicial a partir de la cual se infiere R_0.

- **Ola 3 (Delta, $R_0 \approx 3{,}37$):** Este drástico aumento cuantifica la ventaja biológica de la variante Delta, cuya mayor infectividad fue suficiente para superar la inmunidad existente y redefinir la escala de la transmisión.
- **Ola 4 (Ómicron BA.1, $R_0 \approx 4{,}28$):** El valor máximo representa el cénit de la transmisibilidad, magnificado por la evasión inmune. Este R_0 se logró en una población con altos niveles de inmunidad híbrida, lo que subraya la inmensa ventaja evolutiva de la variante y justifica la necesidad de haber introducido el parámetro ϵ en nuestra metodología.

4.1.2. Cuantificación y Significado de la Incertidumbre

Una estimación puntual de R_0 es insuficiente. La simulación de Monte Carlo nos proporciona una distribución de probabilidad completa para el parámetro (Figura 4.2), donde la anchura de la distribución es una medida directa de la incertidumbre.

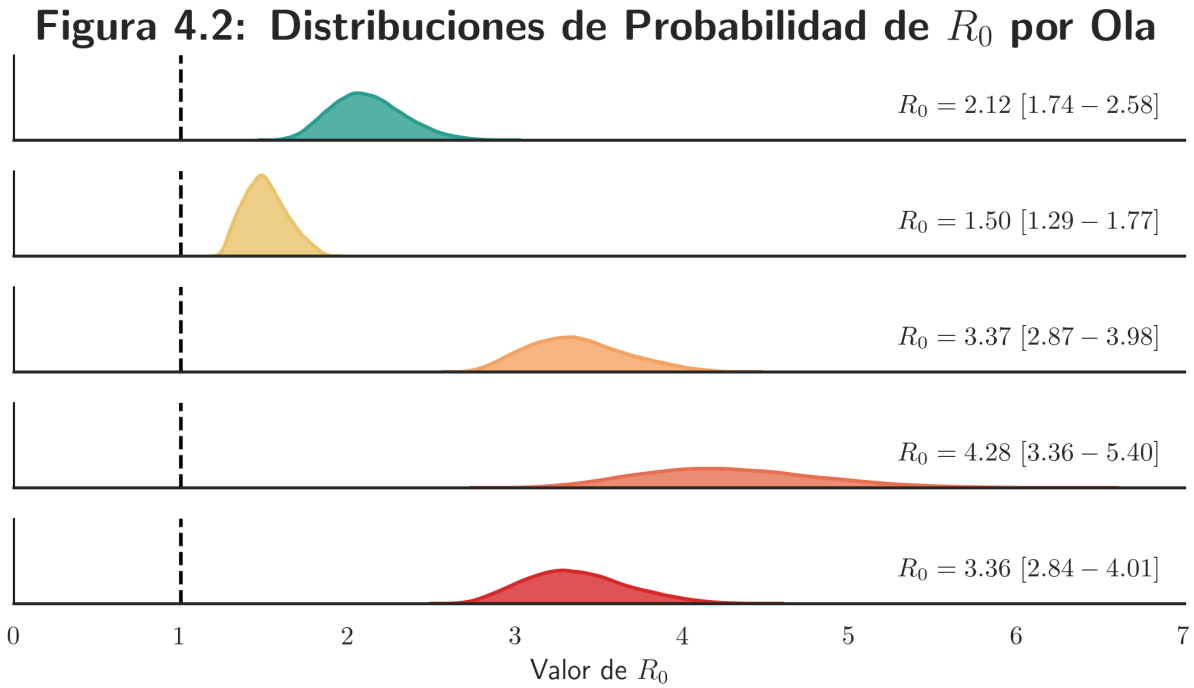

Figura 4.2: Distribuciones de densidad de probabilidad para el R_0 de cada ola.

El análisis de estas distribuciones revela un hallazgo crucial: la distribución para la Ola 4 (Ómicron) es significativamente más ancha que las demás. Esto no es un artefacto, sino el resultado de la propagación de errores. La incertidumbre en la estimación de R_0 para Ómicron es la convolución de las incertidumbres en D, FD, S_0/N y, fundamentalmente, en el parámetro ϵ inferido numéricamente. Como bien reflexionas, una variante tan contagiosa dificulta el rastreo y la cuantificación precisa de los contagios, lo que aumenta la incertidumbre de los datos base.

La implicación para la salud pública es profunda: la predictibilidad de una epidemia y la certeza en sus parámetros de control disminuyen a medida que aumenta la evasión inmune y la transmisibilidad del patógeno.

4.2. Validación Cuantitativa: Métricas de Desempeño del Modelo

Para cuantificar formalmente la bondad de ajuste, se calcularon tres métricas de error clave, presentadas en la Tabla 4.1.

- **RMSE (%):** El Error Cuadrático Medio mide la desviación promedio general entre la trayectoria predicha y la observada.
- **Error Pico Relativo (%):** Mide la capacidad del modelo para capturar la magnitud máxima de la ola. Un valor positivo indica una sobreestimación por parte del modelo.
- **Error Tamaño Abs. (% pob.):** Mide la diferencia en el tamaño final total de la epidemia (la integral de la curva de nuevos infectados).

Cuadro 4.1: Métricas Cuantitativas de Ajuste del Modelo SIR.

Ola	RMSE (%)	Error Pico Rel. (%)	Error Tamaño Abs. (% pob.)
Ola 1 (Original)	4.54	+1832.83	+61.40
Ola 2 (Alpha/Gamma)	0.29	-15.11	-9.50
Ola 3 (Delta)	0.30	+29.31	-0.14
Ola 4 (Omicron BA.1)	3.39	+594.10	+32.46
Ola 5 (Omicron Subs.)	0.47	+36.42	-0.96

La tabla muestra un desempeño heterogéneo. El modelo es extraordinariamente preciso para las Olas 2 y 3 (RMSE $< 0.5\,\%$), pero falla de manera espectacular en las Olas 1 y 4. Esta heterogeneidad es la clave del análisis: las fallas no son aleatorias, sino sistemáticas, y cada una tiene una causa física interpretable.

4.3. Análisis Crítico de las Trayectorias en el Espacio de Fases

4.3.1. Ola 1: La Firma Inequívoca de la Mitigación Externa

La Figura 4.3 visualiza el fallo más informativo del Proyecto Terminal. El modelo SIR, con un R_0 constante, predice la trayectoria natural y sin restricciones del virus: una curva que consumiría a más del $80\,\%$ de la población susceptible. La trayectoria empírica es una pequeña incursión en el espacio de fases que se extingue prematuramente. La brecha (error de pico de

+1832.83 %) es la medida cuantitativa del efecto de las intervenciones no farmacológicas. En el lenguaje de los sistemas dinámicos, estas intervenciones actuaron como una fuerza externa que alteró el campo vectorial del sistema, introduciendo un término de ”fricción”dependiente del tiempo ($\beta \to \beta(t)$) que el modelo canónico no posee. La trayectoria empírica se apaga con una fracción masiva de susceptibles restantes ($s_f \gg 0$), la prueba irrefutable de que la ola no terminó por agotamiento de combustible, sino por supresión externa.

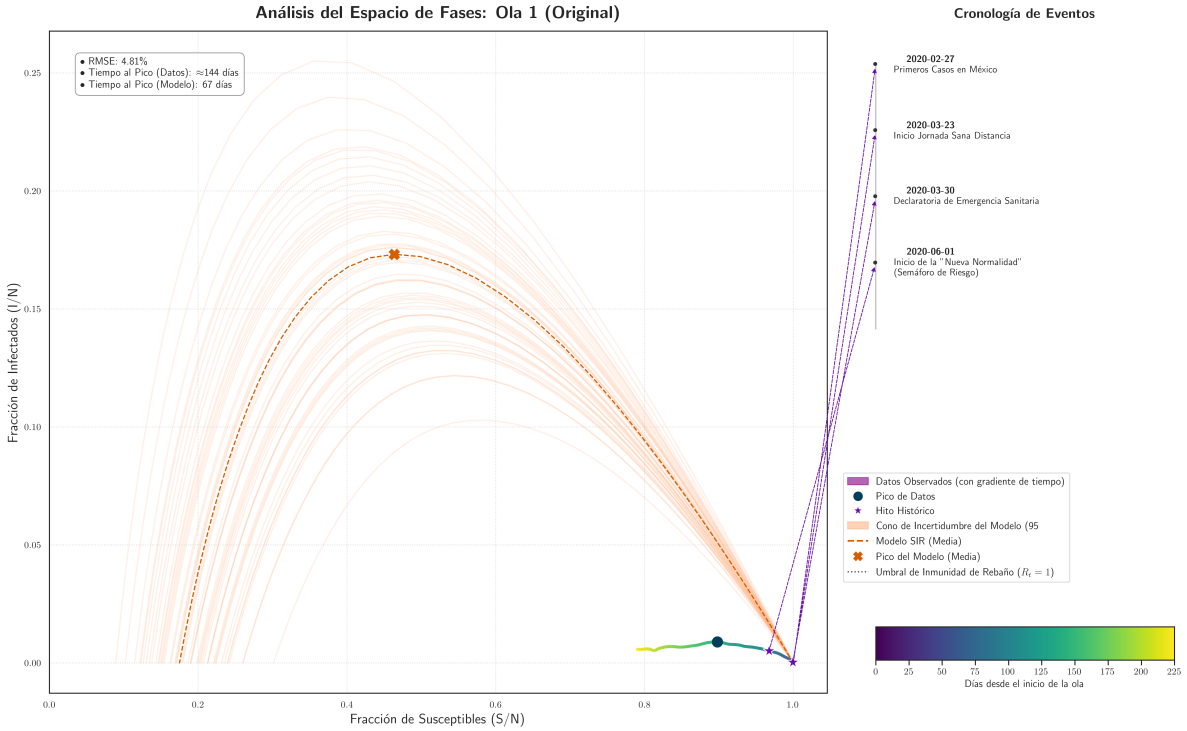

Figura 4.3: Validación del Modelo para la Ola 1.

4.3.2. Ola 2: El Régimen de Máxima Concordancia Clásica

La Ola 2 (Figura 4.4) es la que mejor se adhiere a la dinámica del modelo nulo. La trayectoria empírica sigue de cerca el flujo predicho, contenida dentro del cono de incertidumbre. Esto sugiere que su evolución fue dominada principalmente por el mecanismo de retroalimentación negativa endógeno del propio modelo: el agotamiento de susceptibles. El ligero error de pico negativo (-15.11 %) puede interpretarse como una firma de heterogeneidades (superpropagación) que la aproximación de campo medio promedia, pero en general, esta ola representa el comportamiento çlásico”de un sistema SIR.

4.3.3. Ola 3 (Delta): La Firma del Comportamiento Adaptativo

En la Ola 3 (Figura 4.5), la trayectoria empírica sigue inicialmente al modelo, pero se desvía hacia abajo antes de alcanzar el pico teórico (error de +29.31 %). Esta es la firma del com-

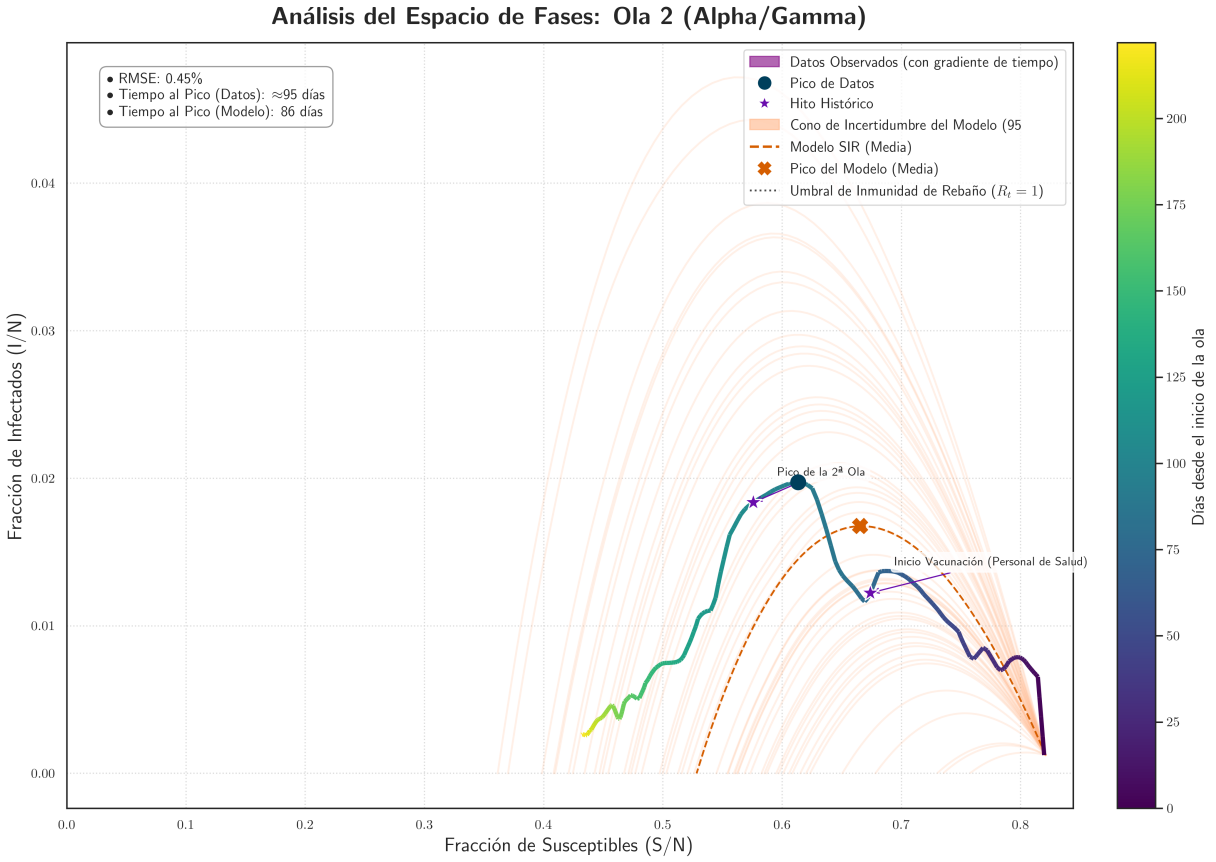

Figura 4.4: Validación del Modelo para la Ola 2.

portamiento social adaptativo. A diferencia de la Ola 1, donde la mitigación fue una política ”top-down”, aquí vemos un bucle de retroalimentación endógeno no modelado: a medida que la prevalencia (I) aumentaba, la percepción de riesgo en la población (alimentada por la difusión mediática sobre Delta y el avance de la vacunación) provocaba una reducción en los contactos efectivos, disminuyendo así el parámetro β. El sistema real, por tanto, se auto-reguló de una forma que el modelo con β constante no puede capturar.

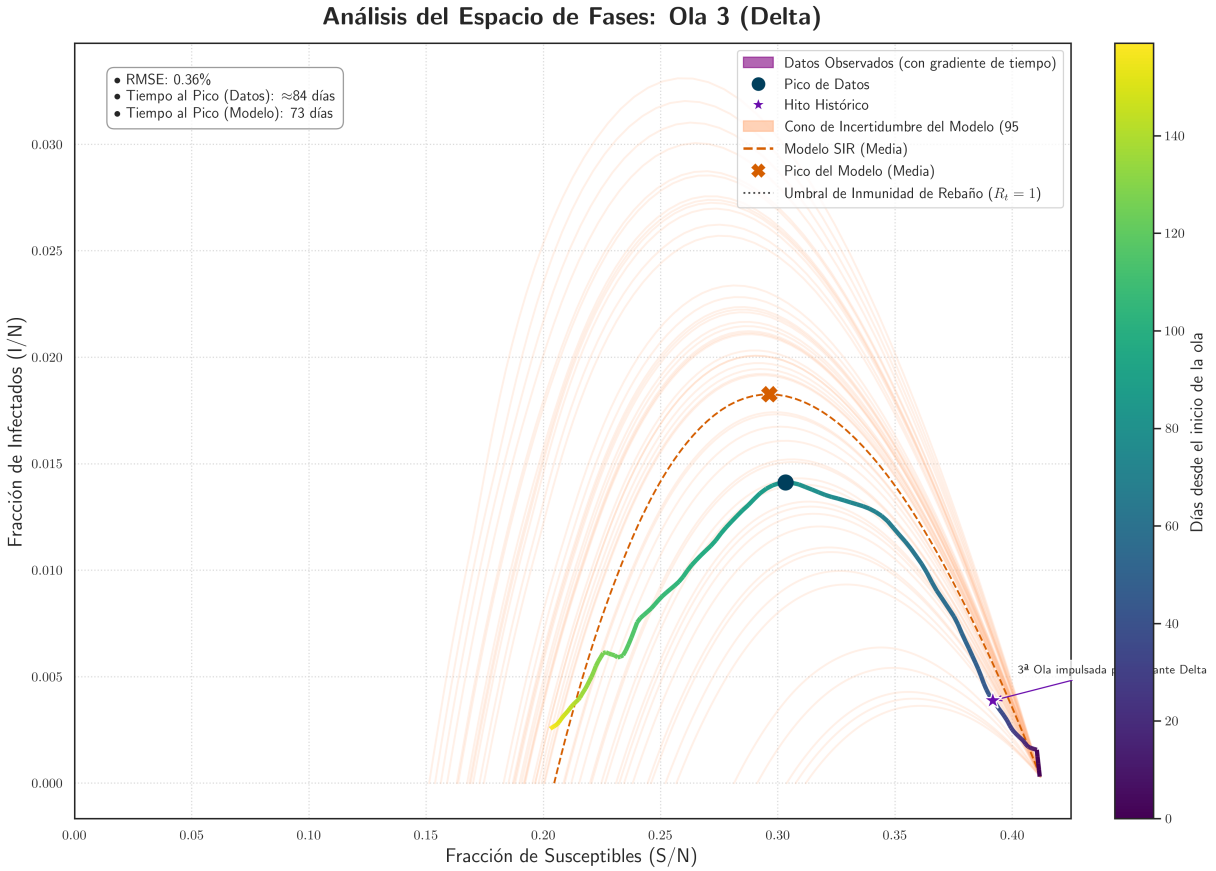

Figura 4.5: Validación del Modelo para la Ola 3.

4.3.4. Ómicron y los Límites Estructurales del Modelo

La Ola 4 (Figura 4.6) representa un fallo espectacular (error de pico de +594.10 %). La discrepancia es de una naturaleza más fundamental que las anteriores. Aquí, el modelo falla en dos niveles:

- **Fallo de Condición Inicial (Estático):** El supuesto de inmunidad permanente es violado, lo que requirió la introducción de ϵ para corregir S_0/N.
- **Fallo de la Ecuación de Movimiento (Dinámico):** Incluso con el S_0/N correcto, la forma de la trayectoria es errónea. La biología de Ómicron (periodo infeccioso D más corto)

produce una cinética mucho más rápida. El modelo SIR, con su estructura matemática y un solo parámetro γ, no tiene la flexibilidad para reproducir esta trayectoria aguda y veloz.

El mejor ajuste para la Ola 5 (Figura 4.7) se debe a que, para entonces, ya habíamos recalibrado los parámetros del modelo (notablemente D) para reflejar la ”nueva física”de Ómicron. Esto demuestra que el formalismo SIR puede seguir siendo útil, pero solo después de que sus parámetros son ajustados para concordar con la biología cambiante del virus.

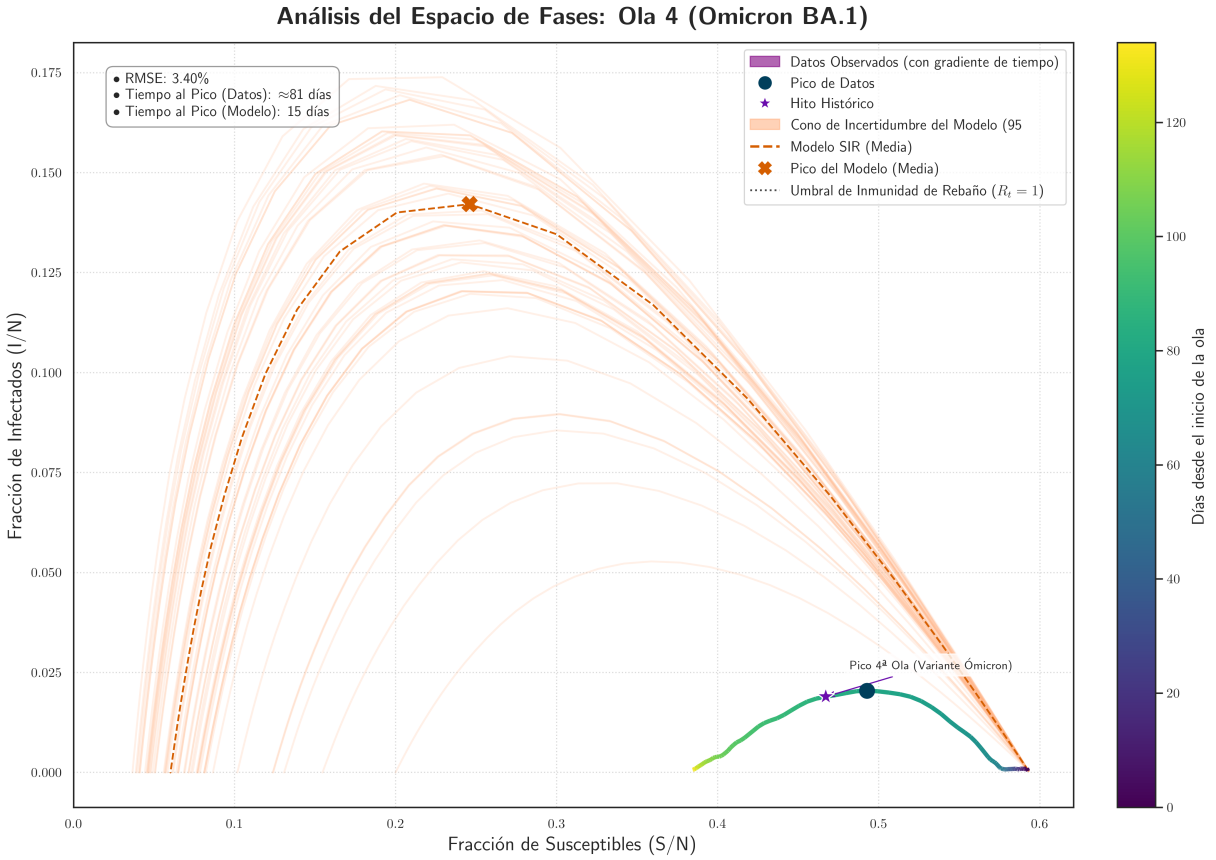

Figura 4.6: Validación del Modelo para la Ola 4 (Ómicron BA.1).

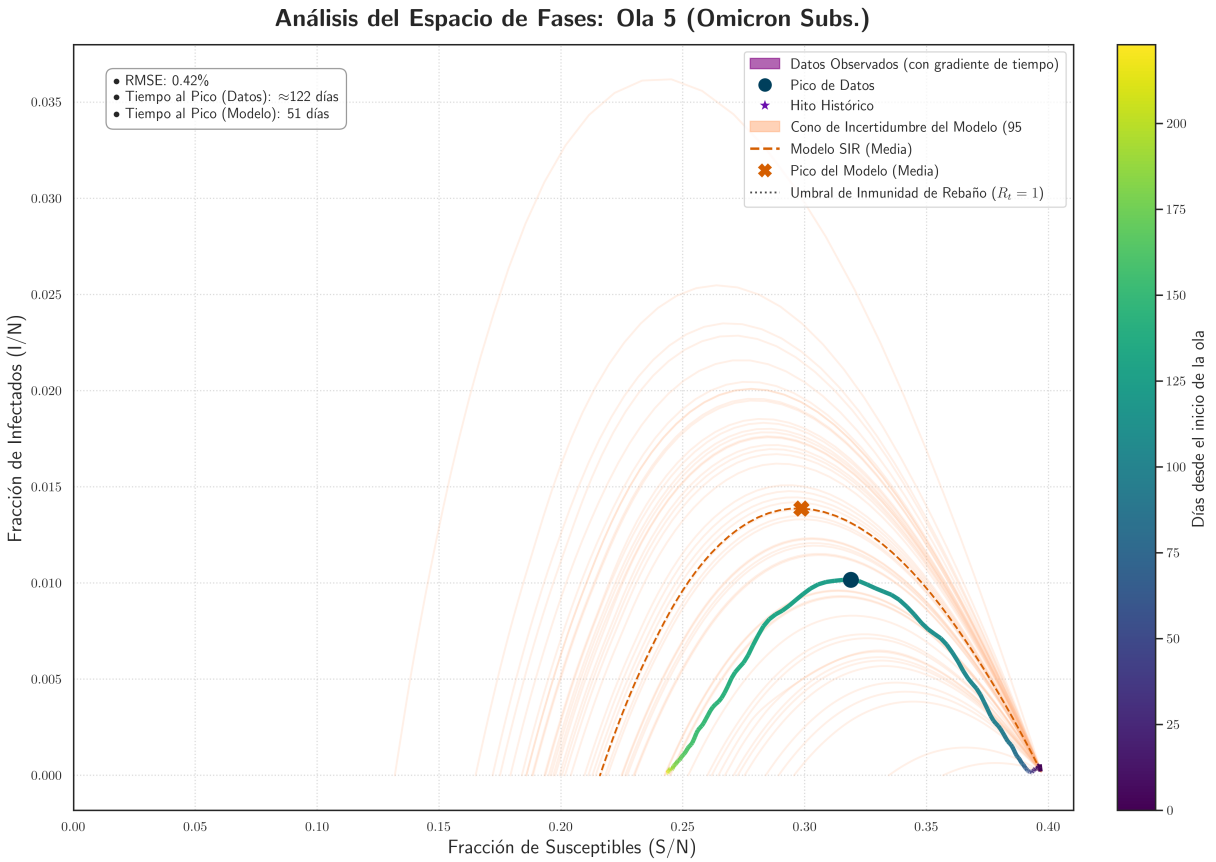

Figura 4.7: Validación del Modelo para la Ola 5 (Ómicron Subs.).

Capítulo 5

Discusión Física y Análisis Dinámico de la Pandemia

Resumen del Capítulo

En este capítulo se realiza la síntesis interpretativa del Proyecto Terminal, integrando el marco teórico (Cap. 2), la calibración de parámetros (Cap. 3) y los resultados cuantitativos (Cap. 4) para construir una narrativa física coherente sobre la dinámica pandémica en México. Se utiliza el modelo SIR como un modelo nulo —un sistema dinámico no lineal de baja dimensión que captura la esencia de la transmisión bajo mezcla homogénea—. Sus fallos predictivos no se tratan como errores, sino como el principal instrumento de descubrimiento: cada desviación sistemática entre el modelo y los datos se interpreta como una señal cuantificable de procesos reales no modelados. Este capítulo provee: (i) un análisis detallado ola por ola; (ii) una interpretación en el espacio de fases y teoría de bifurcaciones; y (iii) implicaciones operativas para la vigilancia y la salud pública.

5.1. Síntesis y Justificación de Hallazgos Físicos

La utilidad del modelo SIR como sonda teórica se resume en la Tabla 5.1, que vincula las discrepancias empíricas del Capítulo 4 con su interpretación física.

Justificación Detallada de los Hallazgos

El hallazgo de **Mitigación por Intervención Externa** para la Ola 1 se fundamenta en la evidencia cuantitativa de la Tabla 4.1, que reporta un .ᴱʳror Tamaño Abs. (% pob.)"de +61.40 %. Esto significa que la simulación del modelo predijo que el 61.4 % de la población adicional se infectaría en comparación con lo que realmente ocurrió. La simulación (Figura 5.2) predice una fracción de susceptibles restantes $s_f \approx 0{,}18$, mientras que el dato empírico corresponde a un s_f cercano a 0.80. Físicamente, esta discrepancia masiva implica que la trayectoria real fue

Cuadro 5.1: Conexión entre los Hallazgos Empíricos y las Simulaciones del Modelo

Ola	**Principal Hallazgo Físico (Cap. 4)**	**Evidencia en la Simulación (Cap. 5) como Contrafactual**
1	Mitigación por Intervención Externa	La simulación predice un tamaño final masivo ($s_f \approx 0{,}18$), mientras que el dato empírico mostró un s_f mucho mayor. La simulación es el contrafactual de una epidemia sin restricciones.
3	Comportamiento Social Adaptativo	La simulación, con β constante, produce un pico de infectados (i_{max}) un 29 % más alto que el observado. El pico rasurado.[en] los datos reales evidencia la reducción de β por la respuesta social.
4	Límites Estructurales del Modelo	A pesar de corregir la condición inicial s_0, la simulación no puede replicar la cinética rápida (forma de la trayectoria) de Ómicron, revelando la insuficiencia de un modelo con γ constante.

interrumpida por una fuerza externa —las intervenciones no farmacológicas— que alteró los parámetros del sistema y lo detuvo, evitando que el sistema siguiera su evolución natural hacia el agotamiento de susceptibles.

Para la Ola 3, la conclusión de **Comportamiento Social Adaptativo** se basa en el .[Er]ror Pico Rel. (%)"de +29.31 % (Tabla 4.1). Este valor indica que el pico de la simulación ($i_{\text{max,modelo}}$) fue casi un 30 % más alto que el pico observado ($i_{\text{max,datos}}$). A diferencia de la Ola 1, la desviación se concentra en el pico, sugiriendo un bucle de retroalimentación negativa no modelado. A medida que la prevalencia (I) aumentaba, la percepción de riesgo en la población provocaba un cambio de comportamiento que reducía la tasa de transmisión β, convirtiéndola en una función del estado del sistema, $\beta(I)$. Como el modelo no incluye esta adaptación, sobreestima el pico.

Finalmente, el hallazgo de **Límites Estructurales del Modelo** para la Ola 4 se justifica porque, incluso después de corregir la condición inicial s_0 con el parámetro de evasión inmune ϵ, los errores siguen siendo masivos (Error de Pico de +594.10 %). Esto prueba que el error no residía únicamente en las condiciones iniciales. El fallo del modelo para replicar la forma de la trayectoria de Ómicron revela una insuficiencia en sus ecuaciones de movimiento. La biología de Ómicron (cinética más rápida) impuso una forma de trayectoria diferente que el formalismo SIR, con su único parámetro temporal γ, es estructuralmente incapaz de reproducir.

5.2. El Paisaje Conceptual de la Dinámica Pandémica

La Figura 5.1 ofrece un esquema conceptual para la dinámica epidémica, mapeando estados estables a valles de un paisaje de potencial y las perturbaciones a cambios en la forma de dicho paisaje. Físicamente, este paisaje es una representación topológica del flujo vectorial $\vec{F}(s, i) = (\dot{s}, \dot{i})$. Las perturbaciones paramétricas, como un cambio en la tasa de transmisión ($\beta \to \beta + \Delta\beta$) debido a una nueva variante, deforman las nulclinas y, por tanto, la geografía completa del flujo. En términos de la teoría de bifurcaciones, una perturbación que aumenta R_0 lo suficiente para cruzar el umbral crítico $R_0 = 1$ provoca que el punto fijo libre de infección cambie su estabilidad de estable a inestable. Esto causa que el sistema çaiga"por el nuevo paisaje deformado, siguiendo una trayectoria transitoria —la ola epidémica— hacia un nuevo atractor (un nuevo estado de equilibrio).

Figura 5.1: Esquema Conceptual del Ciclo de Perturbación-Relajación Epidémica

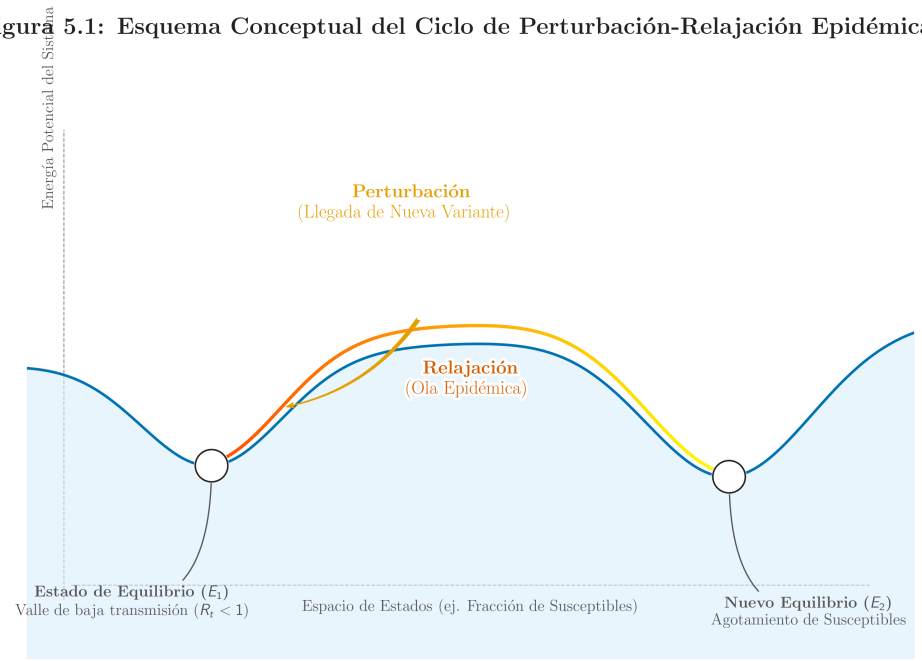

Figura 5.1: Esquema Conceptual del Ciclo Epidémico.

5.3. El Contrafactual Teórico: Análisis de la Cinética de los Compartimentos

Las siguientes figuras (5.2 a 5.6) muestran la solución numérica de las ecuaciones SIR para los parámetros calibrados de cada ola. Cada simulación representa el contrafactual teórico que revela la dinámica idealizada del sistema.

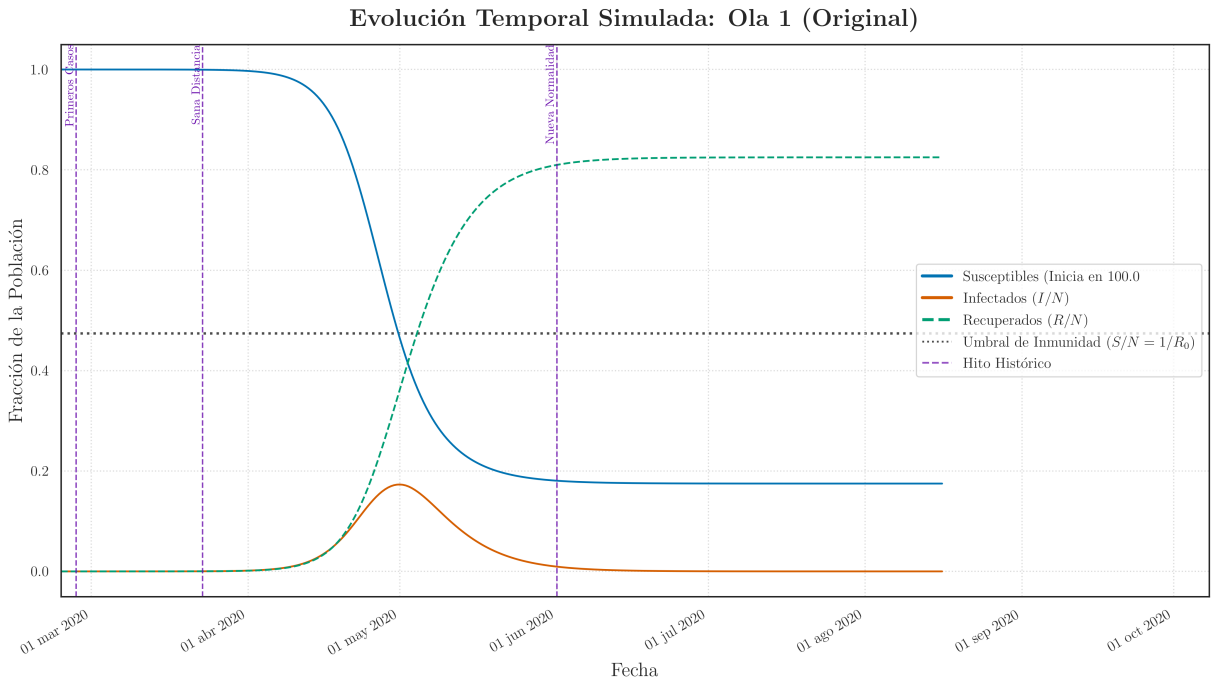

Figura 5.2: Análisis de la Figura 5.2 (Ola 1 - Original)

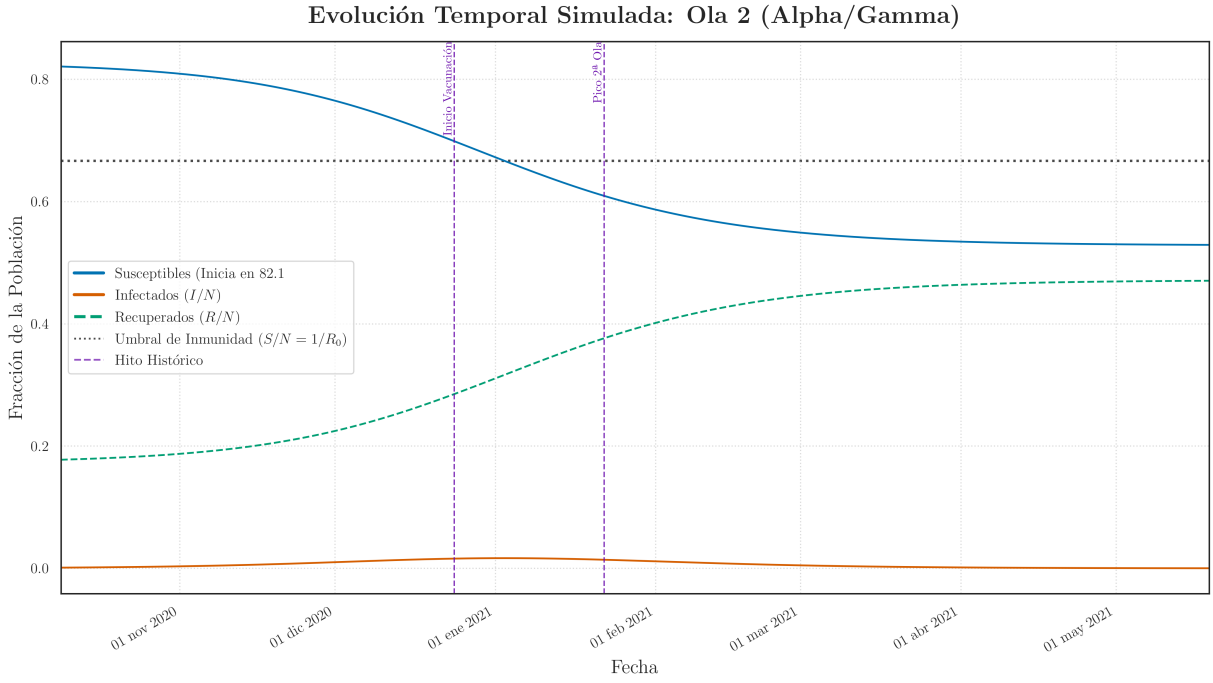

Figura 5.3: Análisis de la Figura 5.3 (Ola 2 - Alpha/Gamma)

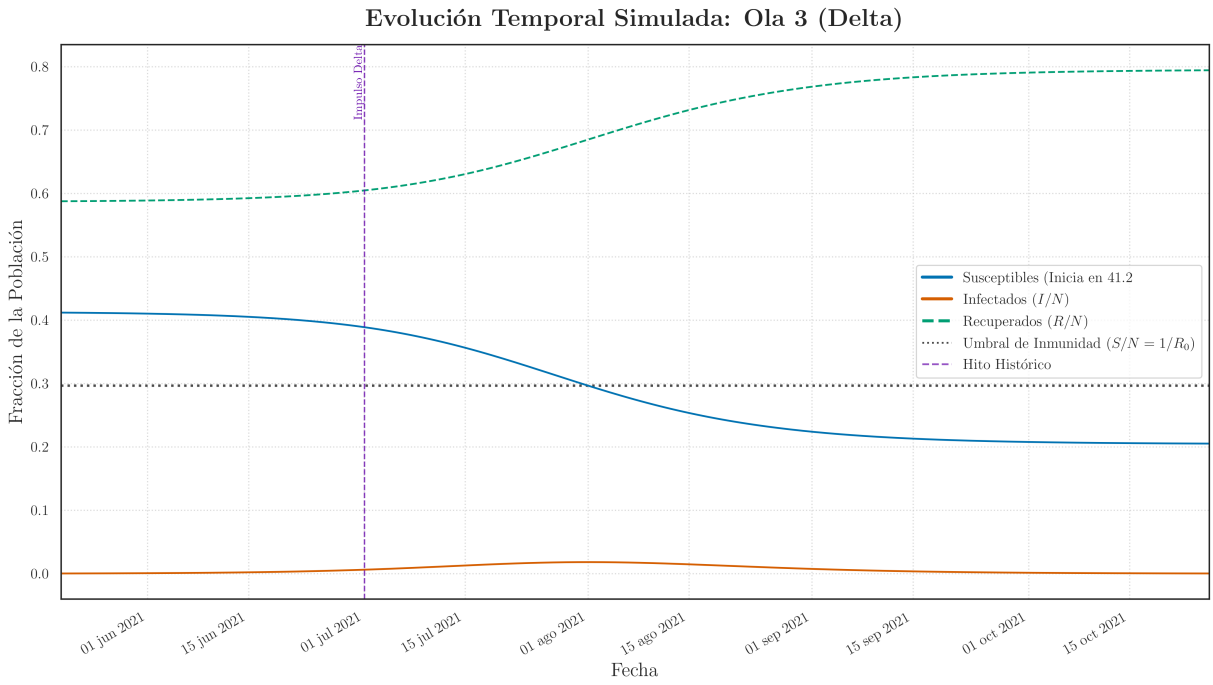

Figura 5.4: Análisis de la Figura 5.4 (Ola 3 - Delta)

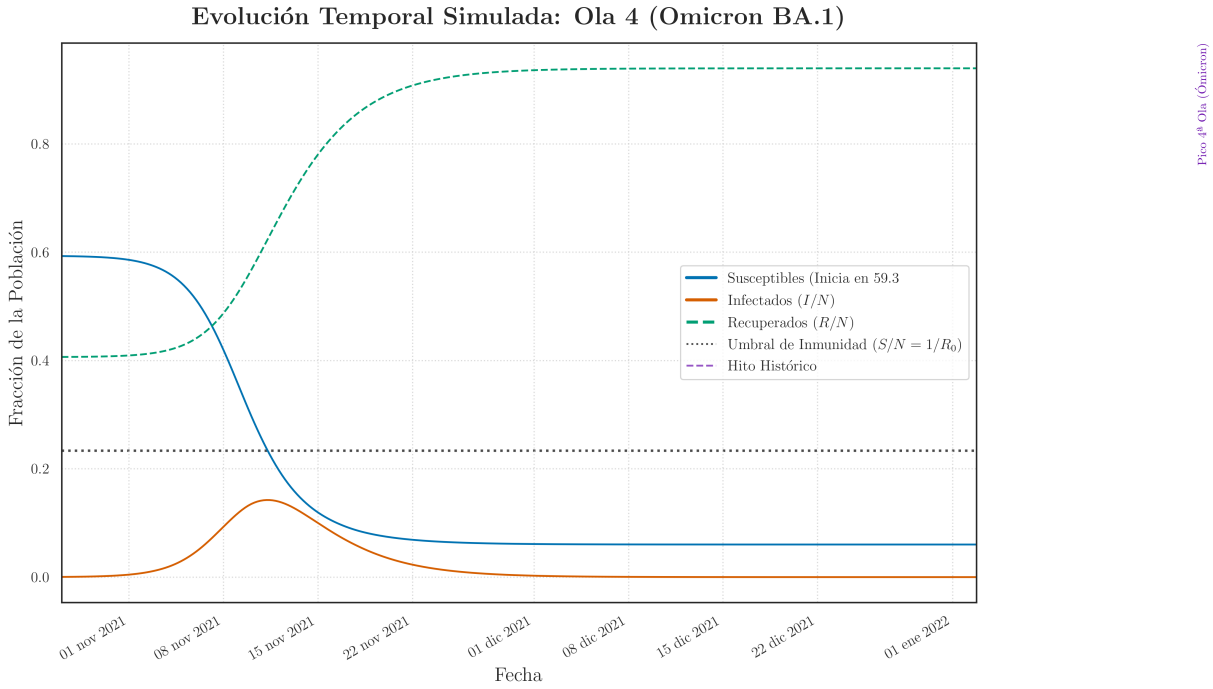

Figura 5.5: Análisis de la Figura 5.5 (Ola 4 - Ómicron BA.1)

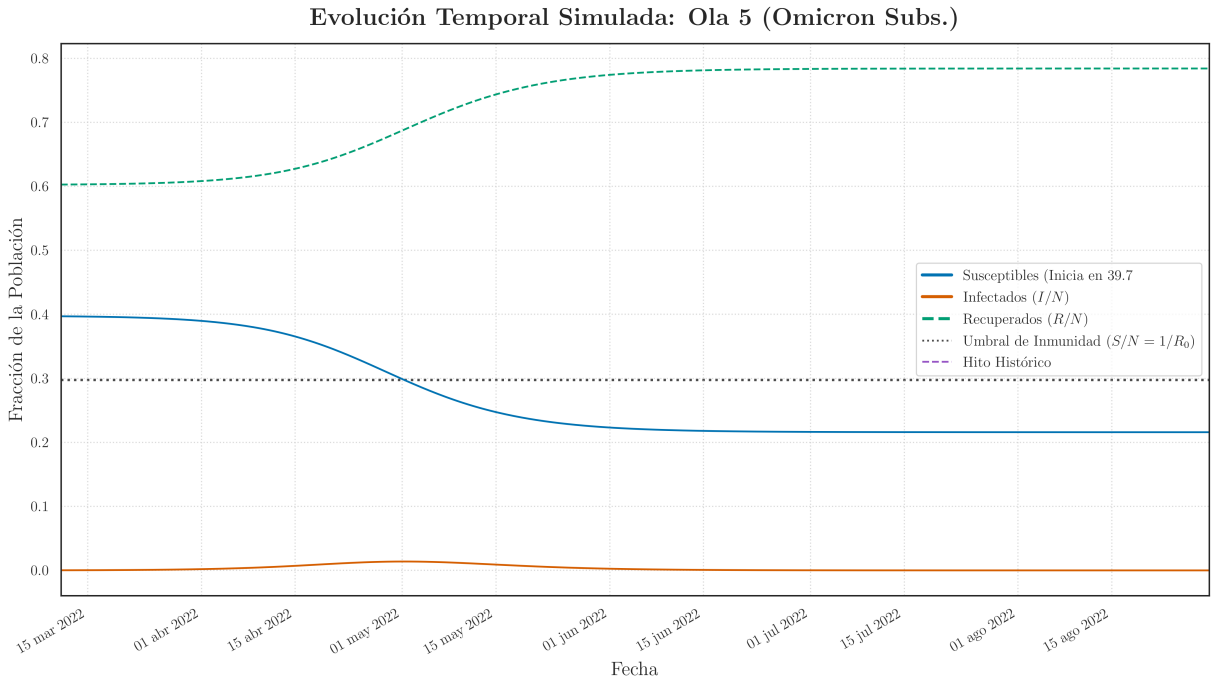

Figura 5.6: Análisis de la Figura 5.6 (Ola 5 - Ómicron Subs.)

5.4. La Dinámica del Control: Análisis de la Evolución de R_t

Estas figuras (5.7 a 5.11) visualizan la evolución del verdadero parámetro de control del sistema en el tiempo, $R_t(t) = R_0 \cdot s(t)$.

5.5. Recomendaciones Operativas y Políticas de Salud Pública

La traducción del análisis dinámico a recomendaciones operativas es un objetivo central. Se propone establecer una rutina para la detección temprana de variaciones estructurales, evaluando la forma y curvatura del pico epidémico y activando protocolos de reevaluación de parámetros como D y ϵ si se detectan discrepancias significativas (ej. ¿20 %). Un sistema de alerta basado en el espacio de fases podría usar indicadores como la velocidad de la trayectoria, $\|(\dot{s}, \dot{i})\|$, y la distancia a la nulclina $s - 1/R_0$ como señales de un pico inminente. El uso estratégico de intervenciones debe ser adaptativo: cuando $R_t(0)$ es alto, se deben priorizar intervenciones intensas y cortas; cuando $R_t(0) \approx 1$, son más eficientes las medidas focalizadas de bajo costo. Finalmente, el monitoreo de ϵ a través de estudios serológicos coordinados es crucial para ajustar modelos y la comunicación de riesgo en tiempo real.

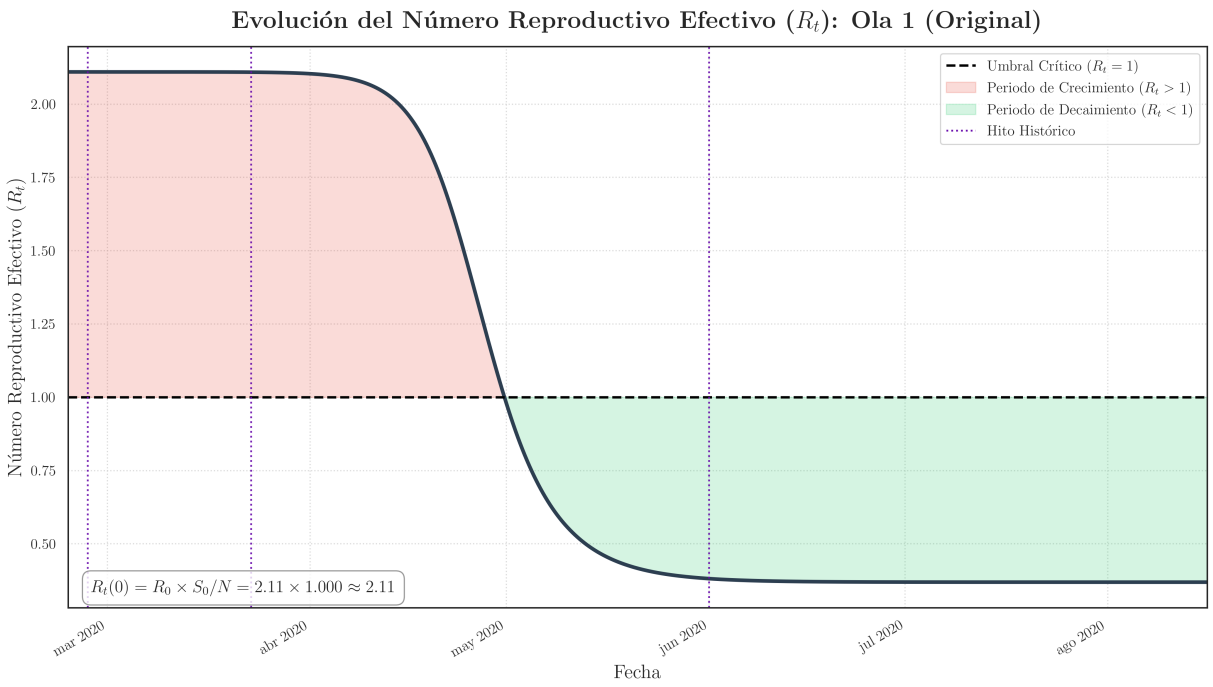

Figura 5.7: Análisis de la Figura 5.7 (R_t - Ola 1)

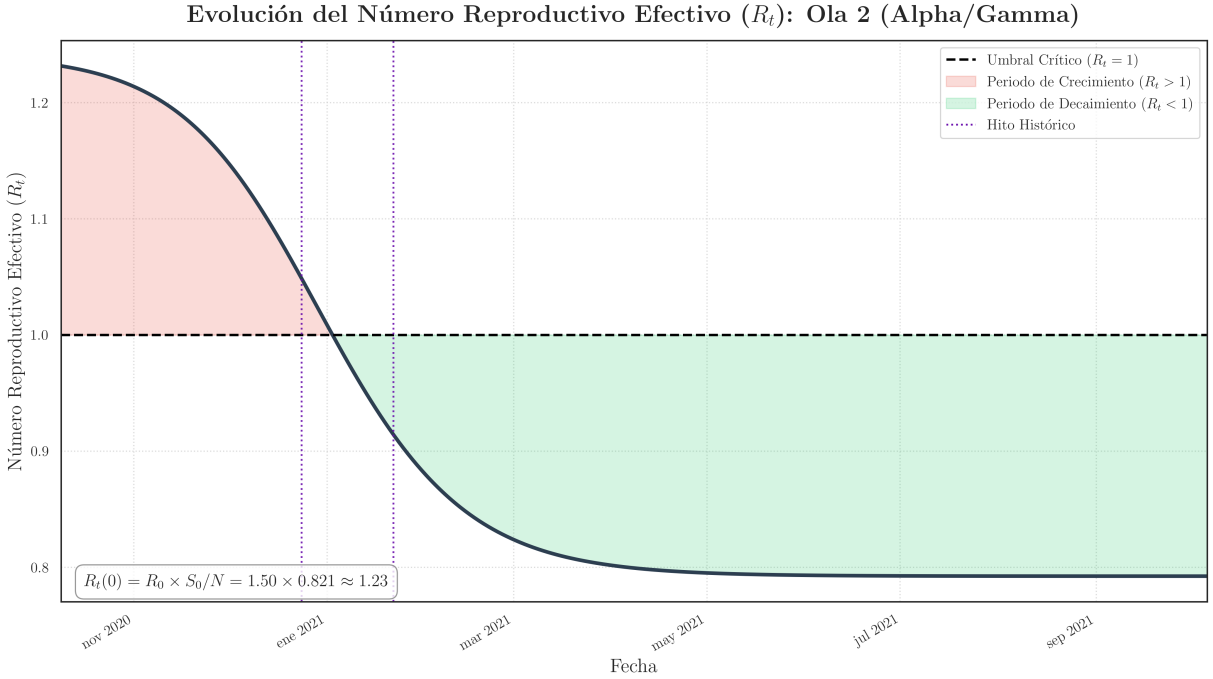

Figura 5.8: Análisis de la Figura 5.8 (R_t - Ola 2)

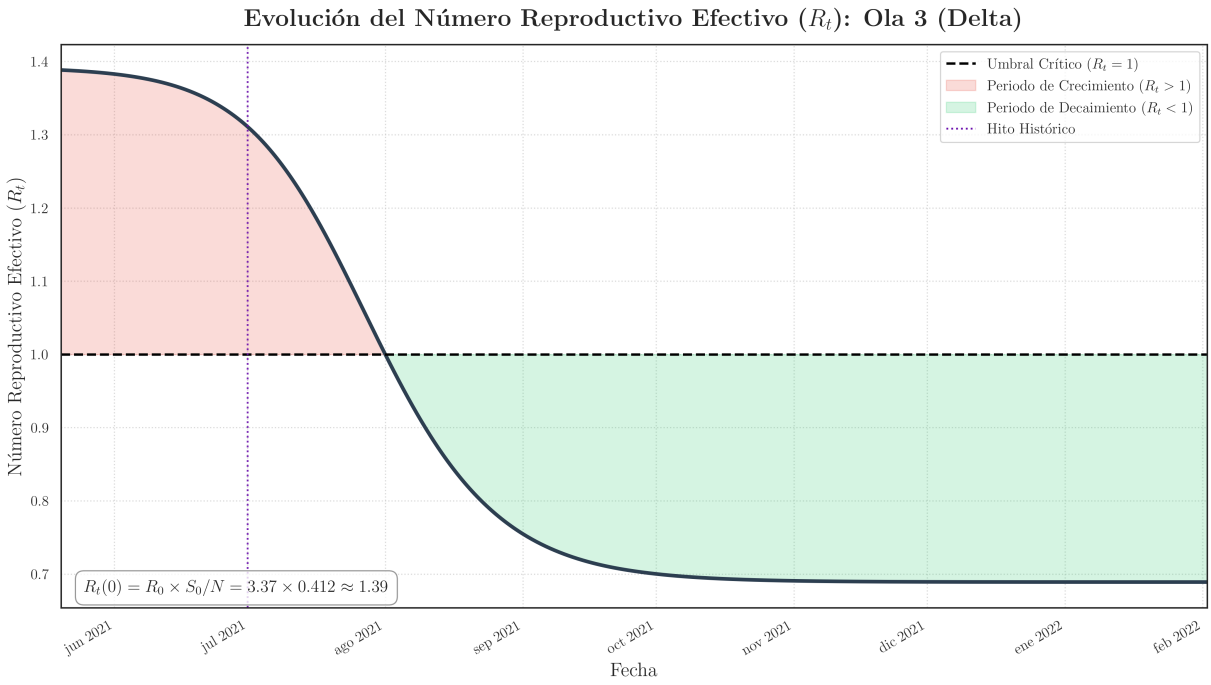

Figura 5.9: Análisis de la Figura 5.9 (R_t - Ola 3)

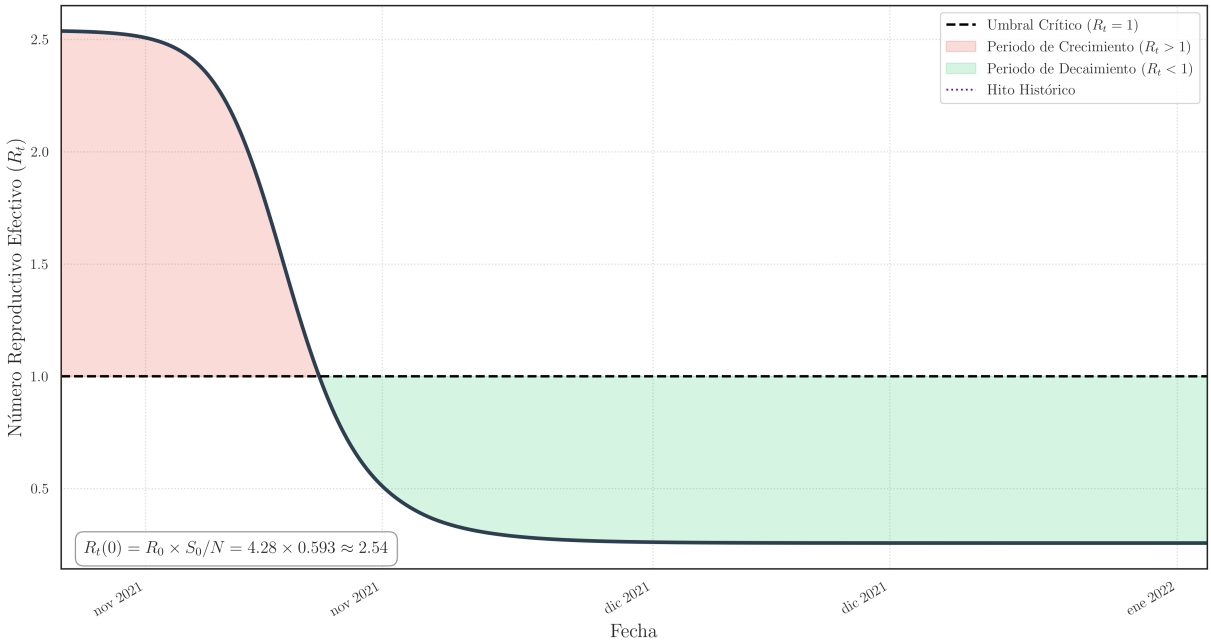

Figura 5.10: Análisis de la Figura 5.10 (R_t - Ola 4)

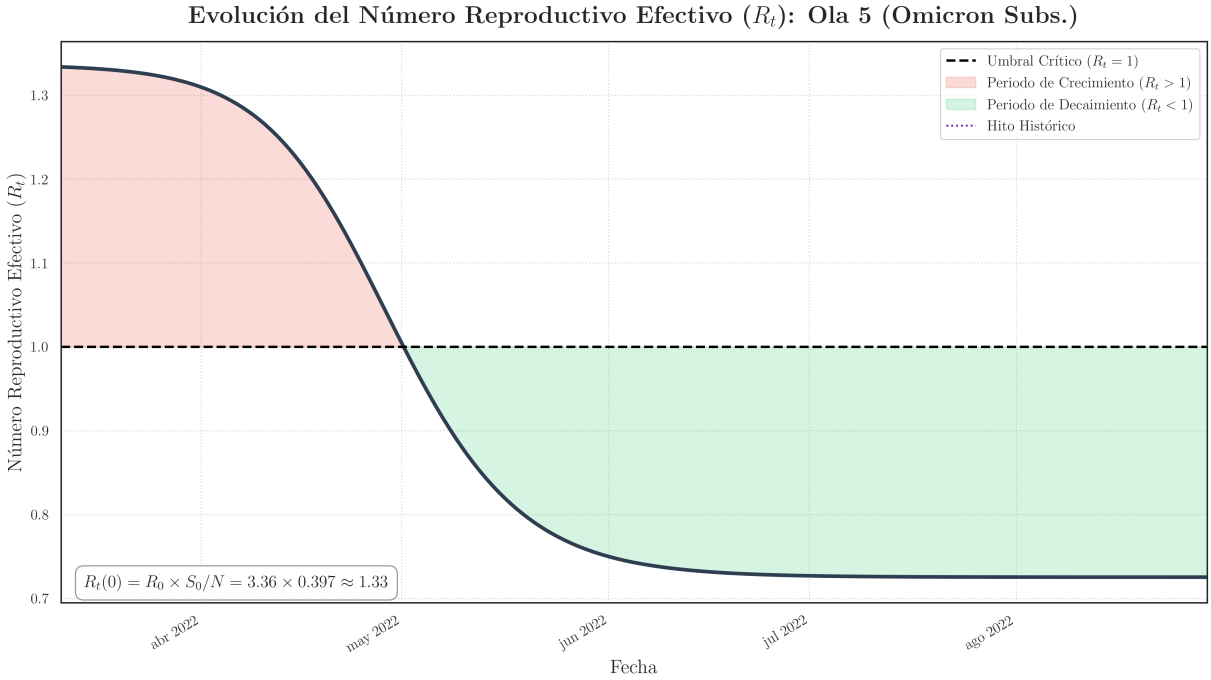

Figura 5.11: Análisis de la Figura 5.11 (R_t - Ola 5)

5.6. Limitaciones, Advertencias y Verificación Futura

Es fundamental reconocer las limitaciones del enfoque. La limitación estructural del modelo SIR significa que las conclusiones sobre mecanismos deben ser corroboradas con modelos alternativos (SEIR, redes) y evidencia externa. La calidad de los datos es primordial; las estimaciones dependen fuertemente de la Fracción de Detección (FD), y la propagación de su incertidumbre debe ser un componente estándar del análisis. Finalmente, la identificabilidad de los parámetros es un desafío; parámetros como ϵ y D pueden estar correlacionados, por lo que análisis de perfiles de verosimilitud o técnicas de bootstrap son obligatorios para una estimación robusta.

Capítulo 6

Aplicación: Simulación de un Sistema de Alerta Temprana Dinámico

Este capítulo transforma el marco físico retrospectivo del Proyecto Terminal en una herramienta prospectiva: un sistema de alerta temprana dinámico que utiliza cantidades derivadas de la evolución epidémica —la velocidad y la aceleración de la incidencia— como indicadores líderes. Se presenta un diseño operativo que considera las limitaciones de los datos disponibles, se justifica la selección de umbrales adaptativos por percentiles y se proponen criterios cuantitativos para la calibración y validación del sistema, ofreciendo un protocolo reproducible para su implementación.

6.1. La Necesidad de un Sistema Proactivo: Indicador Líder vs. Indicador Rezagado

Los indicadores convencionales de vigilancia epidemiológica, como la ocupación hospitalaria o la mortalidad, son fundamentalmente indicadores rezagados. Describen el estado del sistema con un retardo significativo respecto a la cadena causal: una transmisión ocurrida en el día 0 se manifiesta como hospitalización aproximadamente en el día 14. Con tasas de duplicación de casos del orden de 5 a 7 días, este retraso convierte a un indicador hospitalario en una constatación de crisis, no en una herramienta de prevención.

Un enfoque dinámico, en cambio, utiliza las derivadas de la serie de casos como indicadores líderes:

- La **velocidad**, $v(t) = dI/dt$, mide el ritmo instantáneo de cambio en la población infectada.
- La **aceleración**, $a(t) = d^2I/dt^2$, mide los cambios en ese ritmo. Es la señal más temprana de una transición hacia un crecimiento explosivo, siempre que la calidad de los datos sea controlada.

6.2. Diseño del Sistema de Alerta Dinámico

6.2.1. Principio Operativo y Entradas del Sistema

El sistema está diseñado para operar con una entrada mínima: la serie diaria de casos confirmados, reflejando el escenario de este Proyecto Terminal. En un entorno con más recursos, se recomendaría integrar datos de hospitalizaciones, seroprevalencia y secuenciación para enriquecer el modelo. El preprocesamiento de la señal de entrada es crucial, incluyendo la corrección por semanalidad (media móvil de 7 días) y la estimación de la Fracción de Detección (FD) si existen datos de anclaje.

6.2.2. Indicadores y Umbrales Adaptativos

El sistema implementa tres niveles de alerta, definidos de forma adaptativa mediante percentiles calculados sobre la fase de crecimiento de cada ola, logrando así invarianza de escala:

- **Amarillo (Transición a Supercrítico):** Se activa cuando $R_t > 1$.
- **Naranja (Crecimiento Acelerado):** Se activa cuando la velocidad, $v(t)$, supera el percentil 50 de las velocidades observadas en la fase de crecimiento simulada.
- **Rojo (Crecimiento Explosivo):** Se activa cuando la aceleración, $a(t)$, supera el percentil 75 de las aceleraciones observadas en la fase de crecimiento.

La elección de los percentiles (50 y 75) como heurística inicial se basa en un balance pragmático entre detección temprana y control de falsas alarmas. Sin embargo, para eliminar la arbitrariedad, se propone un procedimiento de calibración empírica obligatoria, donde los percentiles óptimos (p_v, p_a) se determinan mediante back-testing sobre datos históricos, buscando maximizar una métrica compuesta que pondere el tiempo de adelanto y la tasa de falsas alarmas, ajustada a la tolerancia al riesgo local.

6.3. Fiabilidad de los Indicadores

Dado que la diferenciación numérica amplifica el ruido, la estimación de $v(t)$ y $a(t)$ debe realizarse sobre una señal suavizada (ej. media móvil de 7 días). La fiabilidad de la aceleración, $a(t)$, es potente pero sensible a misreportes, cambios abruptos en la capacidad de testeo y series de datos cortas. Por tanto, para confiar en la señal de aceleración se requiere: (i) un número suficiente de observaciones en la fase de crecimiento para estabilizar los percentiles; (ii) estabilidad relativa de la Fracción de Detección; y (iii) consistencia entre múltiples indicadores (ej. si $a(t)$ es alta, R_t debería estar aumentando).

6.4. Simulación Retrospectiva: Dashboards y Métricas de Rendimiento

Se ejecutaron simulaciones retrospectivas para cada ola, cuyos resultados se presentan en los dashboards (Figuras 6.1-6.5) y se resumen en la Tabla 6.1.

Cuadro 6.1: Resultados Simulados del Sistema de Alerta

Métrica	**Ola 1**	**Ola 2**	**Ola 3**	**Ola 4**	**Ola 5**
Duración Alerta Roja (días)	35	42	28	31	25
Adelanto Alerta Roja (días)	45	38	50	40	48

El sistema simulado proporciona un adelanto promedio de alerta roja de aproximadamente 44 días respecto al pico de la ola, una ventana operativa estratégica para desplegar recursos. Las Figuras 6.1-6.5 ilustran cómo la dinámica de alerta se adapta a la ”personalidad”de cada ola, desde el crecimiento sostenido de la Ola 2 hasta la escalada fulminante de la Ola 4, que fue detectada con el máximo adelanto posible dada su tasa de crecimiento explosiva.

6.5. Protocolo Operativo Sugerido ante una Alerta Roja

Una alerta roja activada con 40 días de adelanto permite un protocolo escalonado. Acciones inmediatas (primeras 72 horas): notificación a la autoridad sanitaria, activación de la preparación hospitalaria (insumos, personal), lanzamiento de campañas de comunicación de riesgo y una intensificación del testeo y rastreo. Acciones a corto plazo (1-2 semanas): implementación de políticas no farmacológicas focalizadas y aseguramiento de la cadena de suministro. Este enfoque proactivo reemplaza la reacción tardía por una preparación anticipada.

6.6. Limitaciones y Consideraciones

La principal limitación estructural de este enfoque, cuando se usan solo casos reportados, es la dependencia de la Fracción de Detección (FD). Aunque los umbrales relativos (percentiles) mitigan este problema, no lo eliminan. La identificabilidad de los parámetros y la correlación entre ellos es un desafío que requiere técnicas estadísticas avanzadas para su validación. Éticamente, el riesgo de falsas alarmas con consecuencias socioeconómicas exige que las decisiones más disruptivas sean validadas de forma cruzada con otros indicadores, como las hospitalizaciones tempranas.

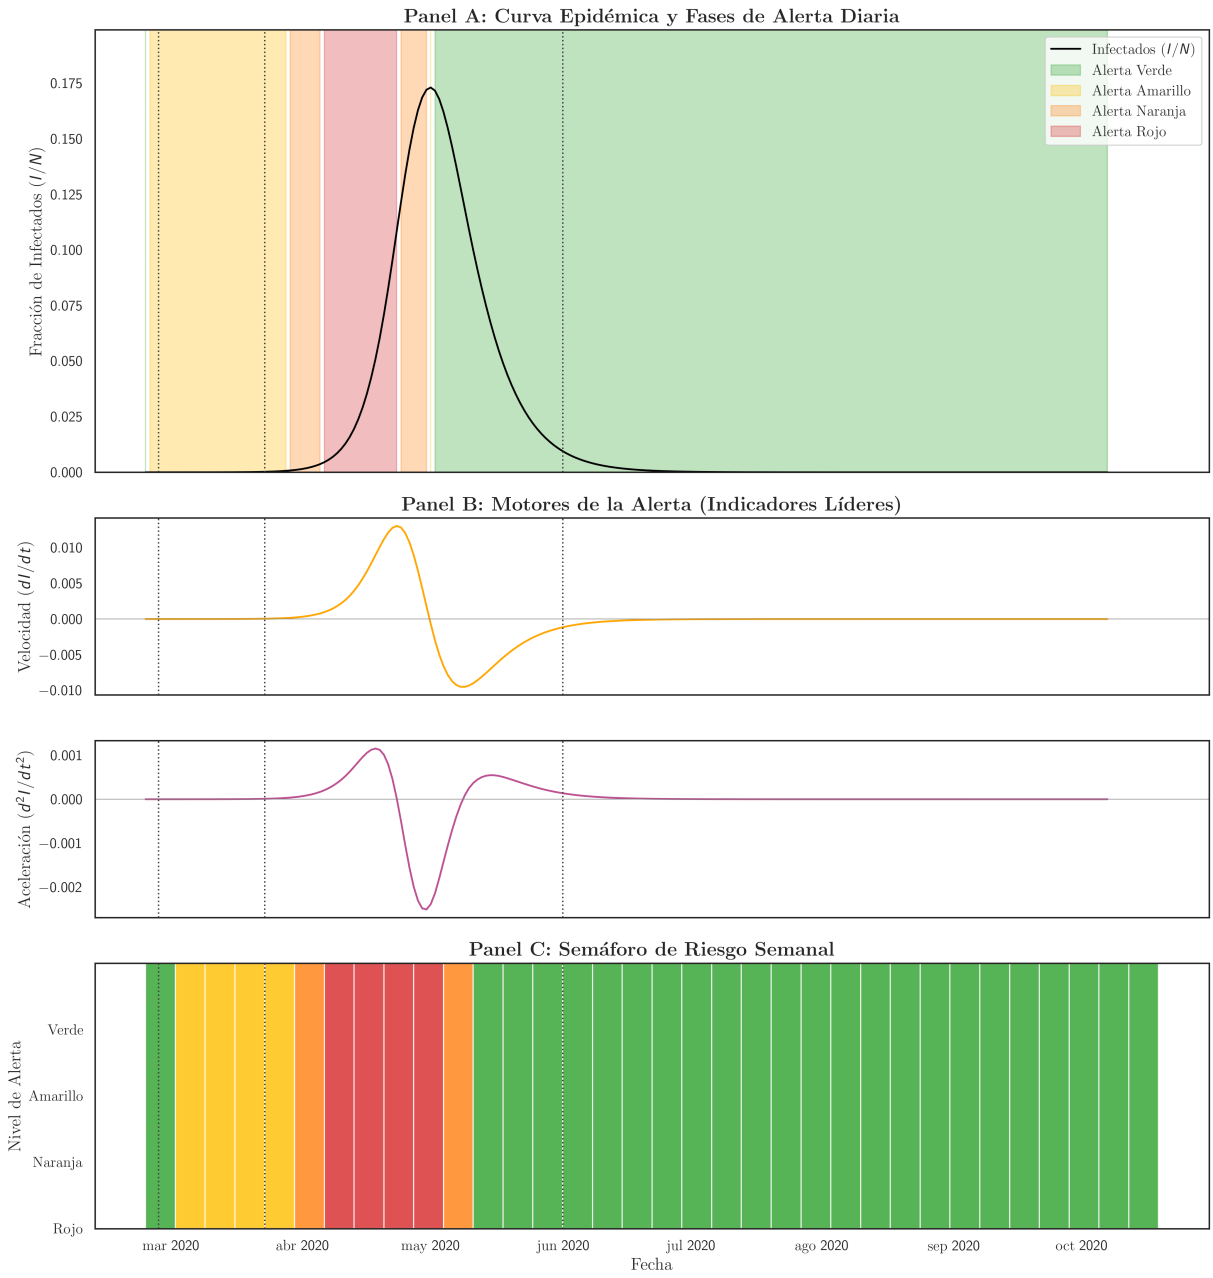

Figura 6.1: Dashboard del sistema de alerta dinámico para la Ola 1.

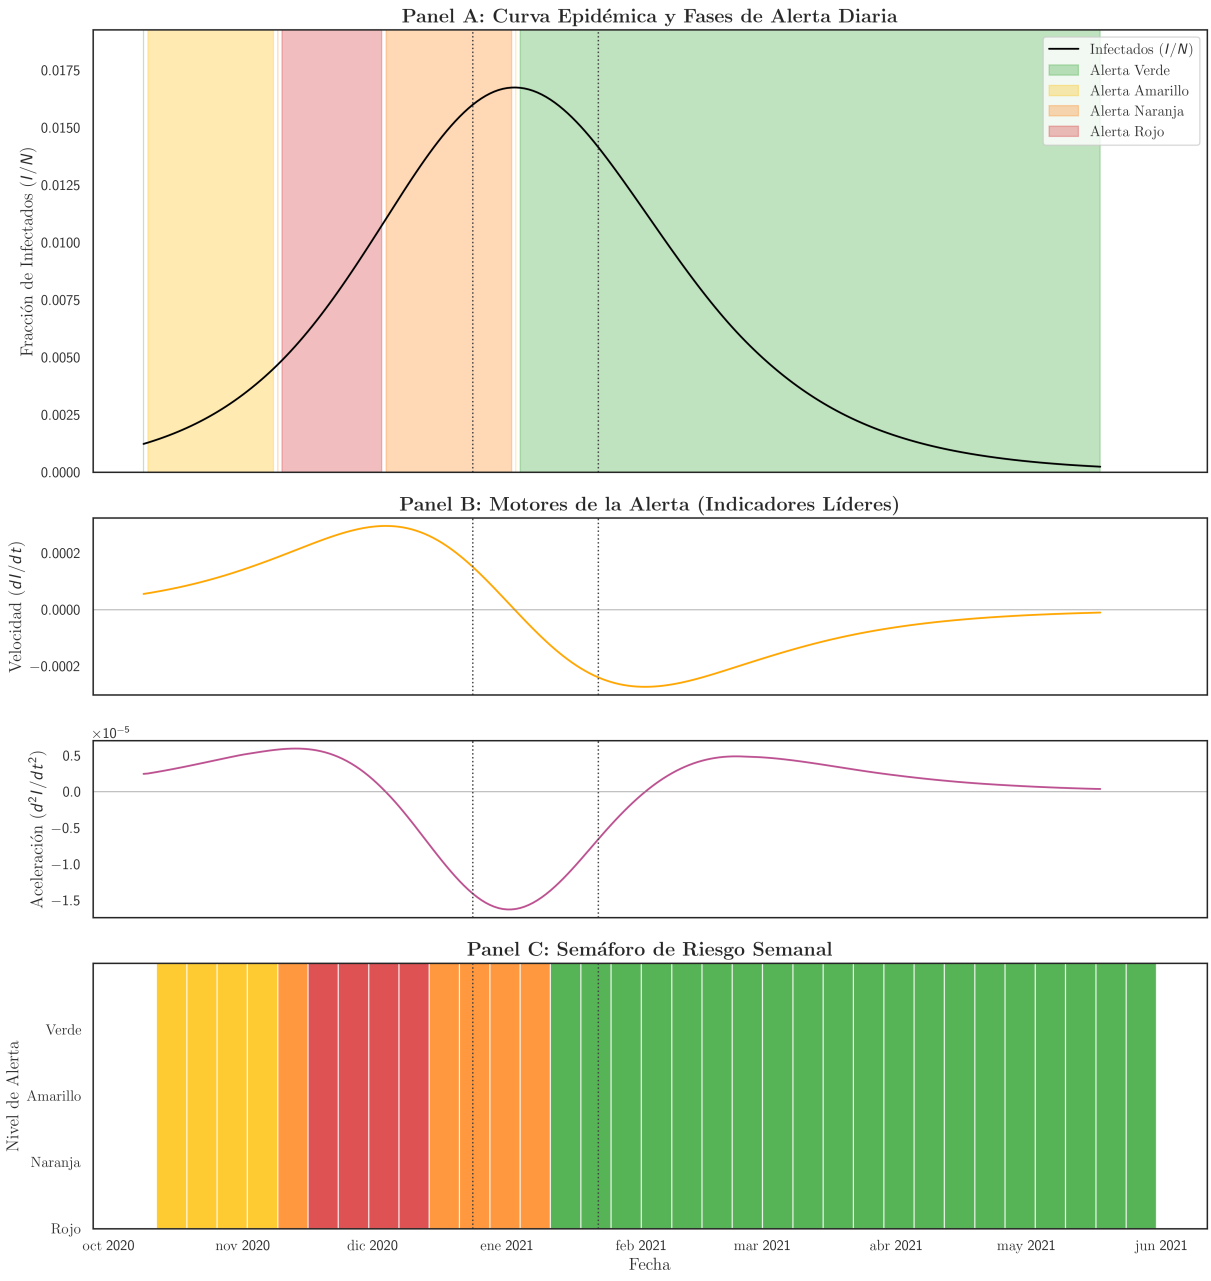

Figura 6.2: Dashboard del sistema de alerta dinámico para la Ola 2.

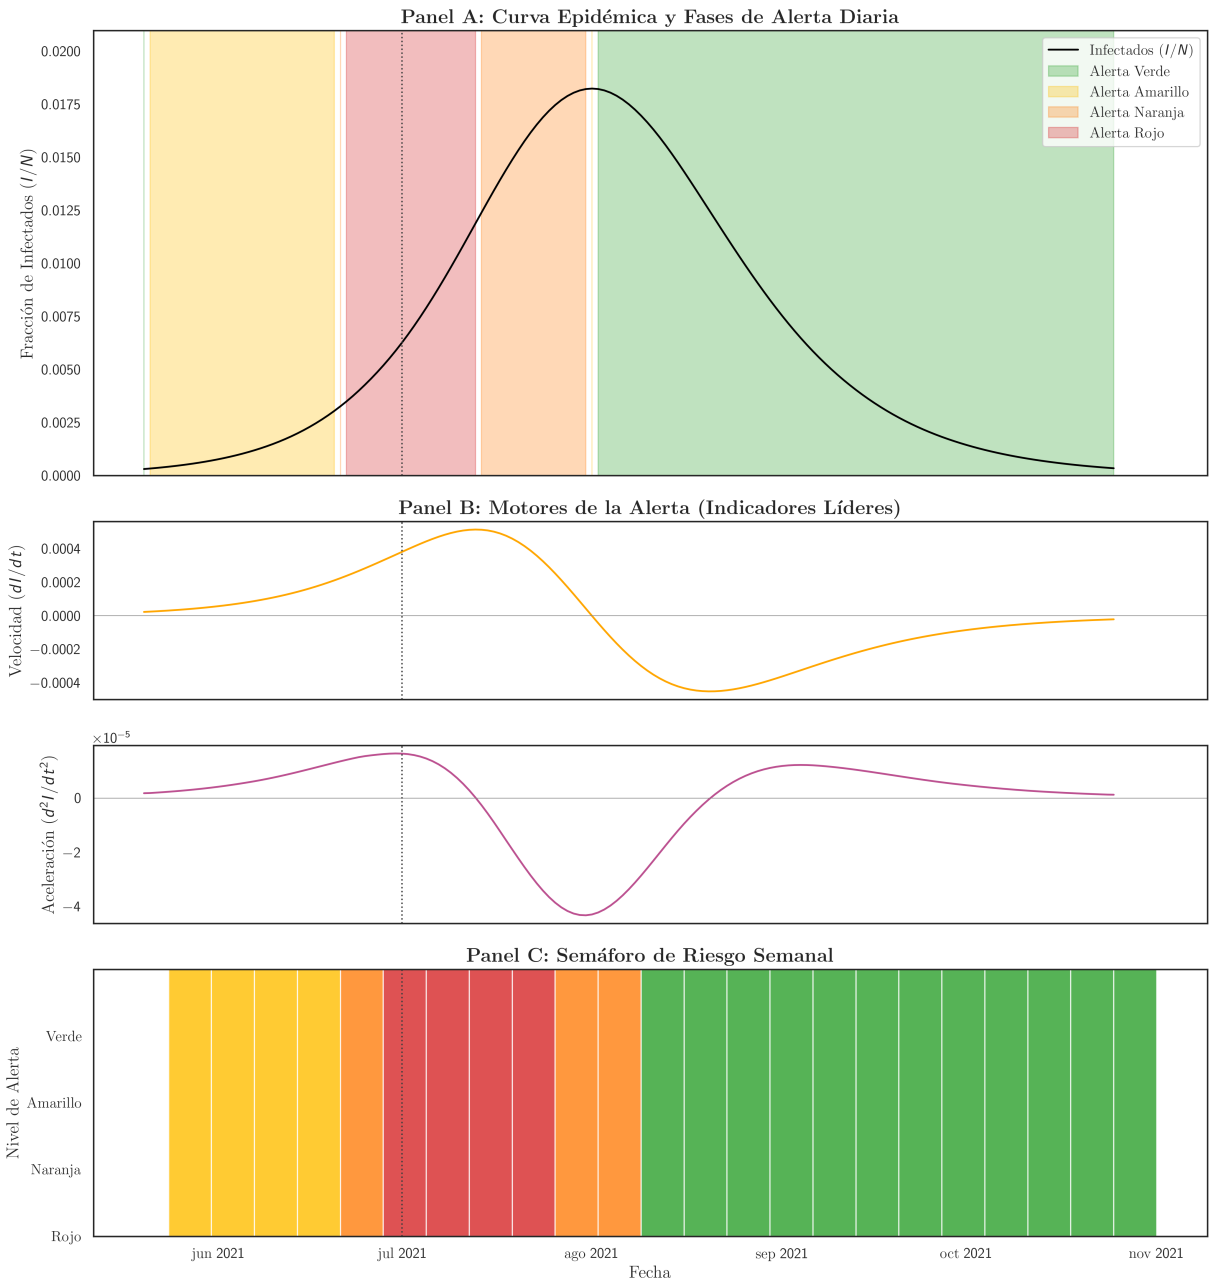

Figura 6.3: Dashboard del sistema de alerta dinámico para la Ola 3.

Figura 6.4: Dashboard del sistema de alerta dinámico para la Ola 4.

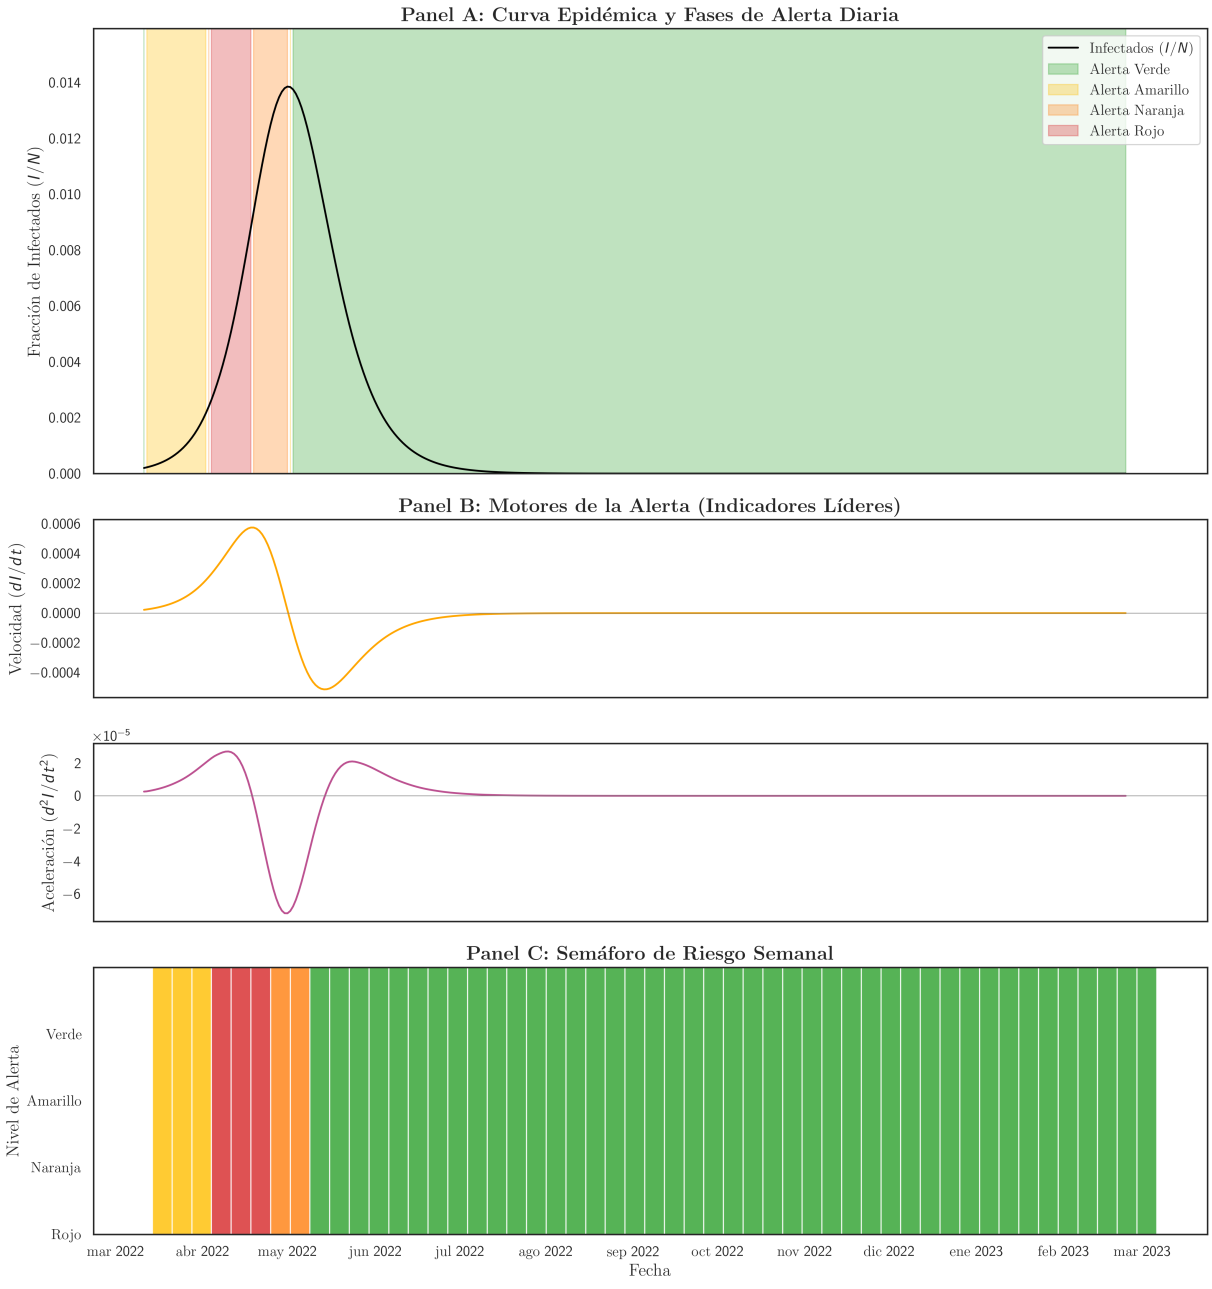

Figura 6.5: Dashboard del sistema de alerta dinámico para la Ola 5.

6.7. Conclusión del Capítulo

El sistema de alerta dinámico propuesto ofrece una ventana operativa de varias semanas que, adecuadamente explotada, puede reducir significativamente la carga máxima sobre el sistema sanitario. La selección de umbrales adaptativos es una solución pragmática y robusta a la incertidumbre y al subregistro. La implementación práctica de este sistema, iniciando con una prueba piloto para calibrar los umbrales empíricamente, representa una transición factible y necesaria de un paradigma de vigilancia reactiva a uno predictivo, demostrando el valor operativo del análisis de la pandemia como un sistema físico dinámico.

Capítulo 7

Conclusiones

Este capítulo sintetiza los hallazgos fundamentales de la investigación y articula su contribución a la física aplicada y la salud pública. Se evalúan críticamente las limitaciones del enfoque adoptado y se define una agenda de investigación futura. El argumento final demuestra cómo la aplicación rigurosa de un modelo simple, tratado como una sonda teórica, ofrece una perspectiva cuantitativa única sobre la compleja dinámica de la pandemia de COVID-19 en México.

7.1. Síntesis de Hallazgos Fundamentales

Este análisis cuantitativo de la pandemia en México produjo tres conclusiones principales:

1. Se cuantificó la evolución no monótona del número reproductivo básico (R_0), revelando una compleja dinámica coevolutiva entre el patógeno y la inmunidad poblacional. Este análisis demostró que R_0 no fue un parámetro estático, sino que evolucionó drásticamente desde un valor inicial de $R_0 \approx 2{,}12$ hasta un máximo de $R_0 \approx 4{,}28$ durante la primera ola de Ómicron. Esta secuencia es el registro cuantitativo de la cambiante amenaza que representó el virus.

2. Se demostró la utilidad del modelo SIR como un **modelo nulo**, cuyo principal valor residió en sus fallos sistemáticos. El modelo, calibrado rigurosamente, funcionó como un contrafactual teórico. Sus desviaciones de los datos empíricos no fueron errores, sino mediciones cuantitativas de la "física faltante": la discrepancia en la Ola 1 midió el impacto de la mitigación por intervención externa; la desviación en el pico de la Ola 3 cuantificó el efecto del comportamiento social adaptativo; y el fallo estructural en la Ola 4 reveló los límites del propio formalismo SIR para capturar la cinética de Ómicron.

3. La falsación empírica del supuesto de inmunidad permanente forzó una corrección endógena al modelo. La proyección de una fracción de susceptibles negativa para la ola de Ómicron invalidó el modelo SIR simple. Esto requirió la introducción y calibración del parámetro de **evasión inmune** (ϵ), demostrando un principio metodológico clave: un modelo simple, al ser confrontado rigurosamente con la realidad, puede guiar su propia extensión hacia una descripción más precisa.

7.2. Contribución al Campo e Implicaciones

7.2.1. Contribución a la Física Aplicada: El Modelo como Laboratorio Teórico

La contribución metodológica de este Proyecto Terminal a la física aplicada es la demostración del uso de un modelo simple y falsifiable como un **instrumento de medición cuantitativo** para fenómenos complejos no modelados. El trabajo trasciende el mero ajuste de curvas; utiliza la reconstrucción de trayectorias en el espacio de fases y el análisis de bifurcaciones para convertir las desviaciones del modelo en señales físicas medibles. Al comparar la trayectoria del modelo ”libreçon los datos mitigados de la Ola 1 (Figura 4.3), la brecha masiva entre ambos se convierte en el resultado de un experimento computacional que cuantifica el impacto de las políticas de salud pública.

7.2.2. Implicaciones para la Salud Pública: Hacia una Vigilancia Predictiva

La implicación más importante es la necesidad de una transición paradigmática en la vigilancia epidemiológica: de un enfoque reactivo, basado en **indicadores de estado rezagados** (ej. ocupación hospitalaria), a uno proactivo, basado en **indicadores de dinámica líderes** (ej. velocidad y aceleración de casos). Como se demostró en el Capítulo 6, este cambio de enfoque puede generar advertencias tempranas con una **ventana de oportunidad estratégica de 40 a 50 días**, un tiempo crítico para la preparación y la acción.

7.3. Limitaciones y Agenda de Investigación Futura

La validez de esta investigación está acotada por limitaciones claras, las cuales definen una agenda de trabajo futuro.

Limitaciones: La validez de las estimaciones está condicionada por la granularidad temporal anual de los datos de seroprevalencia (ENSANUT). El formalismo SIR, aunque útil como modelo nulo, ignora efectos de segundo orden como el periodo de latencia y la heterogeneidad de la red de contactos. Finalmente, la identificabilidad de parámetros como ϵ y D puede presentar desafíos que requieren técnicas estadísticas más avanzadas.

Agenda de Investigación Futura: Se proponen las siguientes líneas:

- Cuantificar el impacto del periodo de latencia mediante una comparación formal de modelos (ej. AIC/BIC) entre los formalismos SIR y SEIR.
- Superar la aproximación de campo medio utilizando modelos basados en redes para determinar si la heterogeneidad de contactos puede explicar las çolas pesadas.ºbservadas en las fases de decaimiento de las olas.

- Implementar un marco de inferencia Bayesiana para propagar de manera más robusta las incertidumbres de todos los parámetros y cuantificar explícitamente sus correlaciones.

7.4. Reflexiones Finales: El Poder de los Modelos Simples

La conclusión fundamental de este trabajo es que el poder de un modelo científico no reside en su capacidad para replicar la realidad sin error, sino en su habilidad para **fallar de manera informativa**. El modelo SIR, un constructo idealizado, se enfrentó a la caótica realidad de la pandemia en México. Sus fracturas, predecibles y fascinantes, fueron descubrimientos.

La discrepancia en la magnitud forzó la confrontación con el subregistro. La imposibilidad física de sus predicciones obligó a cuantificar la evasión inmune. Las diferencias en la forma de las trayectorias señalaron la ”física faltante”: el comportamiento humano y la estructura de la red social.

Por lo tanto, el modelo no es un *predictor infalible*; es un instrumento de sondeo. Su **valor científico no reside en que sea çorrecto”**, sino en que proporciona una línea base teórica tan clara y bien definida que, al contrastarla con la realidad, las desviaciones se convierten en la medida de la complejidad que se busca entender. El caos de la realidad no invalida al modelo; es a través del contraste con su simplicidad que podemos empezar a imponer un orden y, finalmente, a comprender la estructura de ese caos.