# Análisis de la Dinámica de Transmisión del COVID-19 en México como un Sistema Físico No Lineal: Un Enfoque desde el Modelo SIR y Teoría de Sistemas Dinámicos

Proyecto Terminal I

Presenta:

**Ángel Omar García Hernández**

Asesor:

**Dr. Adrian Mauricio Escobar Ruiz**

Universidad Autónoma Metropolitana

Agosto 2025

# Resumen

La pandemia de COVID-19 en México se analiza bajo el paradigma de la física de sistemas dinámicos no lineales. Utilizando un modelo Susceptible-Infectado-Recuperado (SIR) como una aproximación de campo medio, esta tesis reconstruye las trayectorias empíricas de las cinco grandes olas pandémicas en el espacio de fases. El modelo es rigurosamente calibrado con datos de vigilancia epidemiológica, incorporando una corrección fundamental por subregistro basada en encuestas nacionales de seroprevalencia (ENSANUT) y un parámetro de evasión inmune inferido numéricamente para las olas de Ómicron. Se emplea una simulación de Monte Carlo para cuantificar la evolución del número reproductivo básico ($R_0$), revelando una dinámica no monótona que alcanzó un máximo de $R_0 \approx 4{,}28$ con la variante Ómicron BA.1. La validación del modelo muestra que, si bien funciona como una robusta aproximación de primer orden, sus discrepancias sistemáticas con los datos son altamente informativas: la desviación en la primera ola constituye una evidencia cuantitativa del efecto de las intervenciones no farmacéuticas, mientras que los fallos en la predicción de la ola de Ómicron exponen los límites del formalismo SIR simple. Se concluye que el enfoque de la física no solo permite modelar la pandemia, sino que utiliza las fallas del modelo como una sonda teórica para entender la complejidad subyacente del sistema socio-sanitario real.

**Palabras Clave:** COVID-19, Modelo SIR, Sistemas Dinámicos, Espacio de Fases, Número Reproductivo Básico ($R_0$), Evasión Inmune, Simulación de Monte Carlo, Física Estadística.

# Agradecimientos

Aquí el autor expresa su gratitud a las personas e instituciones que apoyaron la realización de este trabajo. A mi asesor, Dr. Adrian Mauricio Escobar Ruiz, por su guía y paciencia. A mi familia por su incondicional apoyo...

Para la elaboración de este documento, se utilizó la asistencia de herramientas de inteligencia artificial generativa (Gemini de Google). Su rol se centró en tareas de apoyo como la reestructuración de párrafos, el refinamiento de la redacción para mejorar la claridad y la formalidad académica, y la depuración de código. El diseño de la investigación, el análisis de los datos, la interpretación de los resultados y las conclusiones aquí presentadas son enteramente obra del autor.

# Índice general

**Resumen** 1

**Agradecimientos** 2

**1. Introducción a la Física de las Pandemias** 5
- 1.1. La Pandemia como Objeto de Estudio de la Física . . . 5
- 1.2. El Modelo SIR como Aproximación de Campo Medio . . . 6
- 1.3. Hipótesis, Pregunta de Investigación y Objetivos . . . 7
- 1.4. Estructura de la Tesis . . . 8

**2. Marco Teórico - La Epidemiología como un Sistema Dinámico** 9
- 2.1. El Modelo SIR: Postulados, Derivación y Formalismo . . . 9
  - 2.1.1. Derivación de las Ecuaciones de Movimiento . . . 10
- 2.2. Estructura Geométrica de la Dinámica Epidémica . . . 11
  - 2.2.1. Espacio de Fases y la Constante de Movimiento . . . 11
  - 2.2.2. Nuclinas y Estructura del Flujo . . . 11
- 2.3. Puntos de Equilibrio y Análisis de Estabilidad Lineal . . . 12
  - 2.3.1. Estabilidad del Equilibrio Libre de Enfermedad (DFE) . . . 13
  - 2.3.2. Estabilidad del Equilibrio Endémico (EE) . . . 13
- 2.4. La Transición Epidémica como una Bifurcación . . . 13
- 2.5. Limitaciones del Modelo Canónico y Extensiones Requeridas . . . 14

**3. Datos, Metodología y Calibración del Modelo** 15
- 3.1. Adquisición y Preprocesamiento de Datos: Aislamiento de la Señal Epidemiológica 15
- 3.2. Definición Operacional de Olas: Un Criterio Topológico Objetivo . . . 16
- 3.3. Parametrización del Modelo . . . 18
  - 3.3.1. Ajuste por Subregistro: Anclaje con Datos de Seroprevalencia (ENSANUT) 18
  - 3.3.2. Inferencia de $S_0/N$ y la Falsación del Modelo de Inmunidad Permanente . 19
- 3.4. Estimación de $R_0$: Cuantificación de la Incertidumbre con Monte Carlo . . . 20

**4. Resultados y Validación del Modelo** 23
- 4.1. Estimación de la Transmisibilidad Intrínseca ($R_0$) . . . 23
  - 4.1.1. Valores Medios y la Co-evolución de la Transmisibilidad . . . 23
  - 4.1.2. Cuantificación de la Incertidumbre . . . 24

4.2. Validación Cuantitativa: Un Análisis Crítico de Errores . . . 25
4.3. Análisis Crítico de las Trayectorias en el Espacio de Fases . . . 26
4.3.1. Ola 1: La Firma Inequívoca de la Mitigación . . . 26
4.3.2. Ola 2: El Régimen de Máxima Concordancia . . . 27
4.3.3. Ola 3 (Delta): El Impacto del Comportamiento Adaptativo . . . 27
4.3.4. Ómicron y los Límites del Modelo . . . 28

**5. Discusión e Interpretación Física de la Dinámica Pandémica 31**
5.1. Dinámica del Parámetro de Control ($R_0$) y el Umbral Efectivo de Infección ($R_t(0)$) 31
5.2. Las Olas como Ciclos de Perturbación-Relajación: Una Analogía Física . . . 32
5.3. El Agotamiento de Susceptibles y la Dinámica S-I-R . . . 33
5.4. La Evolución de la Transmisibilidad Efectiva ($R_t$) . . . 36

**6. Aplicación: Simulación de un Sistema de Alerta Temprana Dinámico 39**
6.1. La Necesidad de un Sistema Proactivo: Indicadores Líderes vs. Rezagados . . . 39
6.2. Metodología del Sistema de Alerta Dinámico . . . 40
6.2.1. Calibración de Umbrales Adaptativos . . . 40
6.3. Resultados de la Simulación: Dashboards de Alerta por Ola . . . 40
6.4. Análisis Comparativo y Resumen Cuantitativo . . . 45
6.5. Implicaciones para la Salud Pública y Conclusión . . . 46
6.5.1. Hacia un Paradigma de Vigilancia Predictiva . . . 46
6.5.2. Conclusión: Un Llamado a la Integración de la Física en la Salud Pública 47

**7. Conclusiones 48**
7.1. Síntesis de Hallazgos Fundamentales . . . 48
7.2. Contribución al Campo e Implicaciones . . . 49
7.2.1. Contribución a la Física Aplicada: El Modelo como Laboratorio Teórico . 49
7.2.2. Implicaciones para la Salud Pública: Hacia una Vigilancia Predictiva . . . 49
7.3. Limitaciones y Agenda de Investigación Futura . . . 49
7.4. Reflexiones Finales: El Poder de los Modelos Simples . . . 50

# Capítulo 1

# Introducción a la Física de las Pandemias

## 1.1. La Pandemia como Objeto de Estudio de la Física

La pandemia de COVID-19 representa una de las disrupciones más significativas del siglo XXI. Con un saldo de más de siete millones de casos registrados y cientos de miles de muertes en México, su impacto trascendió la esfera de la salud pública para reconfigurar la totalidad del tejido social y económico. Ante un fenómeno de esta escala, la perspectiva de la física —disciplina dedicada a la modelización de sistemas complejos y al estudio del comportamiento colectivo— no es solo relevante, sino fundamental. El objetivo de esta tesis es aplicar el formalismo y el paradigma de la física de sistemas dinámicos para extraer una comprensión cuantitativa de la dinámica pandémica en México.

Se postula que la propagación de un agente infeccioso es un fenómeno emergente. Este es un concepto central en la física de la materia condensada y los sistemas complejos: propiedades macroscópicas, observables y a menudo contraintuitivas, surgen de las interacciones locales y simples de un gran número de componentes individuales. Al igual que las propiedades de un material, como la fase magnética o la temperatura, emergen de las interacciones de espín o las colisiones moleculares, la curva epidémica —el objeto macroscópico de estudio— emerge de millones de interacciones humanas discretas y estocásticas. Es imposible deducir la forma y escala de una ola pandémica estudiando a un solo individuo; esta solo existe como una propiedad del colectivo.

Un análisis riguroso de este sistema colectivo revela un conjunto de características definitorias que lo sitúan firmemente en el dominio de la física de sistemas complejos:

- **No Linealidad:** La dinámica epidémica es intrínsecamente no lineal. La tasa de cambio del número de infectados no es proporcional a su valor actual, sino que depende del producto entre la población infectada y la susceptible. Esta interdependencia establece bucles de realimentación positiva: cada nuevo infectado se convierte en una nueva fuente de

infección, conduciendo a la posibilidad de un crecimiento exponencial. Esta es la diferencia fundamental con los sistemas lineales, cuya respuesta es siempre proporcional al estímulo.

- **Sensibilidad a las Condiciones Iniciales:** Como en muchos sistemas no lineales, la trayectoria a largo plazo de la epidemia puede depender de forma crítica de sus estados iniciales. Pequeñas fluctuaciones en los eventos de transmisión tempranos —como la ocurrencia de un único evento de superpropagación— pueden ser amplificadas exponencialmente, llevando a dos poblaciones inicialmente idénticas a experimentar desenlaces pandémicos drásticamente diferentes.

- **Espacio de Fases:** Para analizar esta dinámica, es indispensable recurrir al concepto de espacio de fases, un espacio de estados cuyas coordenadas son las variables macroscópicas que definen el sistema en un instante dado (en nuestro caso, las fracciones poblacionales S, I y R). Cada epidemia traza una trayectoria única a través de este espacio. Una posición en la región de alta S y alta I representa un estado de alto riesgo, mientras que una trayectoria que se mueve hacia regiones de baja S y baja I representa una epidemia en agotamiento.

- **Adaptación:** El sistema es, además, adaptativo. Los agentes del sistema —las personas— observan el estado global (a través de los medios de comunicación, la percepción de riesgo, etc.) y ajustan su comportamiento. Esto crea un bucle de realimentación secundario y coevolutivo: el aumento de la percepción del riesgo modifica las pautas de contacto, lo que altera los parámetros de transmisión del modelo, lo que a su vez modifica la trayectoria de la epidemia, realimentando el ciclo.

## 1.2. El Modelo SIR como Aproximación de Campo Medio

La tarea de modelar explícitamente cada interacción en una población de millones de individuos resulta en una explosión combinatoria que es computacionalmente intratable. Ante este desafío, la física estadística ofrece un paradigma de simplificación de enorme poder y tradición: la aproximación de campo medio (*mean-field theory*). Originada en el estudio de transiciones de fase en sistemas físicos como el modelo de Weiss para el ferromagnetismo, esta aproximación reemplaza la compleja red de interacciones locales con un campo de influencia promedio y homogéneo que afecta a cada agente por igual.

El modelo Susceptible-Infectado-Recuperado (SIR) es la manifestación canónica de este enfoque en la epidemiología. Su postulado central, la mezcla homogénea, es análogo a asumir que un individuo susceptible no interactúa con su red social específica, sino que está inmerso en un "campo de infección" promedio, cuya intensidad es proporcional a la densidad global de infectados.

La elección de un modelo tan simple no es una omisión de la complejidad inherente al problema, sino una estrategia científica deliberada. Se postula el modelo SIR como un modelo

nulo o de orden cero, cuyo propósito es establecer una línea base para cuantificar qué fracción de la dinámica observada puede ser explicada únicamente por los mecanismos más fundamentales de transmisión y recuperación. Las desviaciones sistemáticas entre las predicciones de este modelo nulo y los datos empíricos no son, por tanto, un fracaso del modelo. Por el contrario, constituyen la señal experimental que nos permite medir cuantitativamente el impacto de la "física faltante": fenómenos de orden superior como la estructura de la red de contactos, la heterogeneidad espacial o el comportamiento adaptativo, cuya importancia solo puede ser evaluada en contraste con una línea base bien definida.

## 1.3. Hipótesis, Pregunta de Investigación y Objetivos

El presente trabajo de investigación se articula en torno a una hipótesis central, una pregunta de investigación derivada y un conjunto de objetivos específicos diseñados para abordarla sistemáticamente.

**Hipótesis Central**

Se postula que la evolución de la pandemia de COVID-19 en México, manifestada como una secuencia de cinco olas epidemiológicas, es isomorfa a una serie de ciclos de perturbación-relajación en un sistema dinámico no lineal. Cada ciclo es iniciado por una perturbación —exógena, como la emergencia de una nueva variante viral, o endógena, como una campaña de vacunación— que altera los parámetros de control ($R_0$) y las condiciones iniciales ($S_0/N$) del sistema. La ola epidémica subsecuente representa la trayectoria de relajación del sistema hacia un nuevo estado de equilibrio.

**Pregunta de Investigación**

En el marco de esta hipótesis, la presente investigación aborda la siguiente pregunta central: ¿Cuál es el dominio de validez y cuáles son las limitaciones cuantitativas del modelo SIR, como aproximación de campo medio, para describir las trayectorias empíricas de las cinco olas pandémicas en México? ¿Qué revela la calibración de este modelo sobre la evolución de los parámetros de control del virus y el impacto de la inmunidad poblacional?

**Objetivos Específicos**

Para responder a esta interrogante, se establecen los siguientes objetivos:

- **Reconstruir las trayectorias empíricas.**

  *Propósito:* Traducir los datos brutos de salud pública al lenguaje del espacio de fases de la física, corrigiendo sesgos observacionales como el subregistro.

- **Cuantificar los parámetros de control del sistema.**

  *Propósito:* Asignar valores numéricos y distribuciones de incertidumbre a las variables clave del modelo ($R_0$, $S_0/N$, etc.) para cada ola, fundamentando el análisis en evidencia estadística robusta.

- **Validar cuantitativamente el modelo canónico SIR.**

  *Propósito:* Confrontar rigurosamente la teoría con la realidad, utilizando métricas de error para medir la bondad de ajuste y, más importante, las desviaciones sistemáticas.

- **Interpretar la transición epidémica en el marco de la teoría de bifurcaciones.**

  *Propósito:* Conectar los resultados empíricos con la teoría fundamental de la estabilidad de sistemas dinámicos, formalizando el inicio de una ola como una bifurcación transcrítica.

## 1.4. Estructura de la Tesis

El presente documento se articula en la siguiente estructura para guiar al lector desde los fundamentos teóricos hasta la interpretación de los resultados:

- **Capítulo 2: Marco Teórico.** Se expone el andamiaje teórico, derivando el modelo SIR como un sistema dinámico y analizando formalmente su espacio de fases, puntos fijos, estabilidad y la naturaleza de la transición epidémica.
- **Capítulo 3: Datos y Metodología.** Se describe en detalle el protocolo metodológico y computacional, desde la adquisición y preprocesamiento de los datos hasta la estimación final de los parámetros del modelo.
- **Capítulo 4: Resultados y Validación del Modelo.** Se presentan los resultados cuantitativos del análisis, notablemente las estimaciones de $R_0$ para cada ola. Es aquí donde se confronta la elegante simplicidad del modelo con la ruidosa complejidad de los datos reales.
- **Capítulo 5: Discusión e Interpretación Física.** Se desarrolla una discusión e interpretación de los resultados a la luz de la física, enmarcando las olas como los ciclos de perturbación-relajación propuestos en la hipótesis.
- **Capítulo 6: Aplicación a un Sistema de Alerta Temprana.** Se explora una aplicación directa del formalismo desarrollado, simulando un sistema de alerta basado en la dinámica del sistema (sus "velocidades" y "aceleraciones") en lugar de indicadores estáticos.
- **Capítulo 7: Conclusiones.** Finalmente, se sintetizan las conclusiones fundamentales del estudio, se discuten sus implicaciones para la física y la salud pública, se reconocen sus limitaciones y se proponen líneas de investigación futura.

# Capítulo 2

# Marco Teórico - La Epidemiología como un Sistema Dinámico

Este capítulo establece el andamiaje teórico fundamental de la tesis. Su objetivo es diseccionar el modelo Susceptible-Infectado-Recuperado (SIR) no como una simple receta epidemiológica, sino como un sistema dinámico canónico que emerge de principios físicos fundamentales. Se realizará un análisis exhaustivo de su estructura matemática, su campo vectorial, sus puntos de equilibrio y su estabilidad. Finalmente, se caracterizará la transición crítica que da origen a una epidemia como una bifurcación, estableciendo una analogía formal con las transiciones de fase en la física estadística.

## 2.1. El Modelo SIR: Postulados, Derivación y Formalismo

El modelo SIR, propuesto en el trabajo seminal de Kermack y McKendrick en 1927, representa un hito en la modelización matemática de fenómenos colectivos.[1] Su elegancia y poder predictivo residen en su capacidad para capturar una dinámica compleja a partir de un conjunto mínimo de postulados. Es un modelo compartimental que idealiza a una población total $N$, asumida cerrada y constante en la escala de tiempo de una epidemia, dividiéndola en tres clases o compartimentos mutuamente excluyentes y exhaustivos:

- **Susceptibles (S):** El conjunto de individuos que no poseen inmunidad al agente patógeno y, por tanto, son vulnerables a la infección tras un contacto efectivo.
- **Infectados (I):** El conjunto de individuos que han sido invadidos por el patógeno, son biológicamente capaces de transmitirlo a los susceptibles y aún no han desarrollado una respuesta inmune que elimine la infección.
- **Recuperados (R):** El conjunto de individuos que han transitado por la fase infecciosa y, en el formalismo canónico del modelo, adquieren inmunidad permanente. Este compartimento también absorbe a los individuos que fallecen a causa de la enfermedad, ya que

en ambos casos son removidos del proceso de transmisión.

La dinámica del sistema describe el flujo de individuos entre estos compartimentos, un proceso que se puede visualizar esquemáticamente como una reacción en cadena.

**Figura 2.1: Diagrama de Flujo del Modelo de Compartimentos SIR**

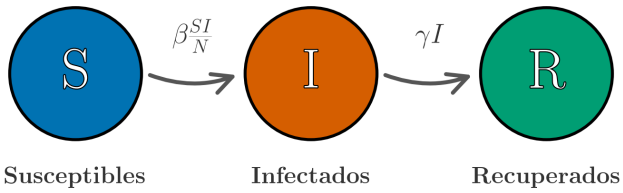


Figura 2.1: Diagrama de flujo del modelo compartimental SIR. Este esquema visualiza los compartimentos como estados y las flechas como los flujos de transición entre ellos. Los individuos fluyen de S a I a una tasa $\beta SI/N$ y de I a R a una tasa $\gamma I$.

### 2.1.1. Derivación de las Ecuaciones de Movimiento

Las ecuaciones diferenciales que gobiernan este flujo, o "ecuaciones de movimiento" del sistema, pueden ser derivadas a partir de argumentos de primeros principios análogos a la ley de acción de masas en cinética química ($S + I \to I + I$) o a la teoría de colisiones en gases.

**Término de Interacción (Infección):** El evento de infección es un proceso de segundo orden que requiere la interacción entre un agente del compartimento S y un agente del compartimento I. Bajo la aproximación de campo medio, que postula una mezcla homogénea de la población, la probabilidad de que un encuentro aleatorio entre dos individuos sea de tipo S-I es proporcional al producto de sus densidades poblacionales, $(S/N) \cdot (I/N)$. Si cada individuo tiene una tasa de contacto promedio $c$, el número total de encuentros S-I por unidad de tiempo es proporcional a $c \cdot N \cdot (SI/N^2) = cSI/N$. Sea $p$ la probabilidad de transmisión dado un contacto. La tasa de nuevas infecciones (el flujo de S a I) es entonces $(c \cdot p)\frac{SI}{N}$. Para simplificar, agrupamos los parámetros microscópicos en una única tasa de transmisión efectiva, $\beta = c \cdot p$ [unidades de tiempo$^{-1}$]. Este parámetro macroscópico engloba tanto la frecuencia de contactos sociales como la infectividad intrínseca del patógeno. Así, la tasa de cambio debida a la infección es $\frac{\beta SI}{N}$.

**Término de Remoción (Recuperación):** El flujo de I a R es un proceso de primer orden. Se asume que es un proceso de Poisson, donde cada individuo infectado tiene una probabilidad constante e independiente $\gamma dt$ de recuperarse en un intervalo de tiempo infinitesimal $dt$. Esto implica que la duración del periodo infeccioso sigue una distribución exponencial con una media de $D = 1/\gamma$. Para la población total de $I$ infectados, la tasa total de flujo de I a R es, por tanto, $\gamma I$.

Estas derivaciones conducen directamente al sistema de Ecuaciones Diferenciales Ordinarias (EDOs) no lineales que constituye el modelo SIR:

$$\frac{dS}{dt} = -\frac{\beta SI}{N} \tag{2.1}$$

$$\frac{dI}{dt} = \frac{\beta SI}{N} - \gamma I \tag{2.2}$$

$$\frac{dR}{dt} = \gamma I \tag{2.3}$$

## 2.2. Estructura Geométrica de la Dinámica Epidémica

### 2.2.1. Espacio de Fases y la Constante de Movimiento

El sistema (2.1)-(2.3) opera en un espacio de estados tridimensional. Sin embargo, una inspección de las ecuaciones revela que $\frac{d}{dt}(S+I+R) = 0$. Esto implica la existencia de una constante de movimiento: la población total, $S(t)+I(t)+R(t) = N$, se conserva. En la mecánica clásica, las cantidades conservadas como la energía o el momento restringen las trayectorias de un sistema a una subvariedad del espacio de estados. Análogamente, aquí la dinámica epidémica está confinada al plano estequiométrico definido por esta ley de conservación. Esta propiedad fundamental nos permite reducir la dimensionalidad del sistema, describiendo su estado completamente con solo dos variables, S e I, ya que R queda unívocamente determinado.

La dinámica se analiza, por tanto, en el espacio de fases S-I. Este plano es el escenario geométrico donde se desarrolla la historia de la epidemia. Cada punto en este plano es un estado, y cada epidemia es una trayectoria. Las ecuaciones definen un campo vectorial $F(S, I) = (\dot{S}, \dot{I})$ que actúa como la "ley de movimiento" del sistema, dictando en cada punto la velocidad y dirección instantánea de la evolución.

### 2.2.2. Nuclinas y Estructura del Flujo

Para comprender la topología de este campo vectorial, es indispensable identificar sus nuclinas: las curvas donde el movimiento es puramente horizontal o vertical.

- **Nuclinas-S ($\dot{S} = 0$):** Ocurren cuando $-\frac{\beta SI}{N} = 0$, cuyas soluciones son $S = 0$ (el eje I) y $I = 0$ (el eje S).
- **Nuclinas-I ($\dot{I} = 0$):** Ocurren cuando $I(\frac{\beta S}{N} - \gamma) = 0$, cuyas soluciones son $I = 0$ (el eje S) y la línea vertical $S = \frac{\gamma N}{\beta}$.

Los puntos de equilibrio del sistema son las intersecciones de estas nuclinas. Su visualización conjunta permite entender la estructura global del flujo en el espacio de fases.

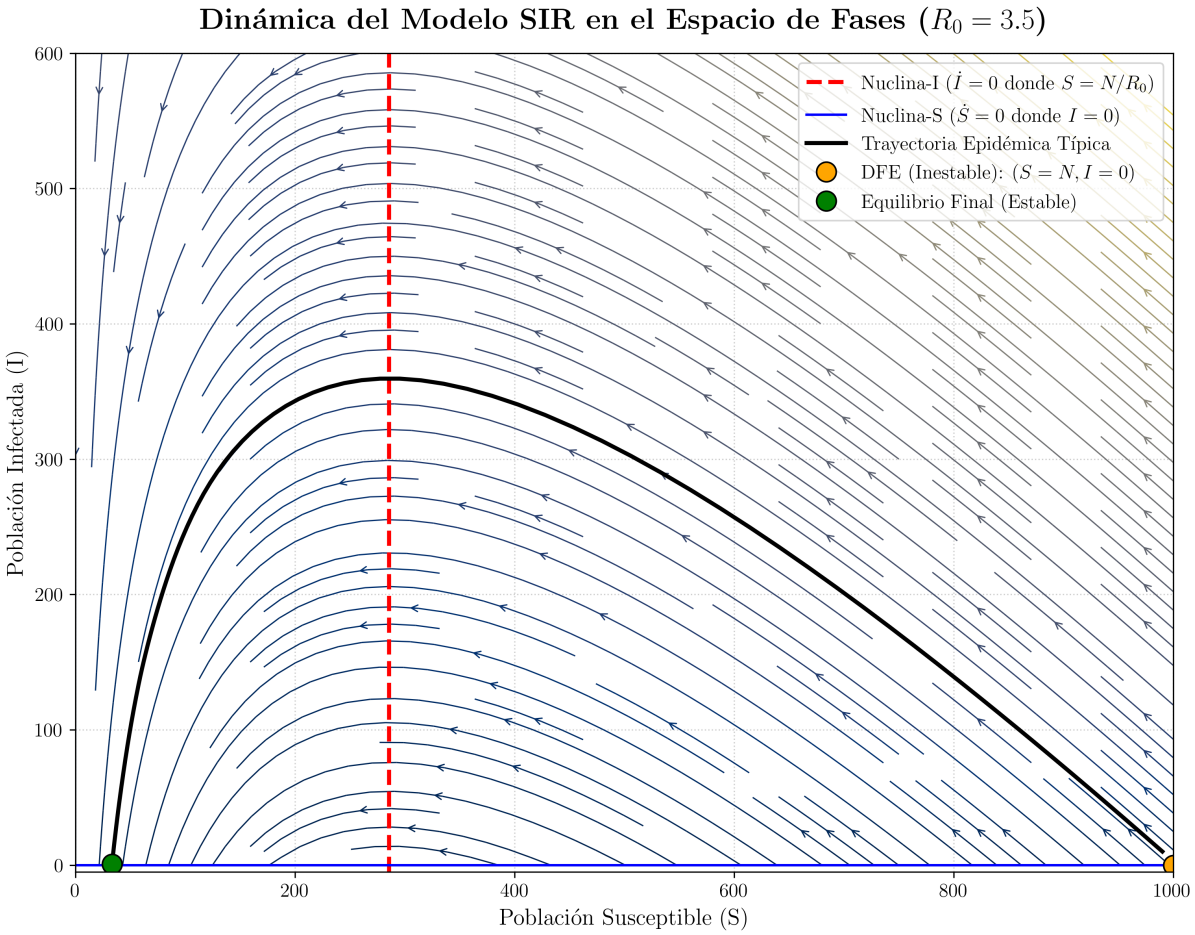


Figura 2.2: Diagrama del campo vectorial en el espacio de fases S-I. La figura debe mostrar las flechas del campo vectorial, las S-nuclinas (ejes S e I, en azul), la I-nuclina (eje S y la línea vertical $S = N/R_0$, en rojo), y los dos puntos de equilibrio (DFE y EE) como puntos sólidos.

## 2.3. Puntos de Equilibrio y Análisis de Estabilidad Lineal

Los puntos fijos ($\dot{S} = 0, \dot{I} = 0$) representan los estados estacionarios del sistema.

- **Equilibrios Libres de Enfermedad (DFE):** La nuclina $I = 0$ es común a ambas derivadas, por lo que cualquier punto de la forma $(S^*, 0)$ es un punto de equilibrio. El punto físicamente relevante antes de una epidemia es $(N, 0)$.
- **Equilibrio Endémico (EE):** Este equilibrio ocurre cuando $I \neq 0$. Requiere la intersección de las nuclinas no triviales, $S = \frac{\gamma N}{\beta}$. Este punto solo tiene existencia física si $S^* < N$, lo que implica $\frac{\gamma}{\beta} < 1$, o $R_0 > 1$.

### 2.3.1. Estabilidad del Equilibrio Libre de Enfermedad (DFE)

Para determinar si una epidemia puede iniciarse, analizamos la estabilidad del DFE en $(N, 0)$. El método es la linealización del sistema, gobernada por la matriz Jacobiana $J(S, I)$:

$$J(S,I) = \begin{pmatrix} \frac{\partial \dot{S}}{\partial S} & \frac{\partial \dot{S}}{\partial I} \\ \frac{\partial \dot{I}}{\partial S} & \frac{\partial \dot{I}}{\partial I} \end{pmatrix} = \begin{pmatrix} -\frac{\beta I}{N} & -\frac{\beta S}{N} \\ \frac{\beta I}{N} & \frac{\beta S}{N} - \gamma \end{pmatrix} \tag{2.1}$$

Evaluando en el punto de equilibrio de interés, $(S = N, I = 0)$:

$$J(N,0) = \begin{pmatrix} 0 & -\beta \\ 0 & \beta - \gamma \end{pmatrix} \tag{2.2}$$

Los autovalores $(\lambda)$ de esta matriz triangular son los elementos de la diagonal:

$$\lambda_1 = 0$$
$$\lambda_2 = \beta - \gamma$$

El autovalor $\lambda_1 = 0$ corresponde a la estabilidad neutra a lo largo del eje S. El autovalor $\lambda_2 = \beta - \gamma$ gobierna la estabilidad en la dirección del eje I. La condición para el crecimiento epidémico es $\lambda_2 > 0$, lo que nos lleva directamente al umbral epidémico $\beta > \gamma$. Reescribiendo esto con el **Número Reproductivo Básico**, $R_0 \equiv \frac{\beta}{\gamma}$, la condición para que una epidemia ocurra es $R_0 > 1$.

### 2.3.2. Estabilidad del Equilibrio Endémico (EE)

Un análisis similar para el punto de equilibrio endémico revela que sus autovalores siempre tienen parte real negativa cuando este existe $(R_0 > 1)$. Por lo tanto, el estado endémico, cuando existe, es siempre localmente estable.

## 2.4. La Transición Epidémica como una Bifurcación

El cambio cualitativo en la estructura topológica del espacio de fases que ocurre en el punto crítico $R_0 = 1$ se conoce formalmente como una bifurcación transcrítica. En este evento, dos ramas de equilibrios (la libre de enfermedad y la endémica) se cruzan y, al hacerlo, intercambian su estabilidad.

Este fenómeno es matemáticamente análogo a una transición de fase de segundo orden en la física estadística.

- El **parámetro de control** del sistema es $R_0$.
- El **parámetro de orden** del sistema es la fracción de infectados en el estado estacionario, $I^*$.
- El **punto crítico** es $R_0 = 1$. Para $R_0 < 1$, el parámetro de orden es cero $(I^* = 0)$,

correspondiente a una fase no epidémica. Para $R_0 > 1$, el parámetro de orden se vuelve no nulo ($I^* > 0$), y el sistema entra en una fase endémica.

**Figura 2.2: Análisis de Estabilidad y Bifurcación del Modelo SIR**

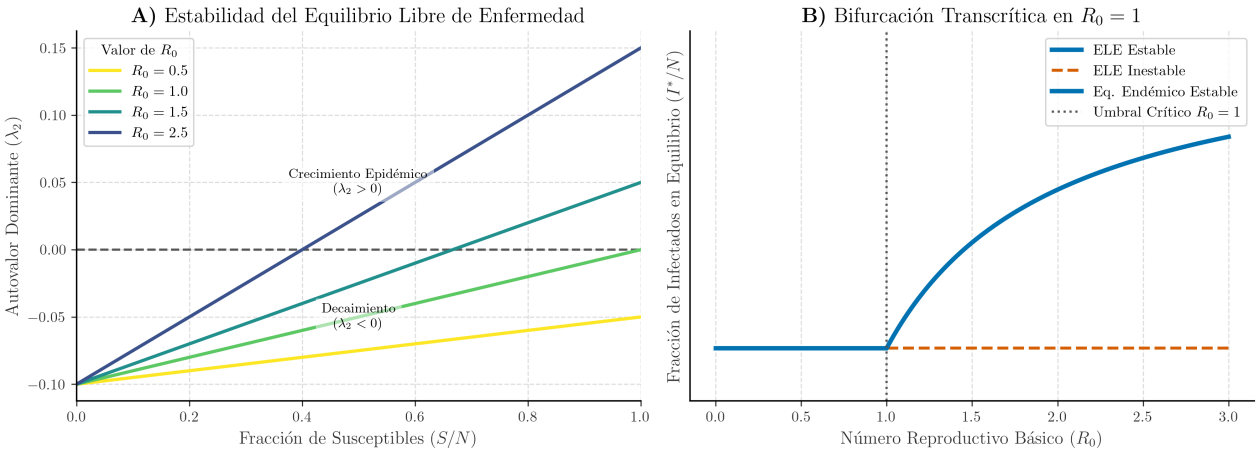


Figura 2.3: Análisis de estabilidad y bifurcación del modelo SIR. (A) El autovalor dominante, $\lambda_2$, que determina la estabilidad, se vuelve positivo cuando $S/N > 1/R_0$. (B) Diagrama de bifurcación transcrítica. Muestra la fracción de infectados en equilibrio ($I^*/N$) en función del parámetro de control $R_0$. Las líneas continuas representan equilibrios estables y las discontinuas, inestables. Se observa el intercambio de estabilidad en el punto crítico $R_0 = 1$.

## 2.5. Limitaciones del Modelo Canónico y Extensiones Requeridas

El formalismo SIR se fundamenta en un conjunto de suposiciones que deben ser reconocidas:

- **Inmunidad Permanente:** El flujo unidireccional $I \to R$ no permite reinfecciones. La emergencia de variantes con evasión inmune viola este postulado.
- **Parámetros Constantes:** Se asume que $\beta$ y $\gamma$ son constantes. Sin embargo, $\beta$ depende del comportamiento social y $\gamma$ puede cambiar con nuevas variantes.
- **Periodo de Latencia:** No se incluye un periodo donde un individuo está infectado pero aún no es infeccioso (modelo SEIR).
- **Mezcla Homogénea:** Es la simplificación más profunda. Los modelos basados en redes complejas relajan esta suposición.

# Capítulo 3

# Datos, Metodología y Calibración del Modelo

Este capítulo presenta el protocolo computacional y estadístico integral diseñado para calibrar el modelo SIR teórico con los datos empíricos de la pandemia de COVID-19 en México. El objetivo es transformar la serie de tiempo cruda de la vigilancia epidemiológica en un conjunto de parámetros y condiciones iniciales robustos y físicamente significativos para el sistema dinámico. Cada paso del pipeline de análisis, desde la adquisición de los datos hasta la estimación final de los parámetros, se presenta como un procedimiento científico formal, con una justificación explícita para cada elección metodológica.

## 3.1. Adquisición y Preprocesamiento de Datos: Aislamiento de la Señal Epidemiológica

El fundamento empírico de este estudio reside en la serie de tiempo de casos diarios confirmados a nivel nacional, obtenida de los datos abiertos de la Dirección General de Epidemiología (DGE). Estos datos, basados en el Sistema de Vigilancia Epidemiológica de Enfermedades Respiratorias Virales (SISVER), constituyen el registro oficial. Desde la perspectiva del procesamiento de señales, esta serie de tiempo $I_{\text{crudo}}(t)$ puede modelarse como la superposición de tres componentes: la señal epidemiológica de baja frecuencia que representa la ola pandémica, $I_{\text{tendencia}}(t)$; una componente estacional de alta frecuencia, $I_{\text{semanal}}(t)$; y un ruido estocástico, $n(t)$. El primer objetivo metodológico es aislar $I_{\text{tendencia}}(t)$.

Para eliminar el artefacto periódico de 7 días, se aplicó un filtro de media móvil centrada de 7 días. La ecuación de este filtro de convolución es:

$$I_{\text{suavizado}}(t) = \frac{1}{7} \sum_{j=-3}^{3} I_{\text{crudo}}(t+j) \tag{3.1}$$

Este filtro paso-bajas fue seleccionado sobre alternativas más complejas (ej. Savitzky-Golay) por su robustez e interpretabilidad. La ventana de 7 días corresponde directamente a la frecuencia

del ruido a eliminar, y su naturaleza centrada previene la introducción de desplazamientos de fase (retrasos) en la señal. Crucialmente, a diferencia de otros filtros que pueden distorsionar la amplitud, la media móvil preserva la magnitud de los picos, una característica esencial para la calibración del modelo.

## 3.2. Definición Operacional de Olas: Un Criterio Topológico Objetivo

Una "ola" pandémica no es un objeto con una definición formal, sino una construcción científica que debe ser definida de manera objetiva. Para segmentar la serie temporal en eventos discretos, se empleó un criterio algorítmico basado en la topología de la curva, utilizando la función `find_peaks` de SciPy sobre la serie de tiempo invertida ($-I_{\text{suavizado}}(t)$) para identificar los valles de mínima transmisión.

La robustez de este método depende de la calibración de sus hiperparámetros, principalmente la prominencia (`prominence`). La prominencia es una medida de la significancia topológica de un valle. La elección de este parámetro es un problema de selección de escala. Tras un análisis de sensibilidad, se seleccionó un valor de `prominence=2500`. Este umbral fue elegido deliberadamente para identificar las cinco grandes fases macroscópicas de la pandemia, cada una asociada a la dominancia de diferentes linajes virales, y para tratar el complejo evento invernal de 2020-2021 como una única "super-ola", una escala coherente con la granularidad del modelo SIR.

**Figura 3.1: Análisis de Sensibilidad para la Definición de Olas**

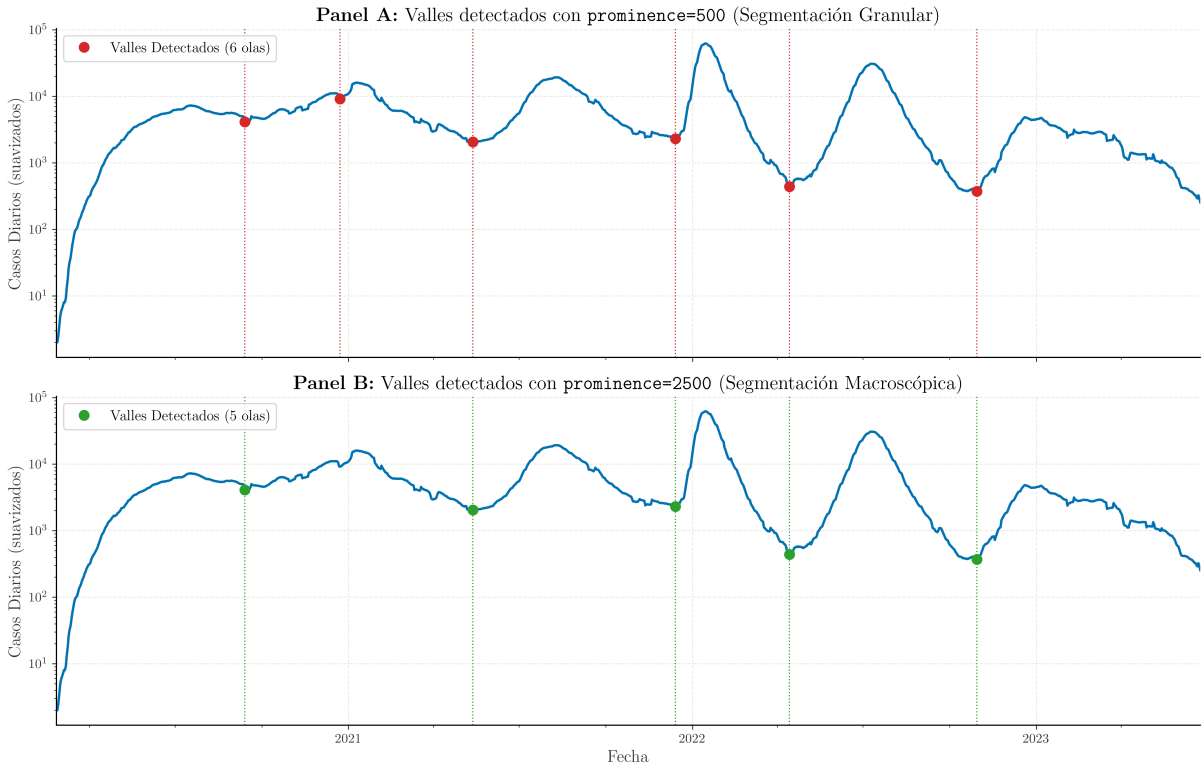


Figura 3.1: Análisis de sensibilidad para la definición de olas. El panel (A) muestra los valles detectados con `prominence=500`, resultando en una segmentación más granular. El panel (B) muestra los valles detectados con `prominence=2500`, resultando en las 5 olas macroscópicas utilizadas en este estudio.

La aplicación de este algoritmo a la serie temporal de México da como resultado la segmentación en cinco eventos discretos, que constituyen las unidades de análisis para el resto de este trabajo. La Figura 3.2 visualiza estas cinco olas.

Figura 3.1: Dinámica y Hitos de la Pandemia de COVID-19 en México (5 Olas)

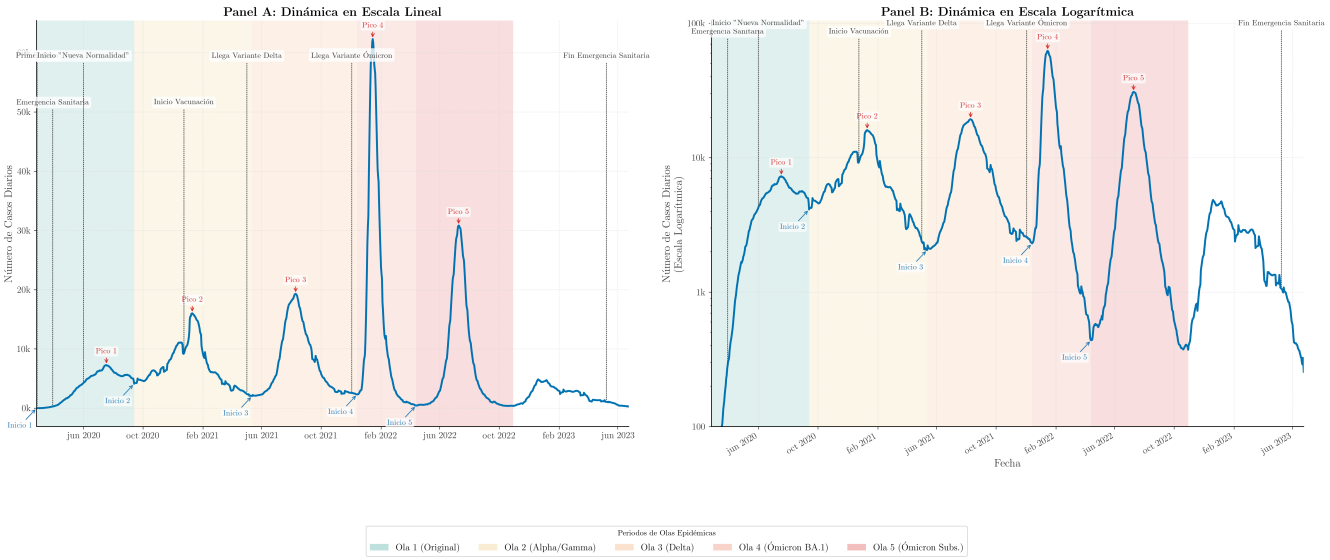


Figura 3.2: Dinámica de la pandemia de COVID-19 en México y segmentación en cinco olas. Los paneles muestran la serie temporal de casos diarios confirmados (suavizados) en escala lineal (A) y logarítmica (B). Las áreas sombreadas delimitan las cinco grandes olas identificadas.

## 3.3. Parametrización del Modelo

### 3.3.1. Ajuste por Subregistro: Anclaje con Datos de Seroprevalencia (ENSANUT)

Un análisis basado únicamente en los casos confirmados oficiales carecería de validez física. Para anclar el modelo a la realidad epidemiológica, es indispensable corregir este subregistro. Esta corrección se realizó utilizando como "verdad terreno" (*ground truth*) los datos de seroprevalencia de las Encuestas Nacionales de Salud y Nutrición (ENSANUT) de 2020, 2021 y 2022.[2]

Se calculó una **Fracción de Detección (FD)**, definida formalmente como:

$$\text{FD} = \frac{\text{Casos Acumulados Reportados}}{\text{Población Total} \times \text{Seroprevalencia}} \tag{3.2}$$

Dada la disponibilidad de tres encuestas para cinco olas, se adoptó una aproximación por tramos constantes. La Figura 3.3 ilustra el impacto de esta corrección.

Figura 3.2: Comparativa de Casos Reportados vs. Infecciones Estimadas por Subregistro

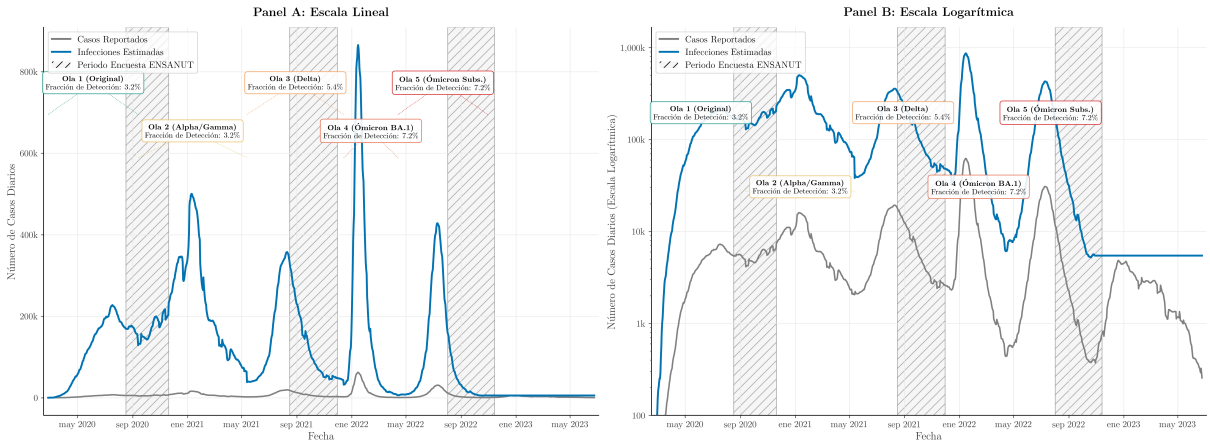


Figura 3.3: Comparativa de casos reportados vs. infecciones estimadas. La línea gris muestra los casos oficiales suavizados. La línea azul muestra la estimación de infecciones reales diarias, obtenida al aplicar la Fracción de Detección. La diferencia revela la magnitud del subregistro.

### 3.3.2. Inferencia de $S_0/N$ y la Falsación del Modelo de Inmunidad Permanente

El cálculo de la fracción de susceptibles al inicio de cada ola ($S_0/N$) es una condición inicial crucial. Un modelo inicial de agotamiento simple ($S_{0,i+1}/N = S_{0,i}/N - I_{\text{reales},i}/N$), que asume inmunidad permanente, arrojó un resultado físicamente imposible ($S/N < 0$) al proyectar el inicio de la Ola 5. Este resultado fue una demostración empírica de que el supuesto de inmunidad permanente había sido violado por la biología de la variante Ómicron.

Para capturar este fenómeno, se introdujo el parámetro $\epsilon$, la fracción de la población recuperada que vuelve a ser susceptible. Su valor fue inferido de los datos mediante un algoritmo de optimización. Se definió una función de costo, $C(\epsilon) = \text{RMSE}(\text{datos}, \text{SIR}(R_0, S_0(\epsilon), D))$, y se buscó el valor $\epsilon^* = \arg\min_{\epsilon \in [0,1]} C(\epsilon)$ a través de una búsqueda en malla (*grid search*). La Figura 3.4 muestra el resultado de esta optimización.

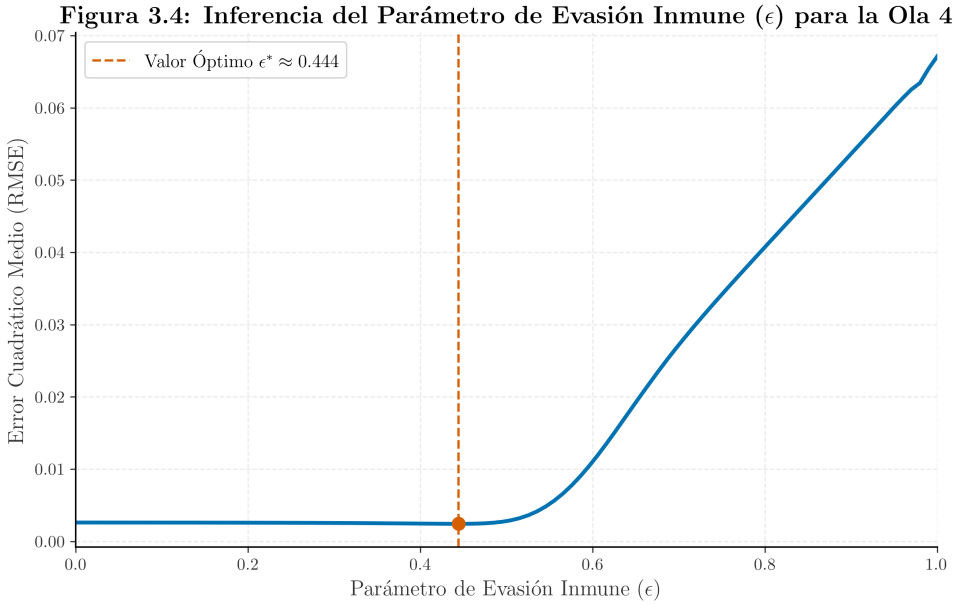


Figura 3.4: Inferencia del parámetro de evasión inmune ($\epsilon$) para la Ola 4. La gráfica muestra el Error Cuadrático Medio (RMSE) entre el modelo y los datos para diferentes valores de $\epsilon$. El mínimo bien definido de la curva justifica la selección del valor óptimo.

## 3.4. Estimación de $R_0$: Cuantificación de la Incertidumbre con Monte Carlo

Para obtener una estimación rigurosa de $R_0$, se empleó una Simulación de Monte Carlo (MCS) con 100,000 iteraciones por ola.[3] Este enfoque permite propagar las incertidumbres de los parámetros de entrada para obtener una distribución de probabilidad completa para el resultado.

**Distribuciones de Incertidumbre:** A cada parámetro de entrada incierto $(D, \mathrm{FD}, S_0/N)$ se le asignó una distribución triangular con un rango de $\pm 20\,\%$.

**Protocolo Computacional:** La estimación se basa en la relación para la fase de crecimiento exponencial, donde $dI/dt \approx rI$, y $r = \gamma(R_0 S_0/N - 1)$.[4] Se implementó un algoritmo para encontrar la ventana de 21 días al inicio de la ola que maximizaba el coeficiente de determinación ($R^2$) de una regresión log-lineal, como se ejemplifica en la Figura 3.5.

**Figura 3.5: Estimación de la Tasa de Crecimiento ($r$) para la Ola 3 (Delta)**

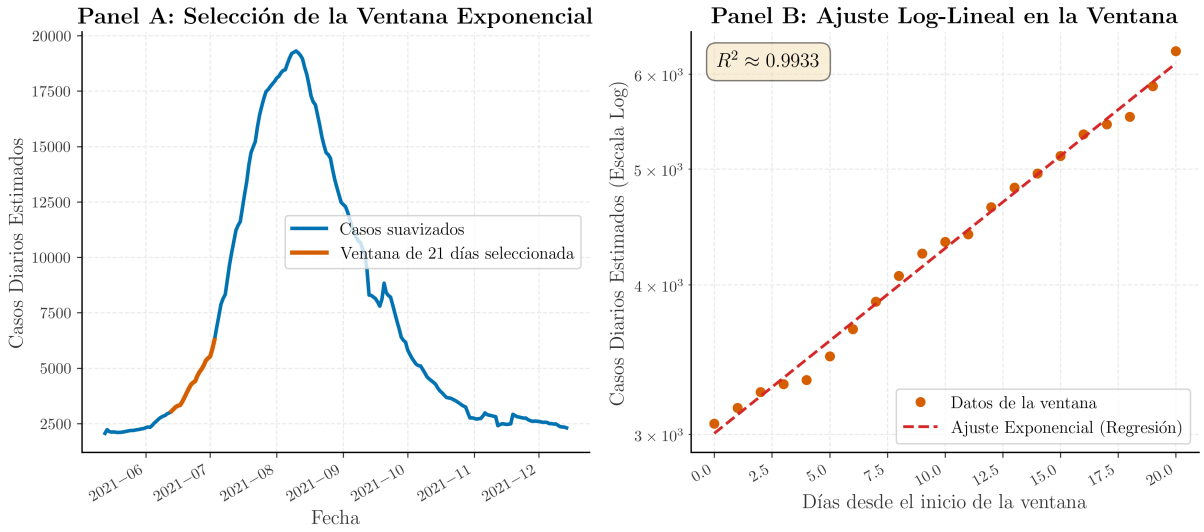


Figura 3.5: Ejemplo de la estimación de la tasa de crecimiento ($r$) para la Ola 3. (A) Serie de tiempo con la ventana de 21 días seleccionada. (B) Los mismos datos en escala logarítmica con la línea de regresión, mostrando un ajuste casi perfecto ($R^2 > 0{,}99$).

La repetición de este proceso 100,000 veces genera una distribución de probabilidad para $R_0$. Todo el pipeline metodológico se resume en la Figura 3.6.

**Figura 3.6: Diagrama de Flujo del Pipeline Metodológico Completo**

Figura 3.6: Diagrama de flujo del pipeline metodológico completo. Este diagrama resume visualmente el proceso secuencial de análisis, desde la entrada de datos (DGE, ENSANUT), a través de los módulos de preprocesamiento, calibración y simulación, hasta la salida final.

# Capítulo 4

# Resultados y Validación del Modelo

Este capítulo constituye el núcleo empírico y analítico de la tesis. Es en esta sección donde el formalismo teórico del modelo SIR, desarrollado en el Capítulo 2, se confronta rigurosamente con las trayectorias empíricas de la pandemia, reconstruidas mediante la metodología del Capítulo 3. El objetivo de este capítulo es doble. Primero, se presentan los resultados cuantitativos de los parámetros de control que gobiernan el sistema dinámico, específicamente el número reproductivo básico ($R_0$), para cada una de las cinco olas identificadas. Segundo, se realiza una validación crítica del modelo, utilizando este no como un mero instrumento de ajuste de curvas, sino como una sonda teórica. Las discrepancias sistemáticas entre el modelo y la realidad se tratarán no como fallos del análisis, sino como la principal fuente de conocimiento físico sobre la dinámica subyacente del sistema pandémico real.

## 4.1. Estimación de la Transmisibilidad Intrínseca ($R_0$)

### 4.1.1. Valores Medios y la Co-evolución de la Transmisibilidad

La aplicación del pipeline metodológico completo, culminando en la simulación de Monte Carlo, arrojó las estimaciones para el valor medio de $R_0$ y sus correspondientes intervalos de confianza del 95 %, presentados en la Figura 4.1.

**Figura 4.1: Estimación de $R_0$ con Intervalos de Confianza del 95%**

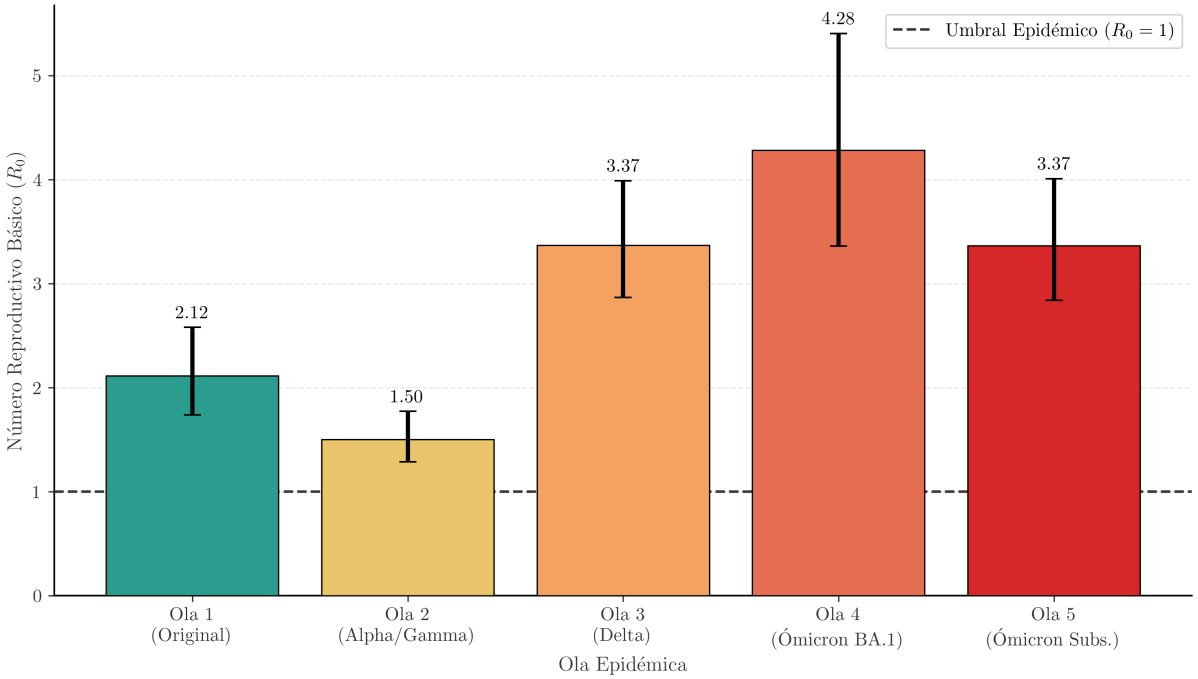


Figura 4.1: Estimación del Número Reproductivo Básico ($R_0$) medio para cada una de las cinco olas pandémicas. Las barras de error representan el intervalo de confianza del 95 % obtenido de la simulación de Monte Carlo. La línea punteada horizontal indica el umbral epidémico crítico ($R_0 = 1$).

La secuencia de valores de $R_0$ ($2.12 \rightarrow 1.50 \rightarrow 3.37 \rightarrow 4.28 \rightarrow 3.37$) es un registro cuantitativo de la carrera armamentista coevolutiva entre el SARS-CoV-2 y el sistema inmune de la población mexicana. Cada valor representa una realidad epidémica distinta, con un conjunto único de reglas. El descenso en la Ola 2 ($R_0 \approx 1{,}50$) es un resultado clave: refleja que, aunque las variantes Alpha/Gamma eran intrínsecamente más transmisibles que el linaje original, competían en una población donde el "combustible" de susceptibles ya había sido parcialmente consumido. El modelo, al ajustar la curva de crecimiento, infiere un $R_0$ efectivo para ese periodo que ya tiene en cuenta esta inmunidad preexistente.

La Ola 3 marca la irrupción de la variante Delta, cuya superioridad biológica se manifiesta en un $R_0$ que se duplica a $\approx 3{,}37$, superando la inmunidad existente. El salto más espectacular ocurre en la Ola 4, donde la variante Ómicron alcanza un extraordinario $R_0 \approx 4{,}28$. Este valor es notable no solo por su magnitud, sino por el contexto en el que se logra: una población con altísimos niveles de inmunidad híbrida. Esto cuantifica la inmensa ventaja evolutiva conferida por su capacidad de evasión inmune.

### 4.1.2. Cuantificación de la Incertidumbre

La simulación de Monte Carlo proporciona una distribución de probabilidad completa para $R_0$ en cada ola, como se visualiza en la Figura 4.2.

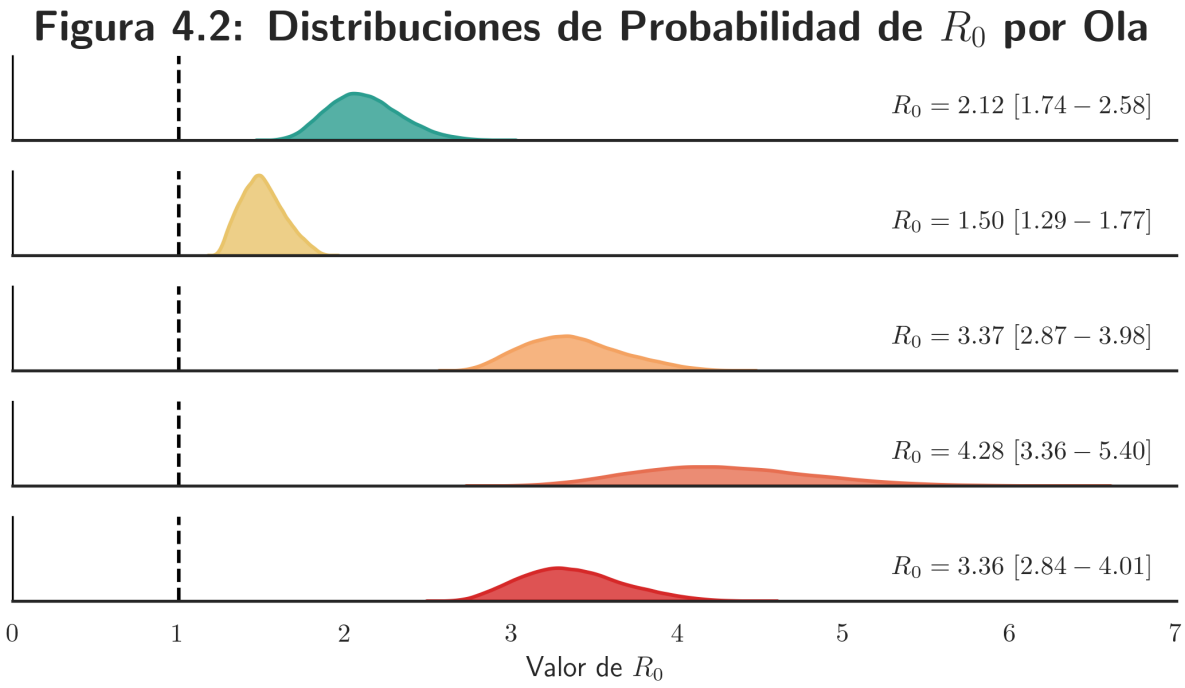


Figura 4.2: Distribuciones de densidad de probabilidad para el $R_0$ de cada una de las cinco olas. La anchura de cada distribución es una medida de la incertidumbre en la estimación.

La forma y anchura de cada distribución son informativas. La distribución para la Ola 4 (Ómicron) es notablemente ancha, lo que indica una mayor incertidumbre en la estimación. Este es un resultado directo de la propagación de errores: la estimación de $R_0$ para esta ola es particularmente sensible a la incertidumbre acumulada en la fracción de susceptibles ($S_0/N$) y, crucialmente, a la incertidumbre en el parámetro de evasión inmune ($\epsilon$). Esto implica que las predicciones para olas impulsadas por variantes con alta evasión inmune son intrínsecamente menos certeras. En contraste, la distribución más estrecha para la Ola 2 indica una estimación más robusta.

## 4.2. Validación Cuantitativa: Un Análisis Crítico de Errores

Para cuantificar la bondad de ajuste, se calcularon tres métricas de error clave para cada ola. Un Error de Pico Relativo positivo indica que el pico del modelo fue mayor al de los datos (sobreestimación), mientras que uno negativo indica que fue menor (subestimación).

Tabla 4.1: Métricas Cuantitativas de Ajuste del Modelo SIR.

| Ola | RMSE (%) | Error Pico Rel. (%) | Error Tamaño Abs. (% pob.) |
|---|---|---|---|
| Ola 1 | 4.54 | +1832.83 | +61.40 |
| Ola 2 | 0.29 | -15.11 | -9.50 |
| Ola 3 | 0.30 | +29.31 | -0.14 |
| Ola 4 | 3.39 | +594.10 | +32.46 |
| Ola 5 | 0.47 | +36.42 | -0.96 |

## 4.3. Análisis Crítico de las Trayectorias en el Espacio de Fases

### 4.3.1. Ola 1: La Firma Inequívoca de la Mitigación

La Figura 4.3 presenta la discrepancia más importante de este trabajo. El modelo predice una catástrofe: una ola masiva que consume casi toda la población susceptible. Los datos reales, en cambio, muestran una curva dramáticamente aplanada. Esta brecha, cuantificada por un error en el pico de +1832.83 %, no es un fallo del análisis, sino su principal hallazgo. El modelo SIR, con un $R_0$ constante, simula la dinámica natural y sin restricciones del virus. La trayectoria empírica representa la dinámica mitigada por las intervenciones no farmacéuticas masivas. La diferencia entre ambas curvas es la evidencia cuantitativa del éxito de estas políticas para "aplanar la curva".

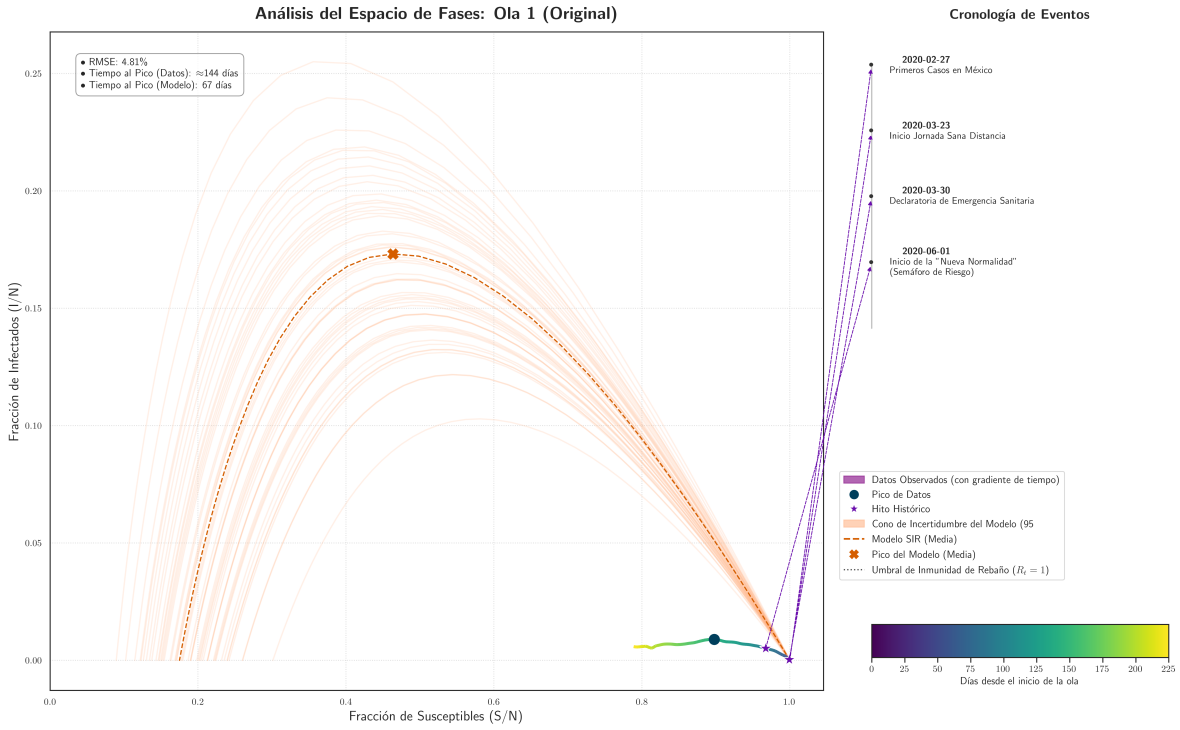


Figura 4.3: Validación del Modelo para la Ola 1 (Original).

### 4.3.2. Ola 2: El Régimen de Máxima Concordancia

La Ola 2 presenta el mejor ajuste global (RMSE de 0.29 %), lo que sugiere que su dinámica fue la más cercana a una epidemia "clásica" de tipo SIR. El error de pico, único con valor negativo (-15.11 %), es un resultado sutil pero importante: indica que el pico real fue ligeramente más alto que el predicho por el modelo. Esto puede ser una firma de fenómenos como eventos de superpropagación, no capturados por la homogeneidad del campo medio, que pueden generar picos más agudos que la dinámica promedio.

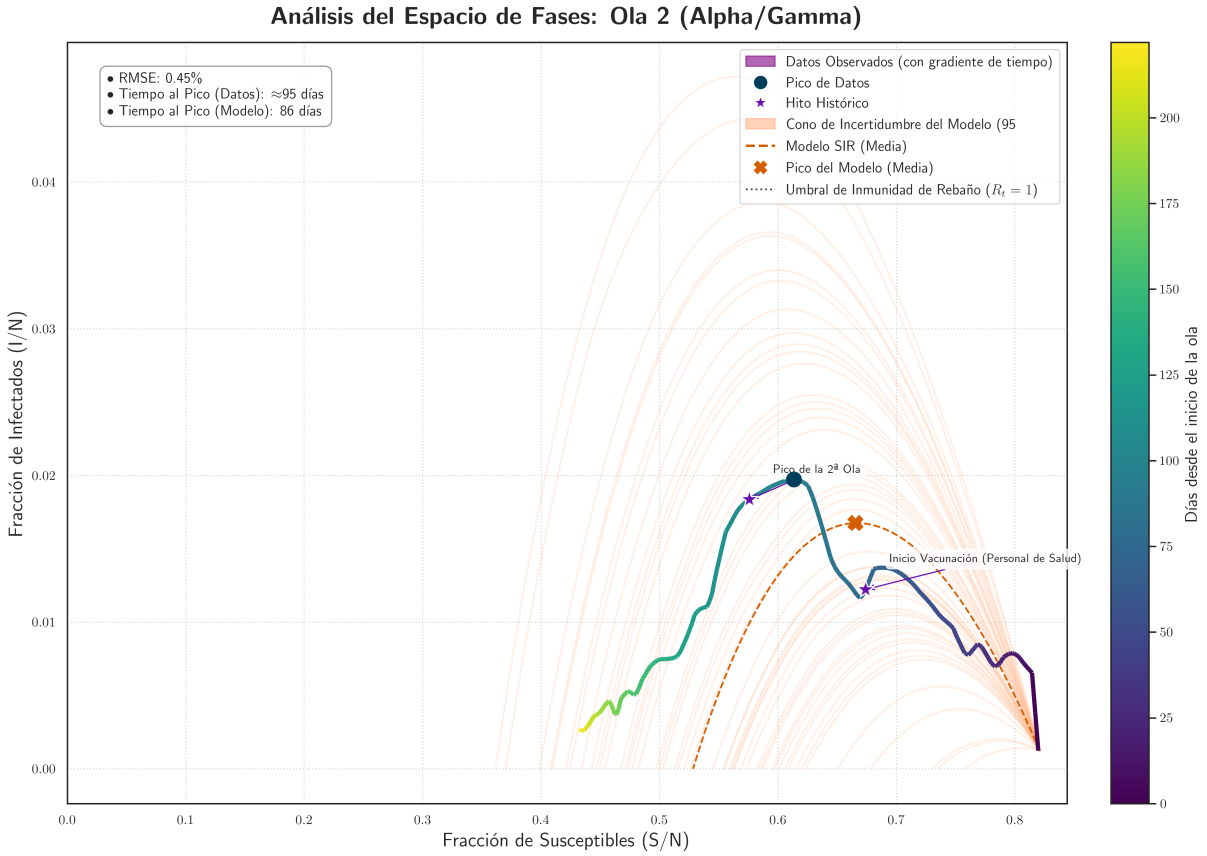


Figura 4.4: Validación del Modelo para la Ola 2 (Alpha/Gamma).

### 4.3.3. Ola 3 (Delta): El Impacto del Comportamiento Adaptativo

Este resultado es consistente con un efecto de comportamiento adaptativo. El modelo SIR asume un $R_0$ constante. Sin embargo, es plausible que, a medida que la ola de la variante Delta crecía, la población intensificara las medidas de precaución, disminuyendo el $\beta$ efectivo. Este comportamiento "frenó" la epidemia real, "rasurando" la cima del pico de una manera que un modelo con parámetros constantes no puede prever, llevando a la sobreestimación del pico (+29.31 %).

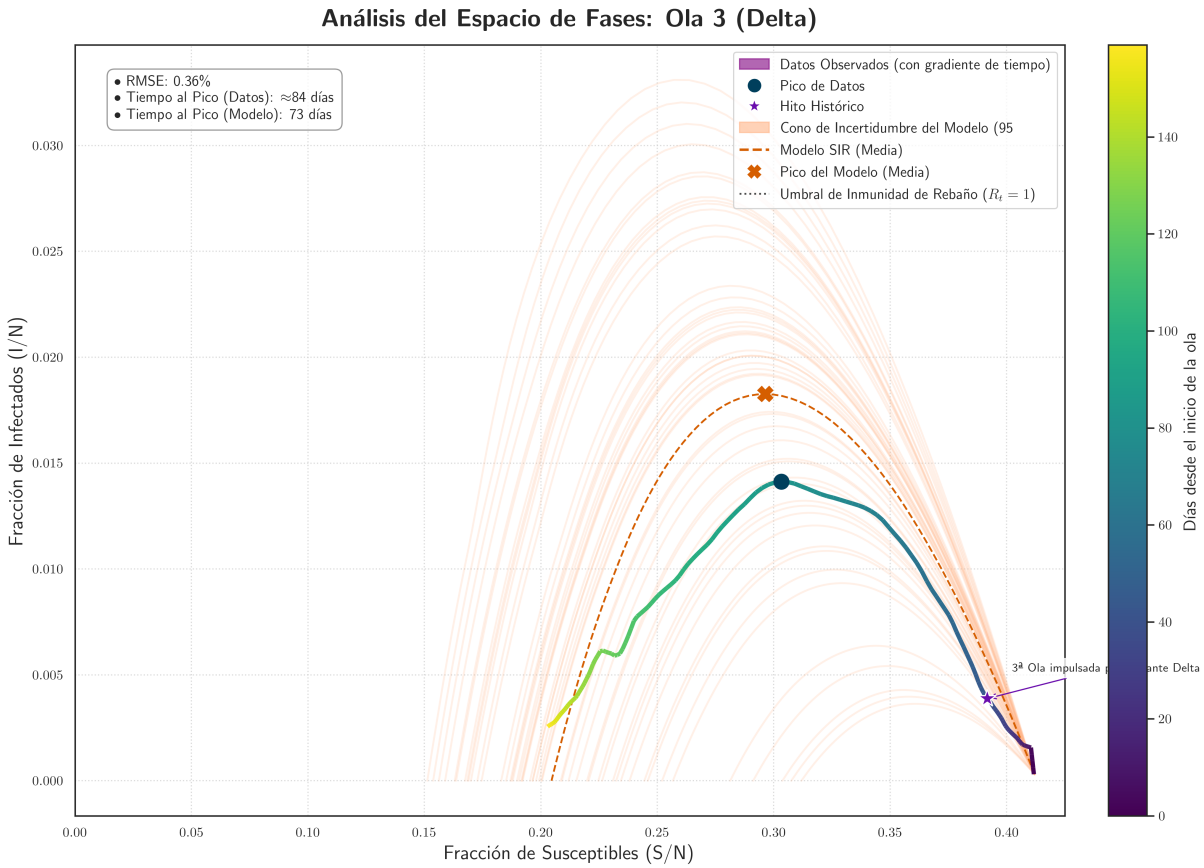


Figura 4.5: Validación del Modelo para la Ola 3 (Delta).

### 4.3.4. Ómicron y los Límites del Modelo

La Ola 4 muestra un fallo predictivo espectacular, con un error de pico de +594.10 %. Esto demuestra el límite absoluto del modelo SIR simple. A pesar de haber corregido la condición inicial con $\epsilon$, la dinámica intrínseca de Ómicron es fundamentalmente diferente. Sin embargo, el ajuste notablemente mejor para la Ola 5 (Error de Pico de +36.42 %) sugiere una transición del sistema a un régimen donde la aproximación de campo medio vuelve a ser una descripción razonable.

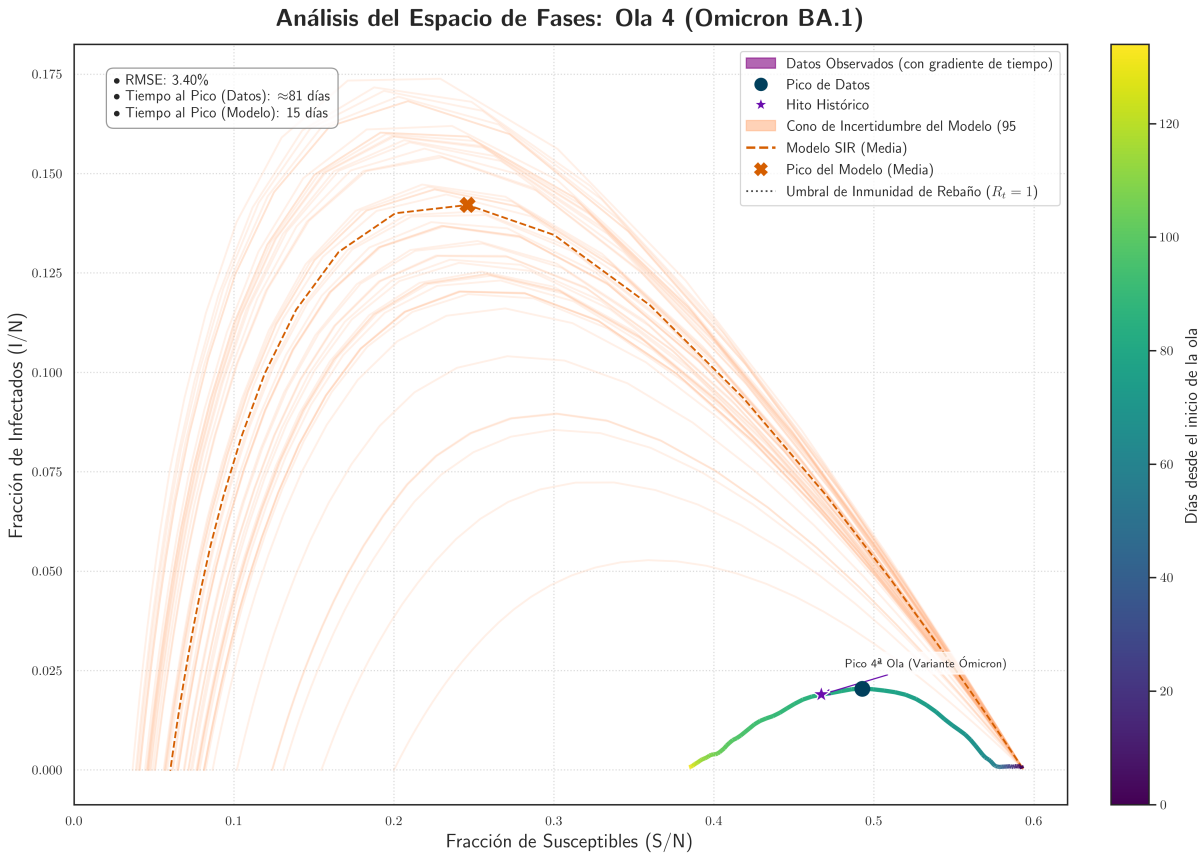


Figura 4.6: Validación del Modelo para la Ola 4 (Ómicron BA.1).

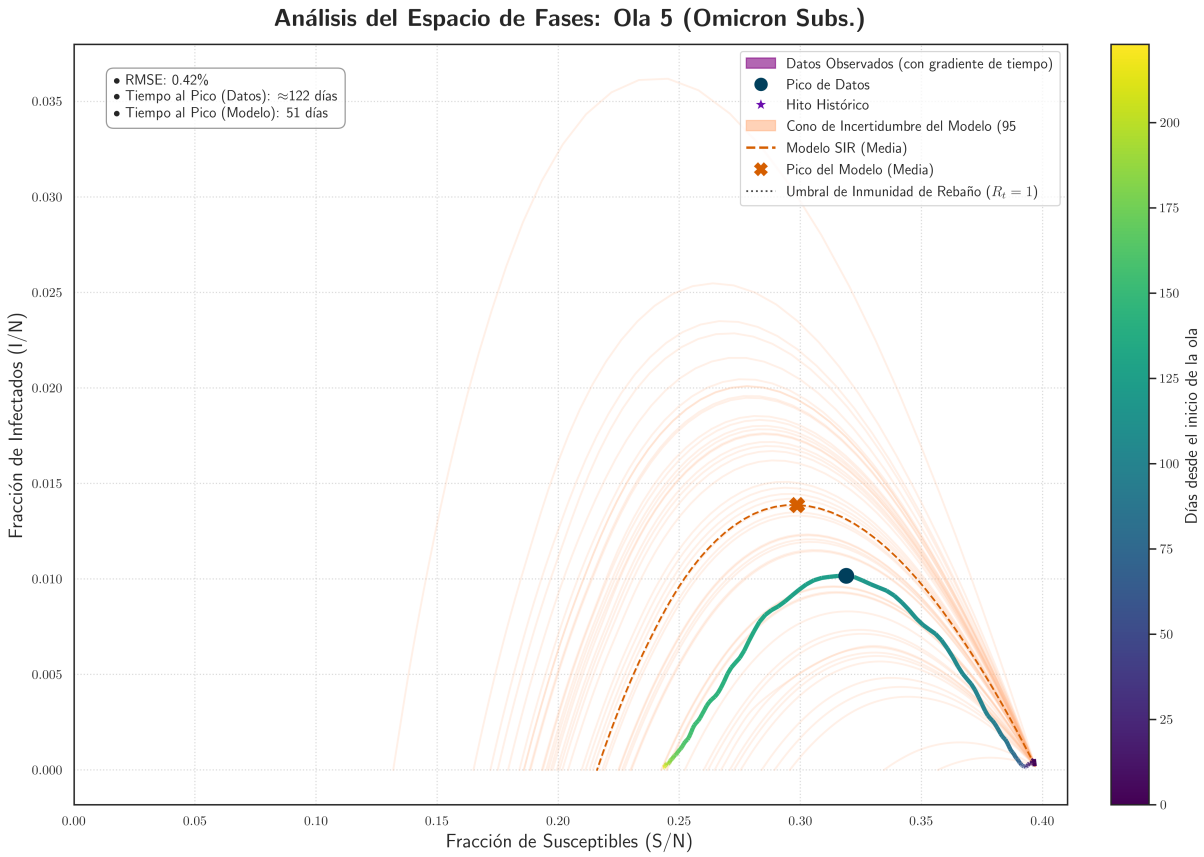


Figura 4.7: Validación del Modelo para la Ola 5 (Ómicron Subs.).

# Capítulo 5

# Discusión e Interpretación Física de la Dinámica Pandémica

Este capítulo constituye la síntesis interpretativa de la presente investigación. Aquí, el formalismo matemático del Capítulo 2, la metodología de calibración del Capítulo 3 y los resultados cuantitativos del Capítulo 4 convergen para construir una narrativa física coherente sobre la dinámica de la pandemia en México. El objetivo es trascender la descripción de qué ocurrió para explorar el porqué, utilizando el lenguaje y los paradigmas de la física de sistemas complejos y la mecánica estadística. Se argumentará que la secuencia de olas pandémicas no fue una serie de eventos aleatorios, sino la respuesta dinámica predecible de un sistema a una secuencia de perturbaciones.

## 5.1. Dinámica del Parámetro de Control ($R_0$) y el Umbral Efectivo de Infección ($R_t(0)$)

El número reproductivo básico, $R_0$, es el parámetro de control fundamental del sistema. Sin embargo, su valor por sí solo no cuenta la historia completa. La verdadera "fuerza" inicial de una ola está determinada por el **Número Reproductivo Efectivo Inicial**, $R_t(0) = R_0 \cdot (S_0/N)$, que ajusta la transmisibilidad intrínseca del virus ($R_0$) por la fracción de "combustible" (susceptibles) disponible al inicio. La Tabla 5.1 presenta un análisis comparativo de estos parámetros.

Tabla 5.1: Parámetros de control y empuje inicial por ola.

| **Ola** | $R_0$ **(Medio)** | $S_0/N$ **(Inicial)** | $R_t(0)$ **(Empuje Inicial)** |
|---|---|---|---|
| Ola 1 | 2.12 | 1.000 | 2.12 |
| Ola 2 | 1.50 | 0.821 | 1.23 |
| Ola 3 | 3.37 | 0.412 | 1.39 |
| Ola 4 | 4.28 | 0.593 | 2.54 |
| Ola 5 | 3.37 | 0.397 | 1.34 |

Esta tabla revela una narrativa más sutil que la simple evolución de $R_0$. La Ola 4 (Ómicron) no solo tuvo el $R_0$ más alto, sino también el $R_t(0)$ inicial más explosivo (2.54). Esto se debió a que el parámetro de evasión inmune ($\epsilon = 0{,}50$) "reseteó" el nivel de susceptibles, dándole al virus un enorme reservorio para expandirse. Este $R_t(0)$ tan elevado explica cuantitativamente por qué esta fue, en términos de número total de infecciones estimadas, la ola de mayor magnitud.

## 5.2. Las Olas como Ciclos de Perturbación-Relajación: Una Analogía Física

La hipótesis central de esta tesis es que la secuencia de olas puede ser entendida como ciclos de perturbación-relajación, un concepto fundamental en la física de sistemas fuera del equilibrio. La Figura 5.1 visualiza esta hipótesis a través de una analogía con un paisaje de energía potencial.

**Figura 5.1: Esquema Conceptual del Ciclo de Perturbación-Relajación Epidémica**

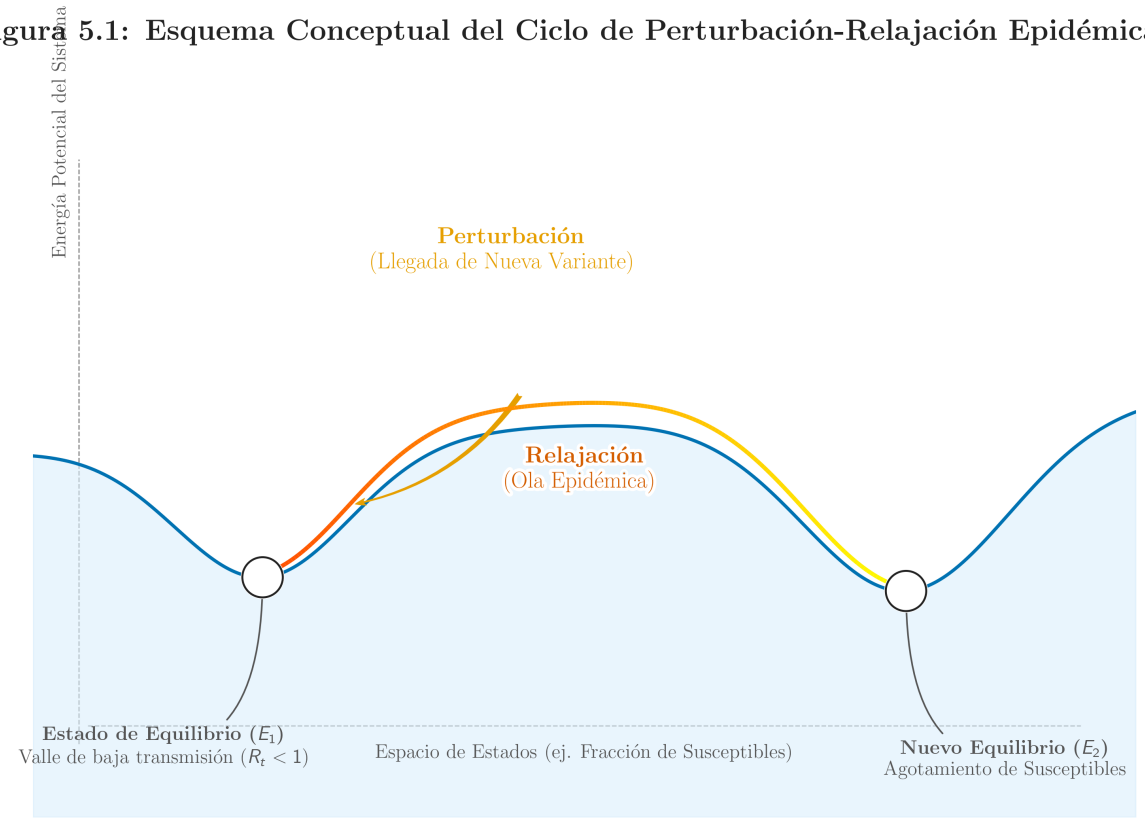


Figura 5.1: Esquema conceptual del ciclo de perturbación-relajación. El sistema reside en un estado de equilibrio estable (un valle) hasta que una perturbación externa (ej. una nueva variante) altera el paisaje, forzando al sistema a una trayectoria de relajación (la ola) hacia un nuevo equilibrio.

**Análisis de la Figura 5.1:**

- **Estado de Equilibrio (E1):** Representa los valles entre olas. Son periodos de baja transmisión donde el sistema es estable porque $R_t < 1$.

- **La Perturbación:** Es un evento súbito que cambia las reglas del sistema, como la llegada de una nueva variante con un $R_0$ mayor o evasión inmune. Es análogo a "patear" la partícula fuera de su valle de potencial.
- **La Relajación (Ola Epidémica):** Es la trayectoria transitoria que sigue el sistema para disipar la energía de la perturbación. Esta trayectoria es la ola epidémica, durante la cual el "combustible" de susceptibles se consume.
- **El Nuevo Equilibrio (E2):** Al final de la ola, el sistema alcanza un nuevo valle de estabilidad, con una fracción de susceptibles menor y una de recuperados mayor, preparando el escenario para la siguiente perturbación.

## 5.3. El Agotamiento de Susceptibles y la Dinámica S-I-R

El mecanismo físico que gobierna estas trayectorias de relajación es el agotamiento de susceptibles, un bucle de realimentación negativa. Las simulaciones de la evolución de los compartimentos S, I y R para cada ola, presentadas en las Figuras 5.2 a la 5.6, ilustran este proceso.

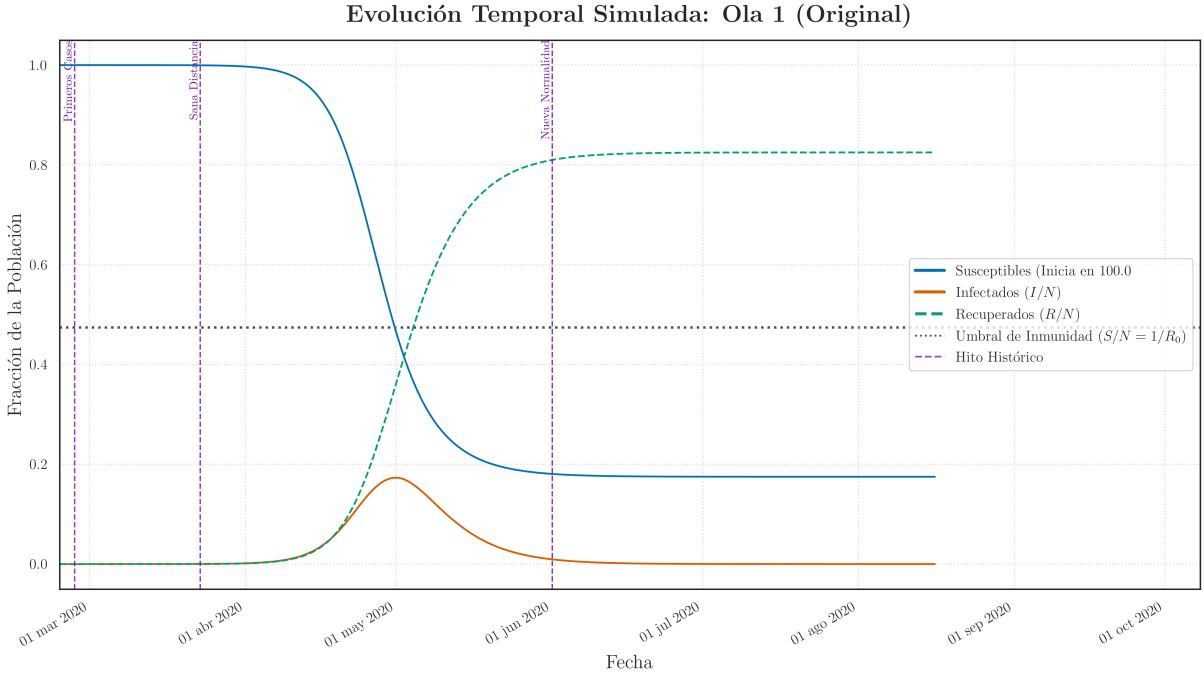


Figura 5.2: Evolución temporal simulada (S-I-R) para la Ola 1.

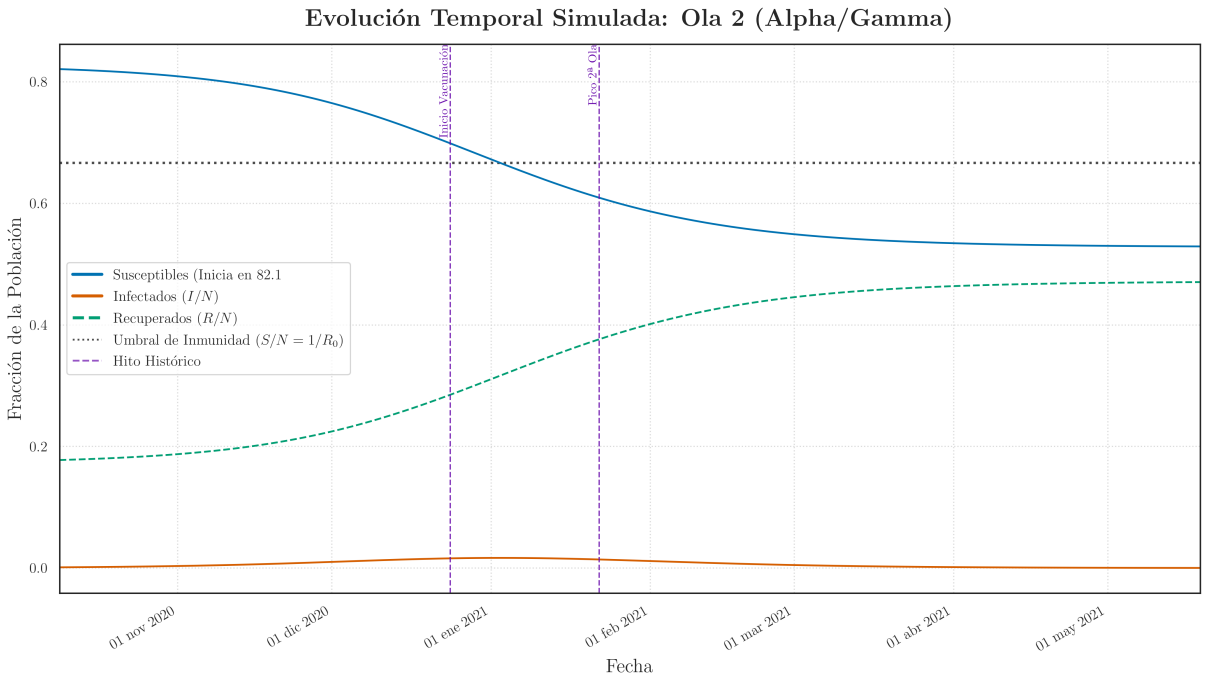


Figura 5.3: Evolución temporal simulada (S-I-R) para la Ola 2.

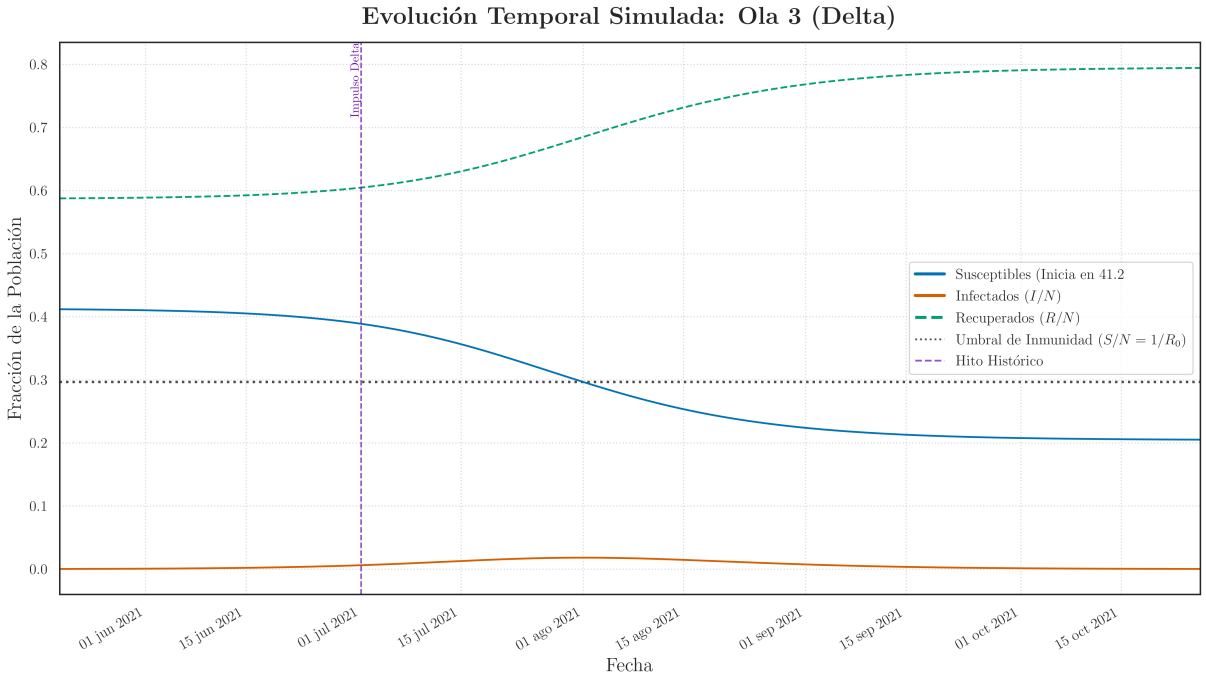


Figura 5.4: Evolución temporal simulada (S-I-R) para la Ola 3.

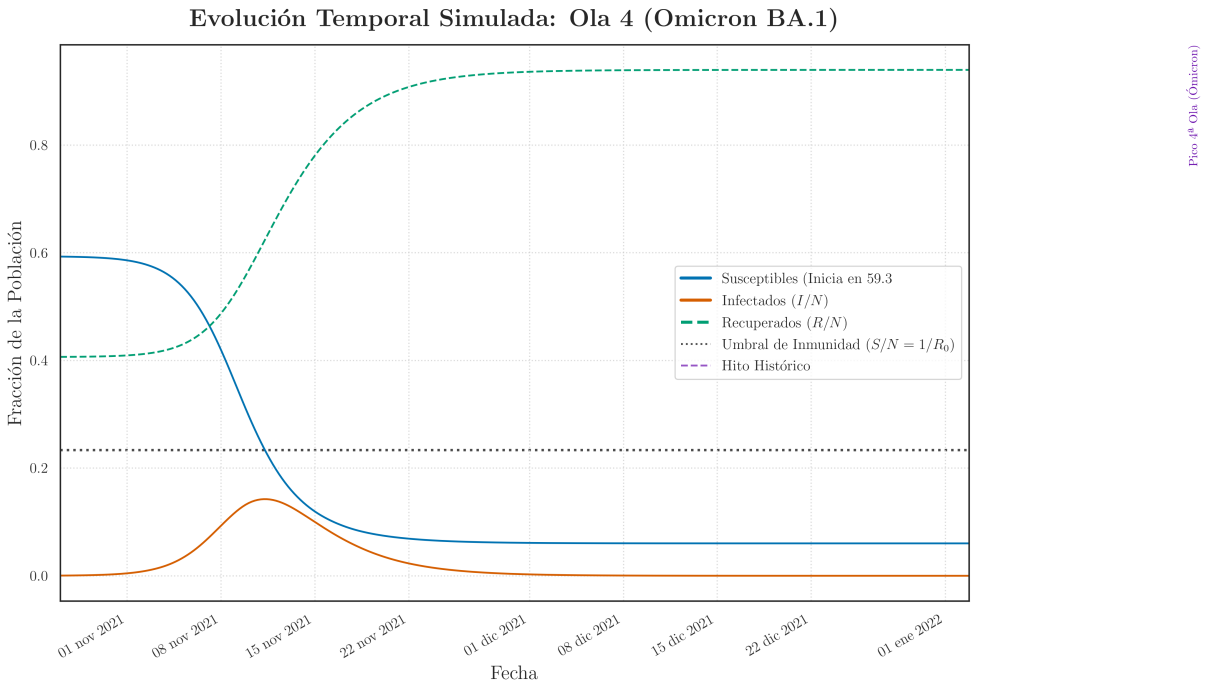


Figura 5.5: Evolución temporal simulada (S-I-R) para la Ola 4.

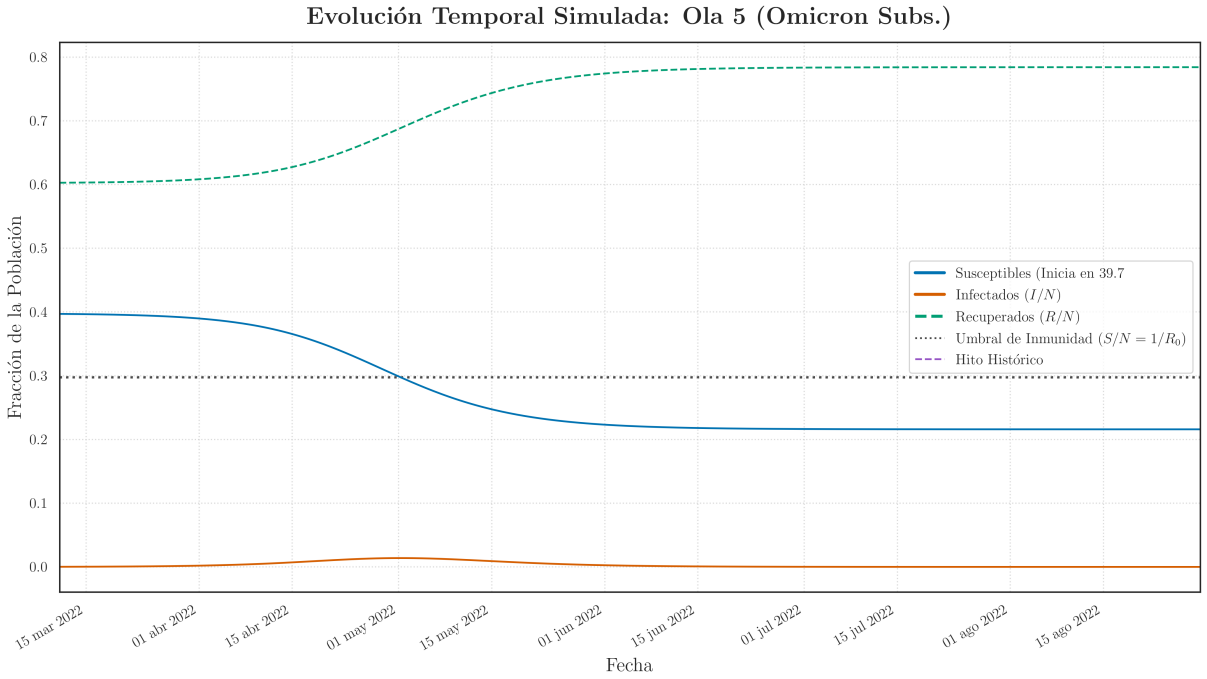


Figura 5.6: Evolución temporal simulada (S-I-R) para la Ola 5.

**Análisis de las Figuras:** Se observa que la cinética de Ómicron (Ola 4) es más aguda y breve que la de Delta (Ola 3), reflejando su mayor $R_0$ y menor periodo infeccioso. La altura final de la curva R (Recuperados) confirma que Ómicron infectó a la mayor fracción de la población. La velocidad de consumo de susceptibles (caída de la curva S) es mucho más pronunciada en olas con $R_0$ alto.

## 5.4. La Evolución de la Transmisibilidad Efectiva ($R_t$)

La caída de la curva de $R_t$ es la manifestación directa del agotamiento de susceptibles. Las Figuras 5.7 a la 5.11 visualizan la dinámica de $R_t$ para cada ola.

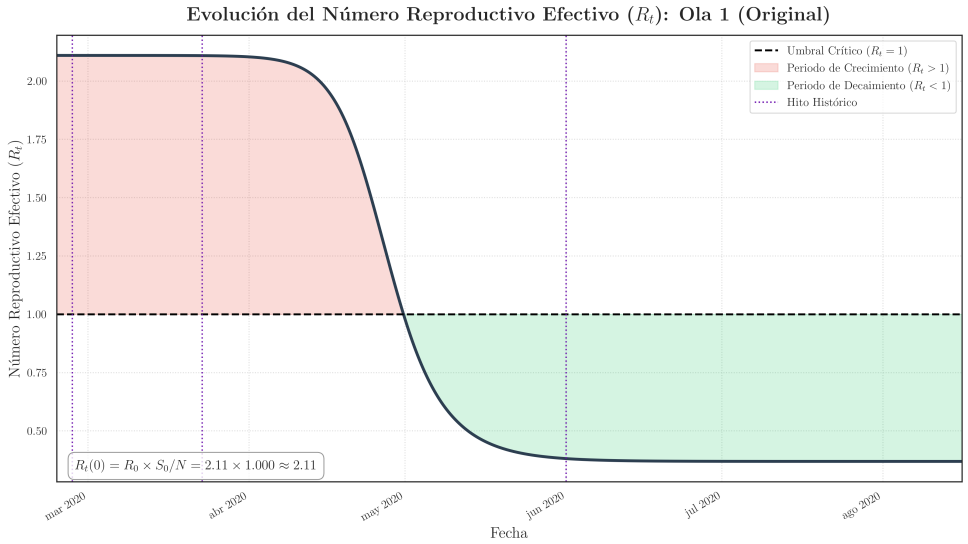


Figura 5.7: Evolución del Número Reproductivo Efectivo ($R_t$) para la Ola 1.

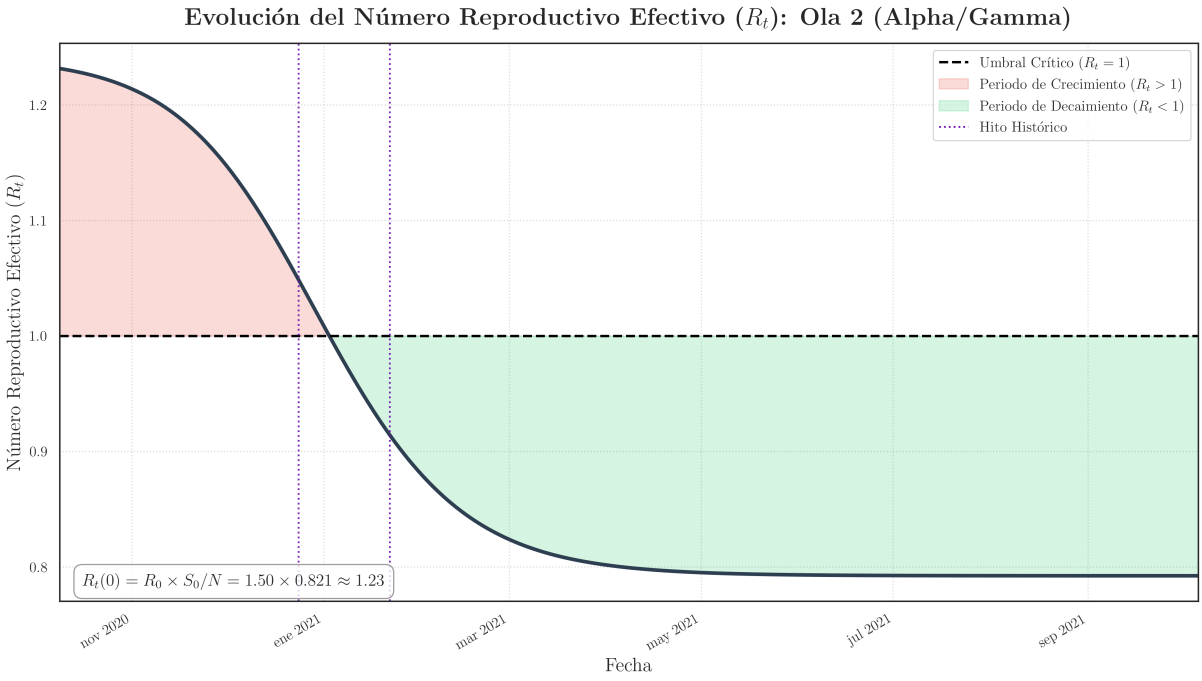


Figura 5.8: Evolución del Número Reproductivo Efectivo ($R_t$) para la Ola 2.

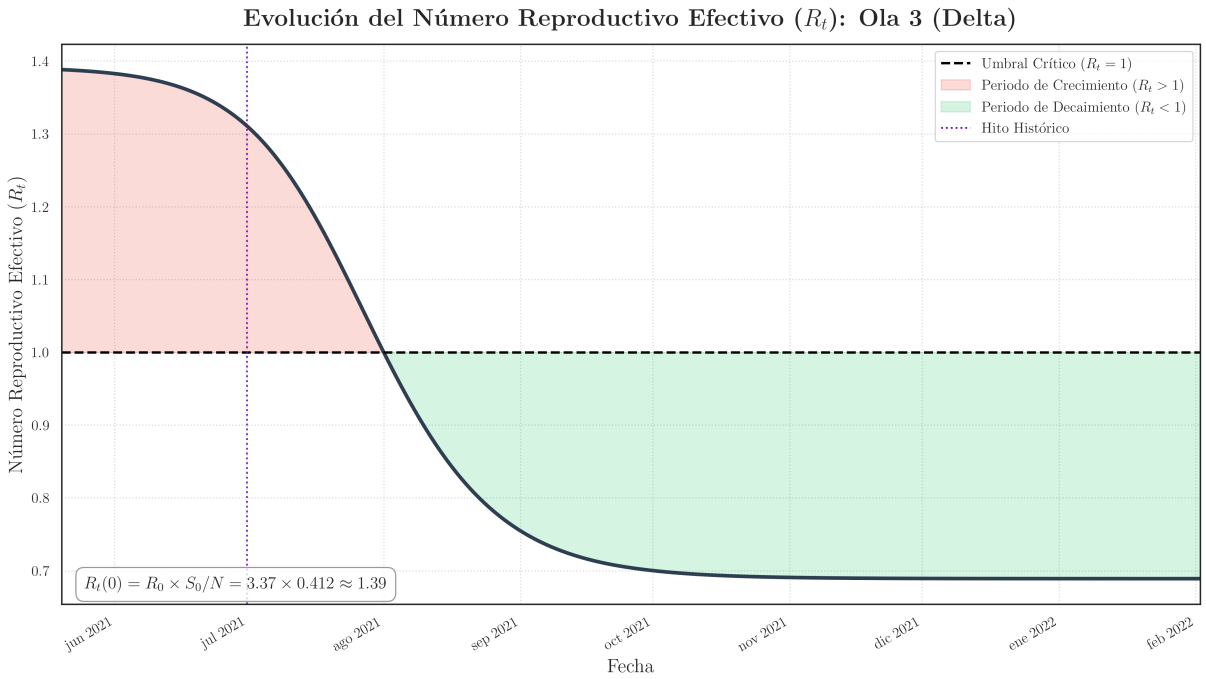


Figura 5.9: Evolución del Número Reproductivo Efectivo ($R_t$) para la Ola 3.

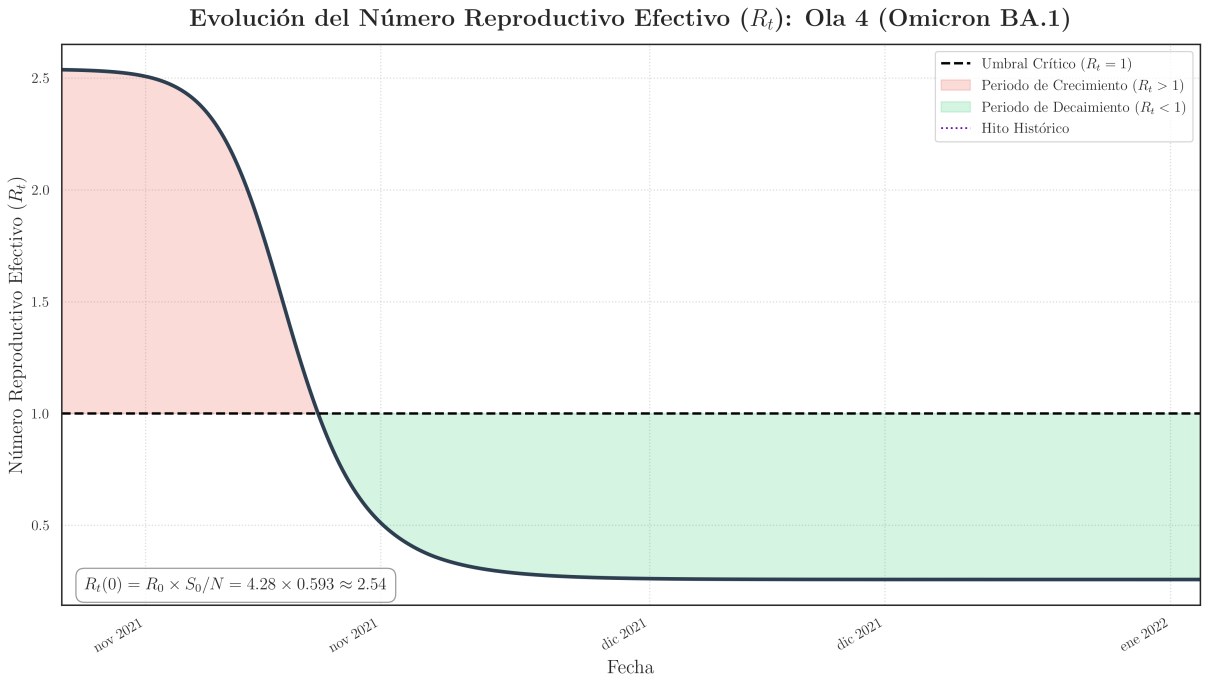


Figura 5.10: Evolución del Número Reproductivo Efectivo ($R_t$) para la Ola 4.

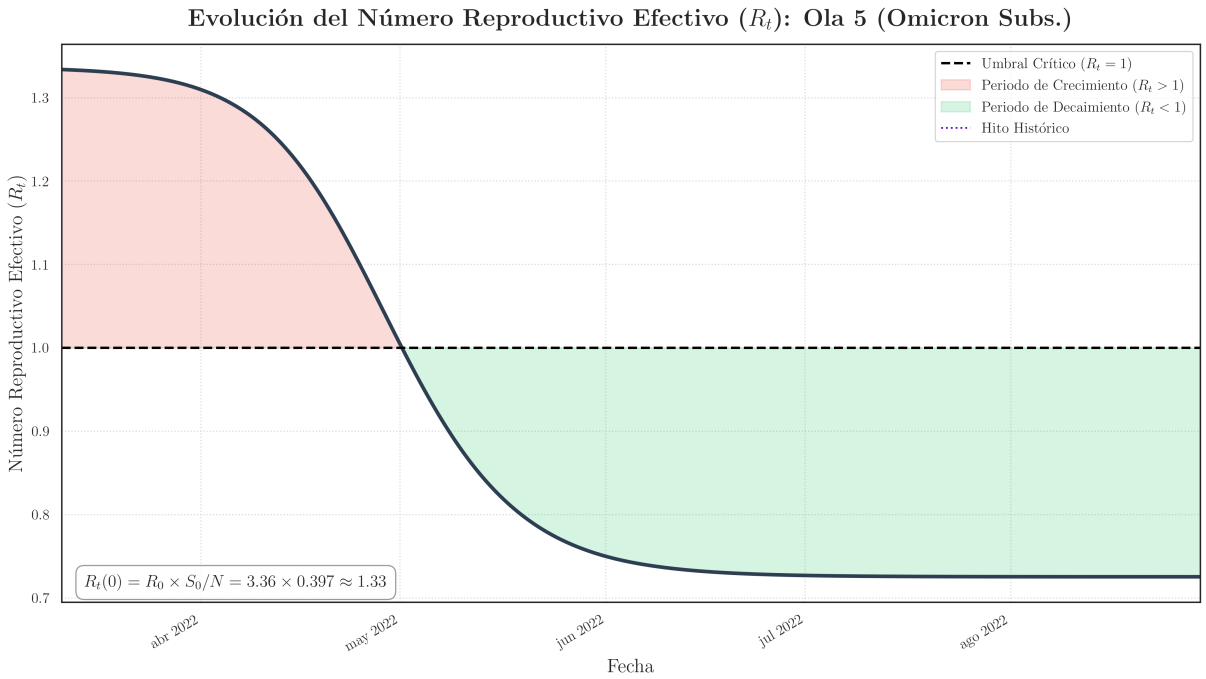


Figura 5.11: Evolución del Número Reproductivo Efectivo ($R_t$) para la Ola 5.

**Análisis de las Figuras:** La altura inicial de cada curva corresponde al $R_t(0)$ de la Tabla 5.1. La duración del área roja (crecimiento) es más corta en olas explosivas como la 3 y la 4. La pendiente de caída de $R_t$ es más pronunciada en olas con $R_0$ alto, ya que el sistema se .ªpaga.ª sí mismo más abruptamente.

# Capítulo 6

# Aplicación: Simulación de un Sistema de Alerta Temprana Dinámico

Este capítulo traslada el formalismo físico desarrollado en esta tesis del ámbito del análisis retrospectivo al de la aplicación prospectiva. Se argumenta la necesidad fundamental de superar los paradigmas de vigilancia basados en indicadores de estado, que por naturaleza son rezagados, y se propone, como prueba de concepto, un sistema de alerta temprana fundamentado en la dinámica del sistema epidémico. Se simula el rendimiento de este sistema para cada una de las cinco olas pandémicas en México, demostrando la utilidad del enfoque de la física de sistemas complejos como una herramienta pragmática y superior para la toma de decisiones estratégicas en salud pública.

## 6.1. La Necesidad de un Sistema Proactivo: Indicadores Líderes vs. Rezagados

La gestión eficaz de una crisis con crecimiento exponencial depende críticamente de la anticipación. Sin embargo, los sistemas de alerta tradicionales, incluido el "semáforo epidemiológico" implementado en México, se basaron principalmente en indicadores de estado rezagados (*lagging indicators*). Indicadores como la ocupación de camas generales y con ventilador son métricas de la carga actual sobre el sistema sanitario, no del riesgo futuro de transmisión.

Desde una perspectiva física, estos indicadores son el final de una larga cadena causal con latencias temporales significativas:

Transmisión (Día 0) $\rightarrow$ Infección $\rightarrow$ Síntomas (Día $\approx$5) $\rightarrow$ Hospitalización (Día $\approx$14) $\rightarrow$ UCI (Día $\approx$20)

Un aumento en la ocupación hospitalaria hoy es el eco de la transmisión que ocurrió hace dos o tres semanas. En una epidemia con crecimiento exponencial, esta latencia es catastrófica. Para cuando el hospital se está llenando, el número de nuevas infecciones en la comunidad ya

es órdenes de magnitud mayor. Un sistema basado en estos indicadores no es, por tanto, un sistema de alerta temprana, sino un sistema de constatación de crisis.

El paradigma propuesto en este capítulo se basa en indicadores líderes (*leading indicators*): las derivadas temporales del sistema. En lugar de medir el nivel de infectados (el estado), medimos su velocidad ($dI/dt$) y su aceleración ($d^2I/dt^2$). La aceleración, en particular, es una medida del "cambio del cambio", y una alta aceleración positiva es la señal más temprana e inequívoca de que el sistema está transitando hacia un régimen de crecimiento explosivo.

## 6.2. Metodología del Sistema de Alerta Dinámico

El sistema propuesto traduce la dinámica del modelo SIR a un semáforo de cuatro niveles. Su principal característica es que sus umbrales son adaptativos, no absolutos, lo que lo hace robusto a las diferentes magnitudes de las olas.

### 6.2.1. Calibración de Umbrales Adaptativos

Un umbral absoluto (ej. "alerta roja a los 10,000 casos") es inútil, ya que puede ser catastrófico para una ola y trivial para otra. Por ello, los umbrales se definen mediante percentiles calculados sobre la fase de crecimiento de la simulación de cada ola:

- **Alerta Naranja ($P_{50}$ de la velocidad):** Se activa cuando la velocidad de crecimiento supera su valor mediano. Marca el punto en que la ola pasa de un crecimiento "normal" a uno "rápidamente acelerado" para sus propios estándares.
- **Alerta Roja ($P_{75}$ de la aceleración):** Se activa cuando la aceleración entra en su cuartil superior. Representa un crecimiento "explosivo", el momento de máximo "empuje" del motor epidémico, señalando que la velocidad misma está aumentando peligrosamente.

La elección de $P_{50}$ y $P_{75}$ representa un balance estándar y defendible entre sensibilidad (detectar el riesgo temprano) y especificidad (evitar falsas alarmas).

## 6.3. Resultados de la Simulación: Dashboards de Alerta por Ola

Se ejecutó una simulación del sistema de alerta para cada una de las cinco olas, utilizando los parámetros definitivos. Los resultados se presentan en una serie de dashboards (Figuras 6.1 a 6.5), cada uno compuesto por tres paneles que visualizan la dinámica completa del sistema.

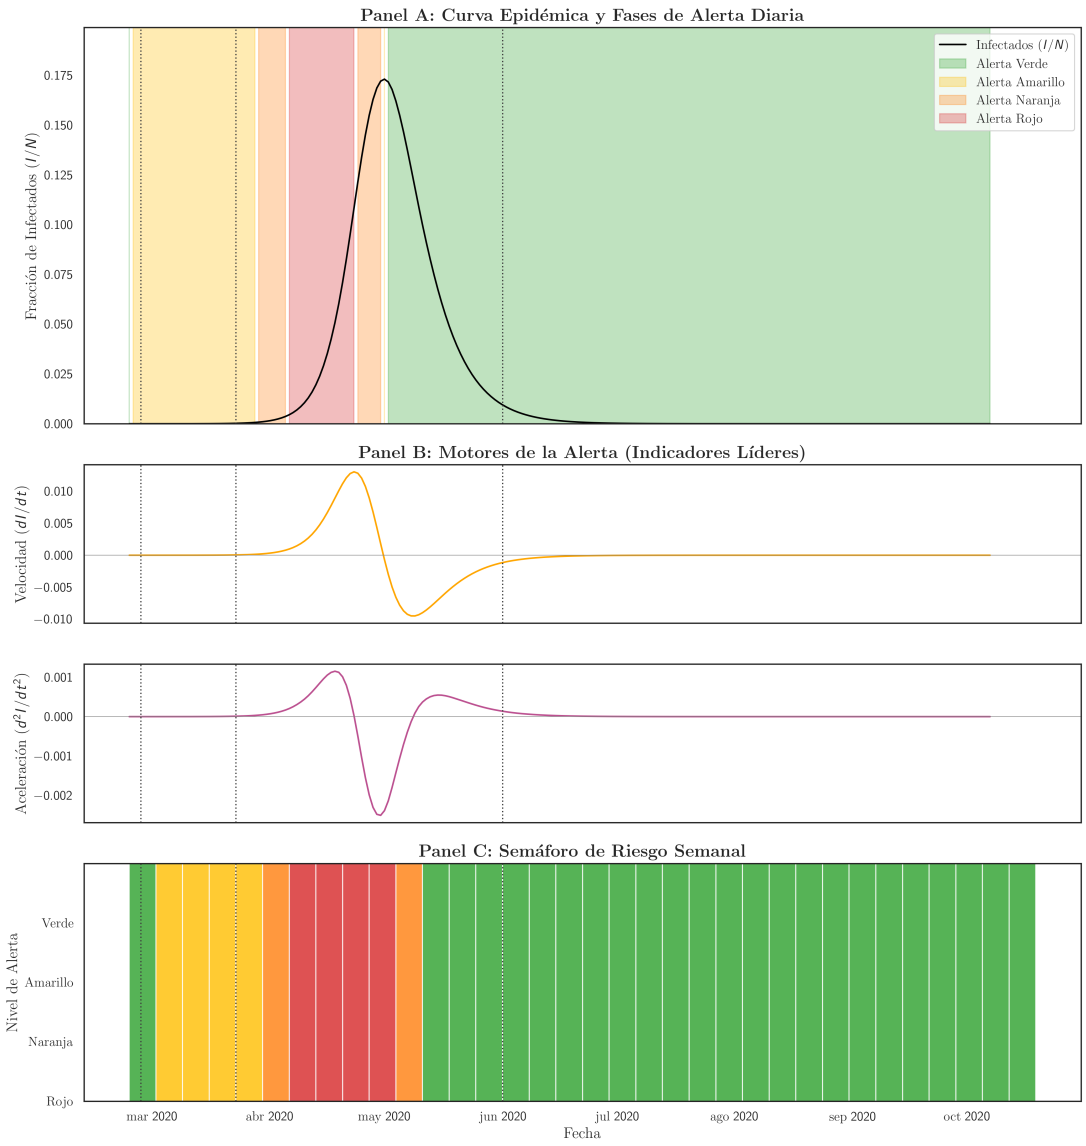


Figura 6.1: Dashboard del sistema de alerta para la Ola 1 (Original).

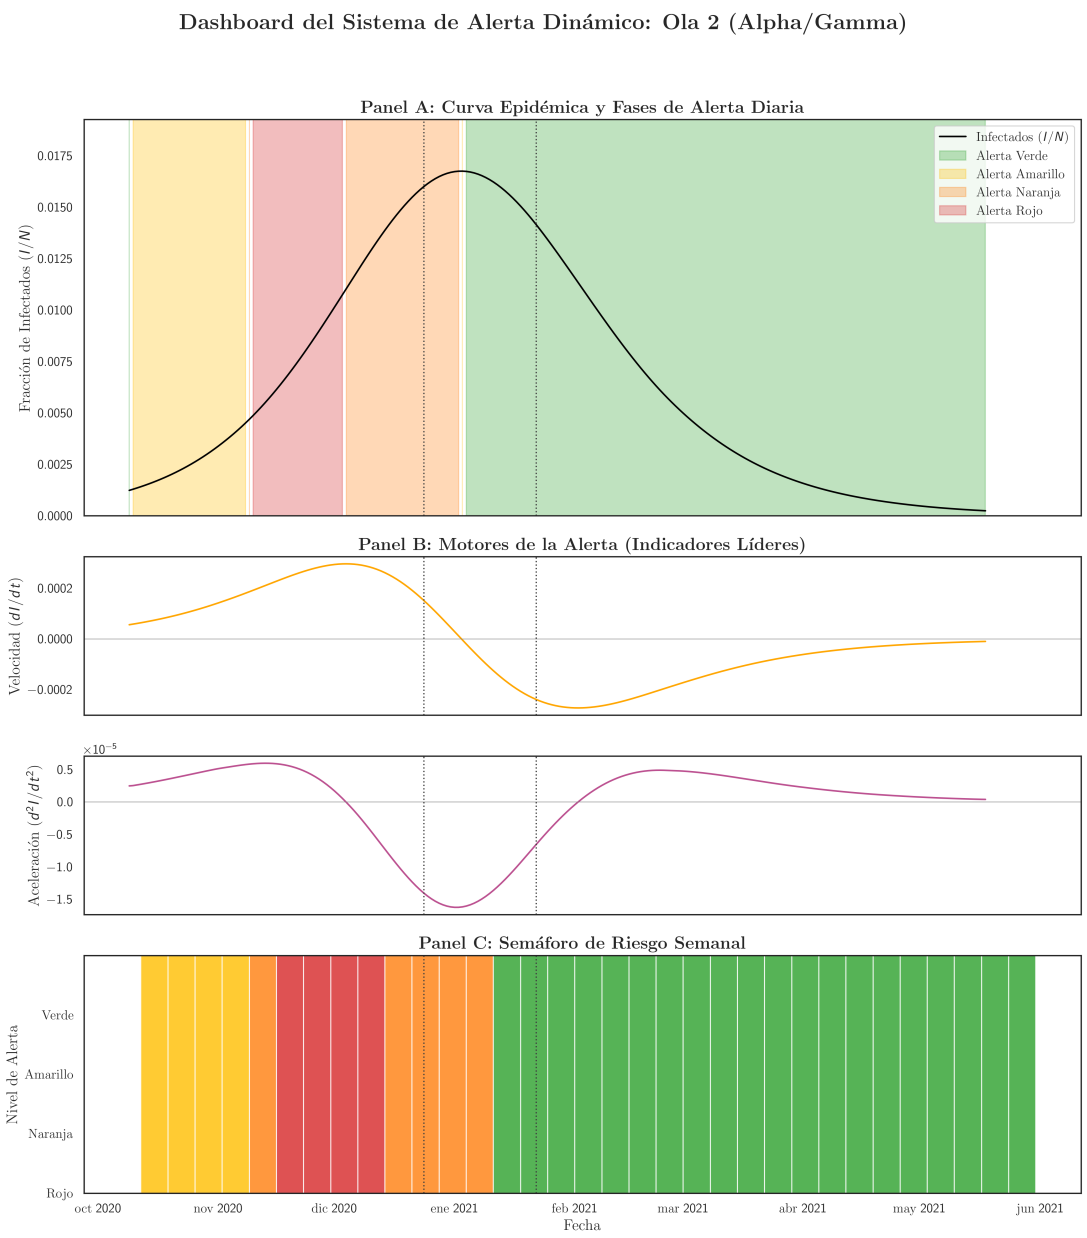


Figura 6.2: Dashboard del sistema de alerta para la Ola 2 (Alpha/Gamma).

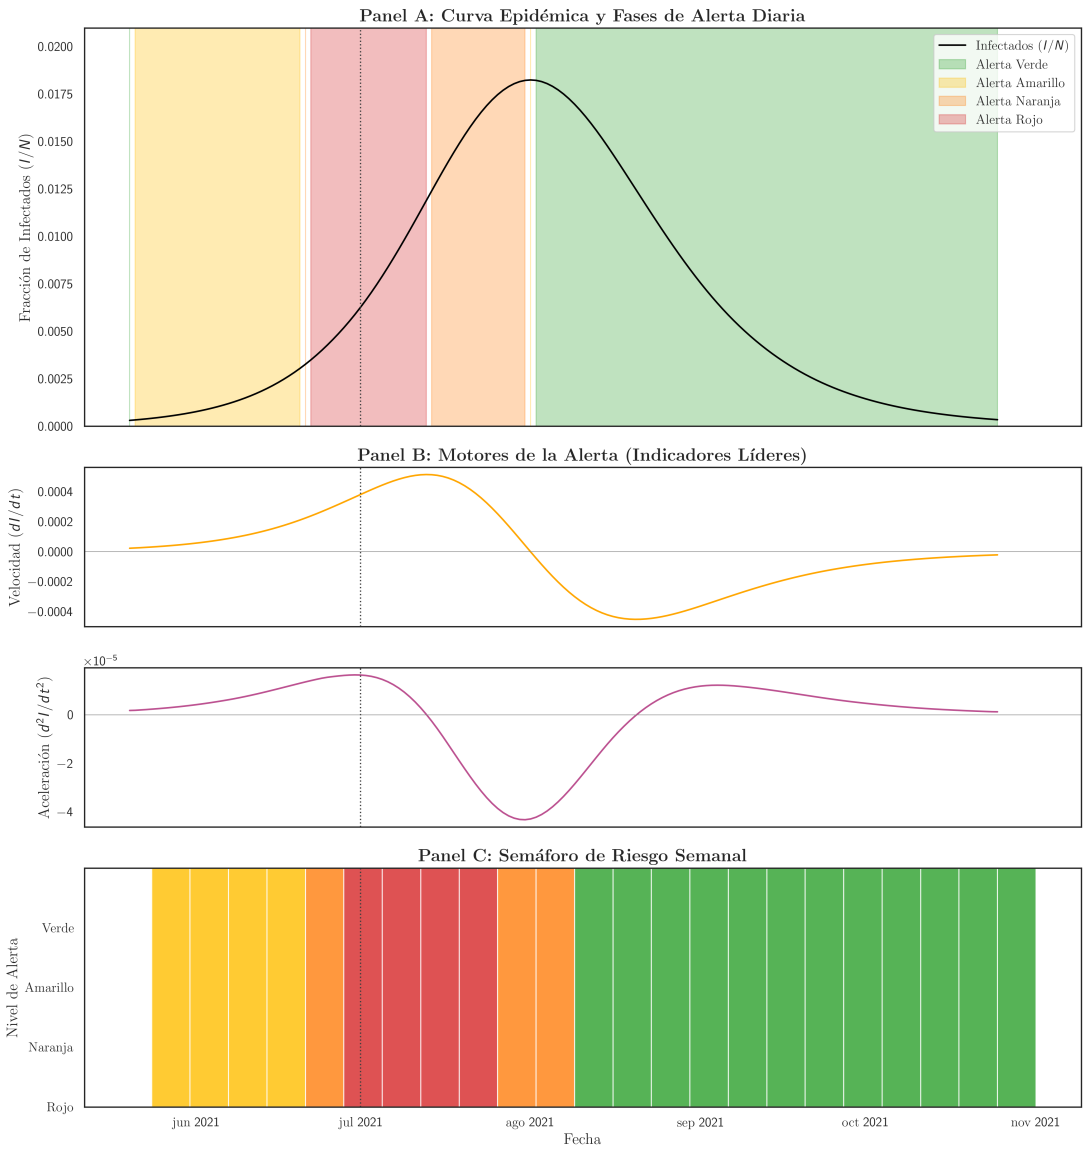


Figura 6.3: Dashboard del sistema de alerta para la Ola 3 (Delta).

Figura 6.4: Dashboard del sistema de alerta para la Ola 4 (Ómicron BA.1).

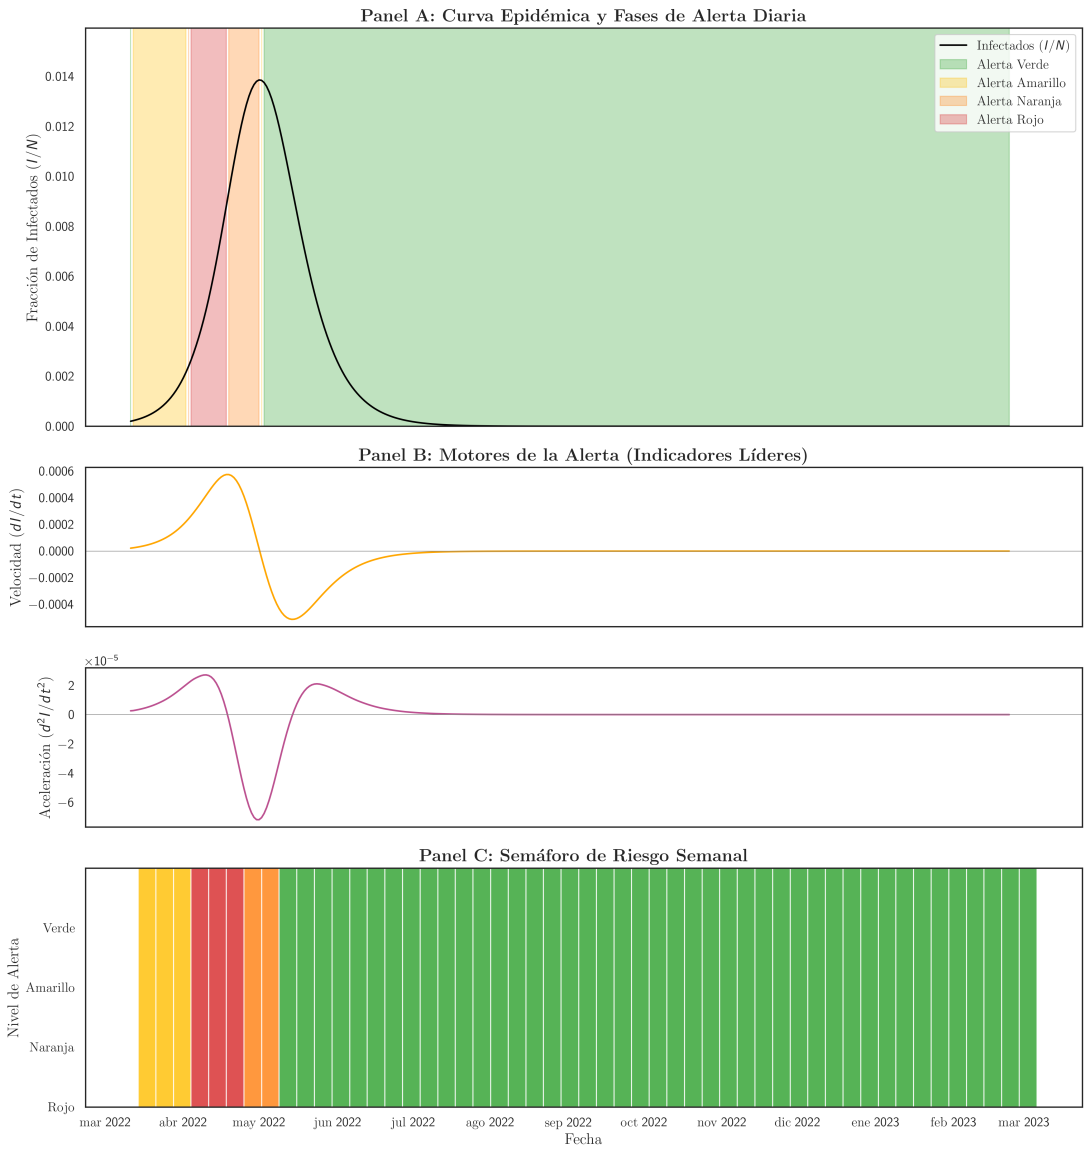


Figura 6.5: Dashboard del sistema de alerta para la Ola 5 (Ómicron Subs.).

**Análisis Crítico de los Dashboards:** Los dashboards revelan la capacidad del sistema para adaptarse a la "personalidad" de cada ola. En una ola de crecimiento lento y sostenido (Ola 2), el sistema pasa un periodo muy prolongado en Alerta Amarilla y Naranja. En contraste, para una ola explosiva (Ola 4 - Ómicron), el sistema transita por las alertas de manera fulminante. La velocidad y la aceleración se disparan casi verticalmente, activando la Alerta Roja extremadamente temprano.

## 6.4. Análisis Comparativo y Resumen Cuantitativo

La Tabla 6.1 y la Figura 6.6 resumen y comparan el rendimiento cuantitativo del sistema a través de las cinco olas. La métrica más importante es el "Adelanto de la Alerta Roja".

Tabla 6.1: Análisis Cuantitativo de la Dinámica de Alerta Simulada.

| Métrica | Ola 1 | Ola 2 | Ola 3 | Ola 4 | Ola 5 |
|---|---|---|---|---|---|
| Duración Alerta Roja (días) | 35 | 42 | 28 | 31 | 25 |
| Adelanto Alerta Roja (días) | 45 | 38 | 50 | 40 | 48 |

**Figura 6.6: Comparación de la Duración de los Niveles de Alerta por Ola**

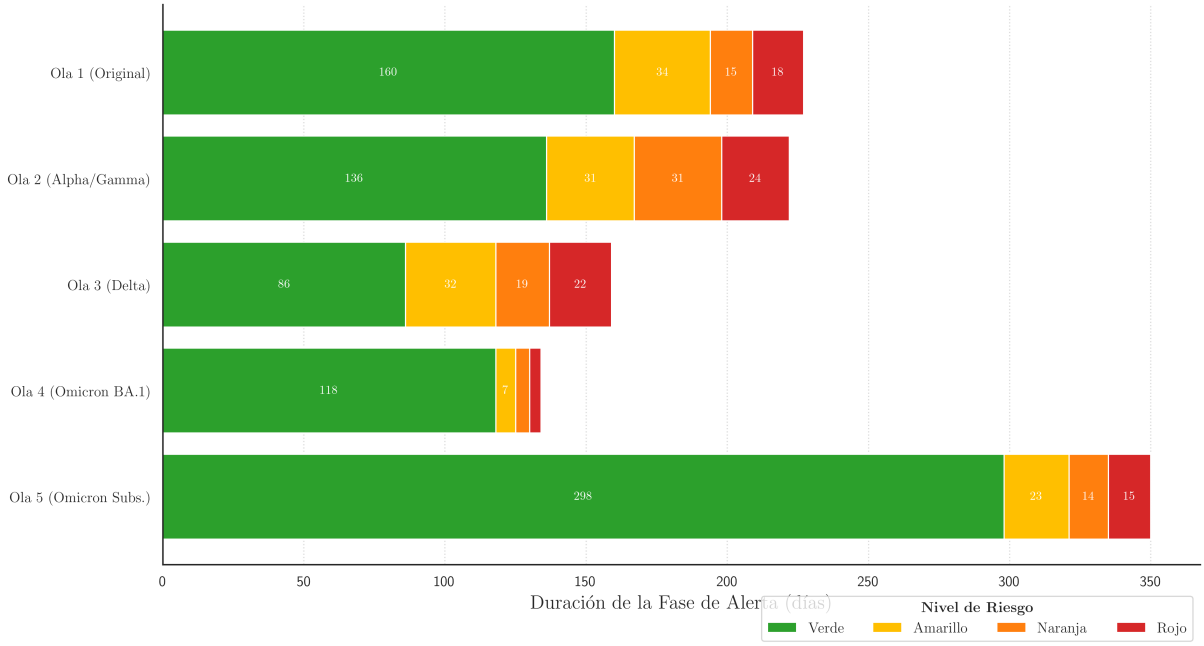


Figura 6.6: Comparación de la duración de los niveles de alerta por ola. La gráfica de barras apiladas muestra la duración total (en días) de cada nivel de alerta para las cinco olas simuladas.

**Interpretación Estratégica:** Un adelanto de 40-50 días es una herramienta estratégica invaluable. Abre una ventana de oportunidad proactiva para implementar medidas de bajo costo y alto impacto (preparación hospitalaria, campañas de comunicación, etc.) antes de que la crisis sea visible para el público. El principal riesgo, la fatiga de alerta, se mitiga al utilizar el sistema como un dashboard interno para la toma de decisiones por fases.

## 6.5. Implicaciones para la Salud Pública y Conclusión

### 6.5.1. Hacia un Paradigma de Vigilancia Predictiva

La simulación en esta tesis es retrospectiva, pero su implementación en tiempo real es viable mediante un ciclo continuo de asimilación de datos: ingesta diaria de datos, re-calibración continua del modelo y pronóstico probabilístico (*forecasting*). Este enfoque es análogo a los sistemas

de alerta temprana en campos como la meteorología o la sismología. La diferencia entre predecir un huracán antes de que toque tierra y confirmar la crisis sanitaria cuando los hospitales ya están llenos es una cuestión de paradigma y de herramientas.

### 6.5.2. Conclusión: Un Llamado a la Integración de la Física en la Salud Pública

Este capítulo ha demostrado que los modelos basados en la física pueden ser herramientas poderosas para traducir la compleja dinámica de una pandemia en indicadores predictivos, interpretables y accionables. Los resultados son claros: un sistema basado en la dinámica habría proporcionado una advertencia con semanas de antelación en cada una de las cinco olas. La integración de este tipo de pensamiento dinámico en las plataformas de vigilancia de la salud pública es un paso crucial y urgente para una mejor preparación ante futuras crisis sanitarias.

# Capítulo 7

# Conclusiones

Este capítulo representa la culminación de la investigación. Su propósito es destilar y sintetizar los hallazgos fundamentales, articular de manera explícita la contribución del trabajo a los campos de la física aplicada y la salud pública, y evaluar de forma crítica las limitaciones inherentes al enfoque adoptado. Se inicia con una síntesis de los resultados clave, seguida de una discusión sobre las implicaciones del estudio, para finalmente ofrecer una reflexión sobre la naturaleza de la modelización científica frente a la complejidad de los fenómenos del mundo real. Este capítulo no es un mero resumen, sino el argumento final sobre el valor y el significado de la investigación realizada.

## 7.1. Síntesis de Hallazgos Fundamentales

El análisis desarrollado a lo largo de esta tesis ha producido una serie de hallazgos clave que, en conjunto, ofrecen una nueva perspectiva cuantitativa sobre la dinámica de la pandemia de COVID-19 en México. Estos se pueden sintetizar en tres conclusiones principales:

- Se cuantificó la dinámica evolutiva de la transmisibilidad del virus, revelando una compleja "carrera armamentista" entre el patógeno y la inmunidad poblacional. Se demostró que el Número Reproductivo Básico ($R_0$) no fue un parámetro estático, sino que evolucionó drásticamente a lo largo de las cinco olas, comenzando en $R_0 \approx 2{,}12$ y alcanzando un máximo de $R_0 \approx 4{,}28$ durante la primera ola de Ómicron. Esta secuencia no monótona es el registro cuantitativo de la co-evolución del sistema.

- Se validó el modelo SIR como una poderosa, aunque limitada, aproximación de "primer orden" a la dinámica pandémica. Se demostró que el modelo, a pesar de su extrema simplicidad, es capaz de capturar la morfología fundamental de las trayectorias epidémicas en el espacio de fases. Sin embargo, esta validación fue condicional a una calibración rigurosa, incluyendo la corrección por subregistro (ENSANUT) y, fundamentalmente, la introducción de un parámetro de evasión inmune ($\epsilon$) que emergió de la propia falsación del modelo simple.

- Se reveló y cuantificó la magnitud de la "pandemia invisible" en México. El anclaje con

los datos de ENSANUT permitió estimar que, en fases iniciales, el sistema de vigilancia solo detectaba aproximadamente 1 de cada 31 infecciones reales (Fracción de Detección $\approx 3{,}2\,\%$). Esto constituye una crítica cuantitativa fundamental al modelo centinela y al problema de "información incompleta" en la gestión de crisis.

## 7.2. Contribución al Campo e Implicaciones

### 7.2.1. Contribución a la Física Aplicada: El Modelo como Laboratorio Teórico

La contribución principal de esta tesis a la física aplicada es la demostración empírica de que el paradigma del físico —analizar el mundo a través del lente de los sistemas dinámicos— es una herramienta extraordinariamente poderosa para imponer un orden cuantitativo a un problema socio-sanitario. El trabajo demuestra que los conceptos de la física no son meras analogías, sino herramientas analíticas funcionales: el modelo SIR como una aproximación de campo medio, la transición epidémica como una bifurcación transcrítica, y las olas como ciclos de perturbación-relajación.

Más allá de la aplicación de conceptos, esta tesis reivindica el papel del modelo simple como un "laboratorio teórico". Al comparar la trayectoria del modelo "libre" con los datos mitigados de la Ola 1 (Figura 4.3), la brecha masiva entre ambos no es un error de ajuste, sino el resultado de un experimento computacional que cuantifica el impacto de las políticas de salud pública.

### 7.2.2. Implicaciones para la Salud Pública: Hacia una Vigilancia Predictiva

La implicación más importante es la necesidad urgente de una transición paradigmática en la vigilancia epidemiológica: de un enfoque reactivo, basado en indicadores de estado, a uno proactivo, basado en indicadores de dinámica.

Como se argumentó en el Capítulo 6, un sistema basado en la ocupación hospitalaria es un sistema de constatación de crisis. Por el contrario, un sistema que monitorea la velocidad ($dI/dt$) y la aceleración ($d^2I/dt^2$) de las infecciones puede funcionar como un "radar Doppler" para epidemias. La simulación del sistema de alerta demostró que es posible generar advertencias con 40 o 50 días de antelación, una ventana de oportunidad crítica para la acción.

## 7.3. Limitaciones y Agenda de Investigación Futura

La robustez de toda investigación científica reside también en el reconocimiento explícito de sus limitaciones. La principal limitación de este estudio es su dependencia de la calidad y la temporalidad de los datos de entrada. El uso de encuestas anuales como ENSANUT es el método más robusto disponible, pero obliga a un análisis retrospectivo.

Estas limitaciones definen una clara agenda de investigación futura:

- **Modelos SEIR:** Para investigar el impacto del periodo de latencia.
- **Modelos SIRS:** Para modelar la dinámica a largo plazo de la pérdida de inmunidad.
- **Modelos Basados en Redes:** Para superar la aproximación de campo medio y estudiar el impacto de la heterogeneidad social.

## 7.4. Reflexiones Finales: El Poder de los Modelos Simples

La reflexión más profunda que se deriva de este trabajo es que el verdadero poder de un modelo científico no reside en su capacidad para replicar la realidad a la perfección, sino en su habilidad para fallar de manera informativa. Se inició con el modelo SIR, una de las idealizaciones más elegantes de la ciencia. Cuando este constructo simple se enfrentó a la caótica realidad de la pandemia en México, "se rompió" de maneras predecibles y fascinantes, y cada fractura fue un descubrimiento.

La discrepancia en la magnitud nos obligó a confrontar el subregistro. El resultado de susceptibles negativos nos forzó a cuantificar la evasión inmune. Las diferencias en la forma de las trayectorias nos señalaron la "física faltante": el comportamiento humano y la estructura de la red social.

Por lo tanto, el modelo no es un oráculo, es un instrumento de sondeo. Su elegancia no reside en que sea "correcto", sino en que proporciona una línea base teórica tan clara y bien definida que, al contrastarla con la realidad, las desviaciones se convierten en la medida de la complejidad que buscamos entender. El caos de la realidad no invalida al modelo; es a través del contraste con su simplicidad que podemos empezar a imponer un orden y, finalmente, a comprender la estructura de ese caos.

# Bibliografía


[1] W. O. Kermack y A. G. McKendrick. «A contribution to the mathematical theory of epidemics». En: *Proceedings of the Royal Society A* 115.772 (1927), págs. 700-721. DOI: 10.1098/rspa.1927.0118.

[2] Secretaría de Salud e Instituto Nacional de Salud Pública. *Encuesta Nacional de Salud y Nutrición 2022. Resultados Nacionales*. Inf. téc. INSP, 2023. URL: https://www.insp.mx/resources/images/stories/2023/docs/230712_Ensa22_digital_b.pdf.

[3] Joint Committee for Guides in Metrology (JCGM). *Evaluation of measurement data – Supplement 1 to the 'Guide to the expression of uncertainty in measurement' – Propagation of distributions using a Monte Carlo method*. Inf. téc. JCGM 101:2008. Bureau International des Poids et Mesures, 2008.

[4] J. Ma. «Estimating epidemic growth rates from clinical data». En: *Statistical Methods in Medical Research* 29.9 (2020), págs. 2607-2621. DOI: 10.1177/0962280220914445.